


PhylogenyPro


Manual de usuario *User Manual*

DEL ALINEAMIENTO AL ÁRBOL FECHADO


EL ALINEAMIENTO



K GRUPOS



EL CONFLICTO



Bursera simaruba



Bursera aptera



Bursera glabrifolia



Commiphora africana



Boswellia sacra



Pinus cembroides



Pteridium aquilinum

Luis Ángel Barrera-Guzmán

VERSIÓN 1.3 · 2026

PhylogenyPro

Manual de usuario · Filogenia molecular, del alineamiento al árbol fechado

AUTOR	Luis Ángel Barrera-Guzmán ORCID 0000-0001-8057-2583 · lbarrerag@chapingo.mx
PROGRAMA	PhylogenyPro, versión 1.3.0 (septiembre de 2026)
MANUAL	Primera edición en español, 2026. Describe la versión 1.3.0 del programa.
LICENCIA DEL PROGRAMA	Licencia Pública General de GNU, versión 3 o posterior (GPL-3.0-or-later). El texto íntegro viene en el archivo LICENSE .
DERECHOS DEL MANUAL	© 2026 Luis Ángel Barrera-Guzmán. Todos los derechos reservados.
IDIOMA DE LA INTERFAZ	El programa está en español e inglés , y se cambia de uno a otro con el botón ES / EN de la esquina superior derecha, sin perder el trabajo. En este manual los botones y menús se escriben tal como aparecen en español, por ejemplo Construir el árbol .

CÓMO CITAR EL PROGRAMA

Barrera-Guzmán, L. Á. (2026). *PhylogenyPro: a browser-based platform for molecular phylogenetics, from the alignment to the dated tree* (versión 1.3.0) [Programa de cómputo].

CÓMO CITAR ESTE MANUAL

Barrera-Guzmán, L. Á. (2026). *PhylogenyPro. Manual de usuario* (1.^a ed.). Distribuido con PhylogenyPro, versión 1.3.0.

Los datos de citación en formato legible por máquina están en [CITATION.cff](#) y [codemeta.json](#), en la raíz del programa. Cuando el programa se deposite en un archivo permanente, el identificador de objeto digital se añadirá a esas fichas y a esta página.

I PRIVACIDAD

PhylogenyPro funciona por completo dentro de tu navegador. Los archivos que abres se leen en tu computadora y **nunca se envían a ningún servidor**. Puedes analizar secuencias inéditas, datos bajo embargo editorial o material sujeto a un acuerdo de acceso sin riesgo de que salgan de tu equipo. Las fotografías que añadas a las puntas de un árbol se guardan también en tu navegador y tampoco viajan a ninguna parte.

Las ilustraciones, diagramas y capturas de este manual son originales y se generaron con el propio programa o con código escrito para el manual. Los conjuntos de datos de ejemplo se describen en la sección I.7: las secuencias están **simuladas** sobre un árbol conocido, de modo que cada ejemplo trae su propia respuesta correcta; los nombres de especie son reales, las secuencias no. La procedencia de las constantes científicas que el programa incorpora —las matrices de sustitución de aminoácidos, la matriz BLOSUM62, el código genético y la escala de tiempo geológico— está documentada en el archivo [PROCEDENCIA.md](#).

Índice

CONTENIDO GENERAL DEL MANUAL

In	Introducción	1
1.1	¿Qué es PhylogenyPro?	2
1.2	Las preguntas que responde	2
1.3	Seis ideas que sostienen todo el manual	3
1.4	Qué datos acepta y qué entrega	5
1.5	Qué necesitas y cómo abrirlo	5
1.6	Recorrido por la interfaz	6
1.7	Los conjuntos de ejemplo, y por qué están simulados	6
1.8	Cómo se recorre un estudio de principio a fin	7
1.9	Cómo leer este manual	7
1.10	Lo que el programa no hace	8
1	La portada: lo que hay que creer antes de empezar	9
2	Datos y alineamiento	17
3	Modelos de sustitución	25
4	Parsimonia y distancias	32
5	Máxima verosimilitud	39
6	Inferencia bayesiana	46
7	El reloj molecular y los tiempos de divergencia	53
8	Diversificación	60
9	Evolución de caracteres	66
10	Biogeografía histórica	73
11	Comparar árboles, y admitir que discrepan	80
12	Figuras, formatos e informe	87
A	Apéndices	95

In

INTRODUCCIÓN · ANTES DE LOS BLOQUES

Un árbol es una hipótesis

Qué es el programa, qué preguntas responde, qué datos acepta, cómo se abre y cómo se recorre. Incluye las seis ideas que hacen falta para entender el resto del manual, la descripción de los conjuntos de ejemplo —simulados a propósito, para que traigan su propia respuesta— y una lista franca de lo que el programa no hace.



I.1¿Qué es PhylogenyPro?

I.3Seis ideas que sostienen todo el manual

I.5Qué necesitas y cómo abrirlo

I.7Los conjuntos de ejemplo

I.9Cómo leer este manual

I.2Las preguntas que responde

I.4Qué datos acepta y qué entrega

I.6Recorrido por la interfaz

I.8Cómo se recorre un estudio

I.10Lo que el programa no hace

1.1 ¿Qué es PhylogenyPro?

PhylogenyPro es una aplicación que hace un estudio filogenético completo dentro del navegador. Se abre con doble clic en un archivo, no se instala, no pide cuenta ni licencia, y no manda tus datos a ninguna parte. Del otro lado, no es un visor: calcula de verdad. Alinea las secuencias, elige el modelo de sustitución, busca el árbol por parsimonia, por distancias, por máxima verosimilitud y por inferencia bayesiana, mide el apoyo de cada rama, prueba el reloj molecular, fecha los nodos con fósiles, ajusta modelos de diversificación, reconstruye caracteres y áreas ancestrales, compara árboles que discrepan y, al final, escribe la sección de métodos con los números de tu corrida y arma un paquete con todo para que otra persona pueda repetirlo.

Está pensado para quien necesita hacer bien un análisis filogenético y no quiere —o no puede— montar una torre de programas de línea de comandos para conseguirlo. Un estudiante de posgrado con su primer gen, un taxónomo que quiere fechar una radiación, un profesor que tiene que enseñar máxima verosimilitud el martes.



LA FRASE QUE RESUME EL PROGRAMA

Un árbol filogenético **no es un dato: es una hipótesis**, y como toda hipótesis vale lo que valgan sus supuestos. Este programa está construido para que los supuestos estén a la vista en todo momento: qué modelo se usó, con qué apoyo, con qué calibración, y qué habría cambiado con otra decisión. Donde algo no se puede saber, la pantalla lo dice en vez de imprimir un número redondo.

Es la aplicación hermana de *PopGeneticsPro*, que cubre lo que pasa **dentro** de una especie —frecuencias alélicas, estructura, endogamia—. PhylogenyPro empieza donde aquella termina: por encima del nivel de especie, donde las relaciones se representan con un árbol y el tiempo entra en la historia.

1.2 Las preguntas que responde

Un programa se entiende mejor por las preguntas que contesta que por la lista de sus funciones. Éstas son las de PhylogenyPro, con el bloque que se ocupa de cada una:

Tabla 1.1. Preguntas de un estudio filogenético y dónde se responden.

Pregunta	Bloque	Lo que obtienes
¿Mis secuencias están bien alineadas? ¿Qué columnas puedo crearme?	2	Alineamiento propio, recorte de bloques ambiguos, control de calidad
¿Qué modelo de evolución describe mejor estos datos?	3	56 modelos de ADN, doce matrices de proteína, Mk y Mk _v , con AIC, AIC _c y BIC
¿Cuál es el árbol más corto? ¿Y el que mejor explica los datos?	4 5	Parsimonia, distancias, máxima verosimilitud con búsqueda NNI y SPR

Tabla I.1. Preguntas de un estudio filogenético y dónde se responden. *(continuación)*

Pregunta	Bloque	Lo que obtienes
¿Qué tanto puedo creerle a cada rama?	5 6	Bootstrap, bootstrap ultrarrápido, SH-aLRT, aBayes, probabilidades posteriores
¿Puedo rechazar el árbol que propuso otro autor?	5	Pruebas KH, SH y AU sobre topologías alternativas
¿Hay reloj molecular? ¿Qué edad tienen estos nodos?	7	Prueba del reloj, calibraciones con fósiles, tres métodos de datación, cronograma
¿El grupo se diversificó siempre igual, o hubo una desaceleración?	8	Linajes en el tiempo, γ , prueba MCCR, cinco modelos comparados por AIC
¿Cómo era el ancestro? ¿Cuándo apareció este carácter?	9	Modelo Mk, estados ancestrales, mapeo estocástico, BM/OU/estallido temprano, PGLS
¿Dónde estaba el ancestro? ¿Cómo llegó hasta aquí?	10	DEC, DIVALIKE, BAYAREALIKE con y sin especiación fundadora, rangos ancestrales
¿Por qué mis genes dicen cosas distintas?	11	Cinco distancias entre árboles, concordancia de genes y de sitios, redes, ABBA-BABA
¿Cómo publico esto sin equivocarme al describirlo?	12	Estudio de figuras, exportación a la resolución de la revista, métodos escritos solos

1.3 Seis ideas que sostienen todo el manual

Estas seis ideas vuelven una y otra vez en los doce capítulos. Si sólo se leen dos páginas de este manual, que sean éstas.

1 · El alineamiento es una hipótesis, y es la primera

Alinear dos columnas es afirmar que **descienden del mismo sitio ancestral**. No es un paso de preparación: es la primera hipótesis del estudio, y todas las demás se apoyan en ella. Un alineamiento mal hecho no produce un árbol con poco apoyo, que sería honesto; produce un árbol **firmemente equivocado**, porque las columnas mal alineadas son sitios informativos falsos y apoyan con entusiasmo agrupaciones que no existen. Por eso el Bloque 2 tiene un visor que permite mirar el alineamiento columna por columna, y por eso el recorte de bloques ambiguos viene con una vista previa de lo que se va a quitar.

2 · Un sitio que cambió dos veces sólo enseña el último cambio

De ahí viene casi toda la dificultad de esta disciplina. Las diferencias que se observan entre dos secuencias **subestiman** los cambios que realmente ocurrieron, y lo hacen cada vez más conforme la divergencia crece, hasta que se estancan: eso es la **saturación**. Corregirla es lo que hacen los modelos de sustitución, y elegir bien el modelo importa tanto como elegir bien el método de inferencia.

3 · Más datos no arreglan un modelo equivocado

Es el error más caro que se comete en filogenia. Cuando el modelo está mal especificado, añadir sitios no acerca la respuesta correcta: **augmenta la confianza en la equivocada**. La atracción de ramas largas es el caso clásico —con datos infinitos, la parsimonia converge *con más seguridad* al árbol falso—, pero la lógica es general y vale también para el bootstrap y para la probabilidad posterior. Un 100 % de apoyo sobre un modelo malo es un 100 % de confianza en un error.

4 · «Apoyo» quiere decir cosas distintas según quién lo diga

Un bootstrap del 70 % y una probabilidad posterior de 0.70 no son lo mismo, y un bootstrap ultrarrápido del 90 % es **menos** apoyo que un bootstrap clásico del 90 %. Cada medida tiene su escala y su umbral, y confundirlas es la equivocación más frecuente en esta disciplina. El programa lleva incorporada una ayuda de interpretación que, junto a cada número, dice en qué banda de su propia escala cae.

5 · El tiempo no sale de las secuencias

Un árbol de máxima verosimilitud tiene ramas medidas en **sustituciones por sitio**, no en años. Lo único que convierte lo uno en lo otro es una calibración externa: un fósil, una tasa publicada, un evento geológico. Y un fósil casi nunca da la edad de un nodo: da su **edad mínima**. Por eso las fechas de un estudio no son mejores que su peor calibración, y por eso ninguna edad se reporta jamás sin su intervalo.

6 · Que los genes discrepen es un resultado, no un estorbo

Cuando dos genes dan árboles distintos, la tentación es concatenarlos y seguir adelante. Pero el desacuerdo puede ser la parte interesante: clasificación incompleta de linajes, hibridación, captura de cloroplasto, introgresión. El Bloque 11 existe para medir ese conflicto en vez de promediarlo, y una rama con 100 % de bootstrap y 35 % de concordancia génica es exactamente el caso que hay que saber ver.

1.4 Qué datos acepta y qué entrega

Tabla 1.2. Entradas y salidas del programa.

	Qué
Tipos de dato	ADN y ARN, aminoácidos, codones y caracteres morfológicos discretos.
Genomas	Cloroplasto, mitocondria, ADN ribosomal nuclear y núcleo de copia baja. Cada partición declara de qué genoma viene , y esa declaración se arrastra a todos los bloques siguientes: no es un adorno, porque el cloroplasto y la mitocondria se heredan por un solo progenitor y no recombinan.
Formatos que lee	FASTA, PHYLIP (estricto y relajado, secuencial e intercalado), NEXUS (bloques DATA, CHARACTERS, SETS, TREES), Clustal, MEGA, archivos planos de GenBank y hojas de cálculo (.csv, .tsv) para matrices morfológicas. Adivina el formato y el tipo de dato, y dice todo lo que tuvo que adivinar .
Formatos que escribe	FASTA, PHYLIP, NEXUS con conjuntos de caracteres, esquemas de partición de RAxML, Newick, NEXUS de árboles con bloque de FigTree, phyloXML, CSV, SVG, PNG, TIFF y un paquete .zip con todo.
Lo que entrega	Árboles con apoyo, cronogramas, reconstrucciones ancestrales, figuras a la resolución que pida la revista, una sección de métodos redactada a partir de lo que realmente se corrió, y un paquete reproducible.

1.5 Qué necesitas y cómo abrirlo

Un navegador moderno —Chrome, Edge, Firefox o Safari, de los últimos años— y nada más. No hace falta internet, ni instalar nada, ni permisos de administrador.

- 1 **Doble clic en** `index.html`. Es la forma más sencilla y funciona para todo, porque el programa trae sus ejemplos incrustados y no busca ningún archivo en el disco mientras corre.
- 2 **O con el servidor local**, si prefieres abrirlo desde otra computadora de la misma red: clic derecho en `server.ps1` → *Ejecutar con PowerShell*, y luego `http://localhost:9800` en el navegador. Ejecutándolo como administrador, imprime además la dirección para entrar desde una tableta conectada a la misma red WiFi.

! SOBRE LA VELOCIDAD

Esto es JavaScript, no C. Cien réplicas de bootstrap por máxima verosimilitud tardan minutos, y cien mil generaciones de cadenas bayesianas acopladas también. El programa **estima el tiempo antes de empezar**, muestra el avance y se puede cancelar. Para filogenómica de cientos de taxones y millones de sitios, sigue usando IQ-TREE o RAxML: la portada del programa lo dice con esas mismas palabras, y con una tabla de tamaños medidos, no prometidos.

1.6 Recorrido por la interfaz

La pantalla tiene siempre las mismas tres partes.

- **La barra de arriba.** El nombre del programa, el selector de idioma **ES / EN** y el botón de tema claro u oscuro. El idioma y el tema se cambian cuando quieras: nada se pierde ni se recalcula.
- **La cinta de bloques.** Doce pasos numerados, del 1 al 12. Se recorren en orden porque cada uno usa lo que produjo el anterior, pero se puede volver atrás en cualquier momento: si cambias el alineamiento, los bloques que dependían de él te lo dirán.
- **El panel del bloque.** Arriba, una explicación de qué se decide ahí y por qué importa. En medio, los controles. Abajo, los resultados: mosaicos con las cifras principales, tablas, figuras, y un **veredicto en palabras** que dice qué significa lo que acaba de salir. Al pie de cada bloque hay una **guía de interpretación** desplegable con una ficha por concepto: qué mide, en qué escala se lee y cuál es el error más común con él.

Junto a muchas cifras verás un pequeño círculo con un signo de interrogación. Al pulsarlo se abre la ficha de esa medida, con su escala en bandas de color. Cuando el umbral que usa la disciplina es una costumbre y no una ley estadística —y la mitad de ellos lo son—, la ficha lo dice.

1.7 Los conjuntos de ejemplo, y por qué están simulados

El programa trae cuatro conjuntos de ejemplo, y todos tienen una peculiaridad deliberada: **las secuencias están simuladas sobre un árbol conocido**, bajo un modelo conocido, con los huecos insertados por linaje. Los nombres de especie son reales —plantas mexicanas, sobre todo del género *Bursera*, los copales—, pero las secuencias no son las de ningún organismo.

No es una limitación: es el motivo por el que sirven para aprender. Cada ejemplo trae **su propia respuesta correcta**. El árbol verdadero y el alineamiento verdadero están guardados junto a los datos, así que se puede comparar lo que uno estima con lo que de verdad ocurrió. Eso es imposible con datos reales, y es justo lo que hace falta cuando uno está aprendiendo a distinguir un resultado firme de uno que sólo lo parece.

Tabla 1.3. Los conjuntos de ejemplo.

Ejemplo	Qué contiene y para qué sirve
Bursera · 3 genes sin alinear	rbcl (cloroplasto, codificante), trnL-F (cloroplasto, con indeles) e ITS (ribosomal nuclear), 18 taxones. Para practicar el alineamiento y comparar el resultado con el verdadero.
Bursera · concatenado y alineado	Los mismos tres genes ya alineados y concatenados, con su mapa de particiones. El punto de partida para los bloques 3 en adelante.
Familia génica · proteínas	Secuencias de aminoácidos de una familia MYB. Para los modelos de proteína y el alineamiento por codón.
Matriz morfológica	Caracteres discretos codificados. Para Mk, Mkv y la reconstrucción de estados ancestrales.

1.8 Cómo se recorre un estudio de principio a fin

El orden de los bloques no es caprichoso: es el orden en que se hace un estudio de verdad, y cada paso usa lo que dejó el anterior.

- 1 **Carga y alinea** (Bloque 2). Declara de qué genoma viene cada partición. Revisa el alineamiento a ojo antes de seguir; es el único paso que ningún algoritmo hace mejor que quien conoce el grupo.
- 2 **Mira los supuestos antes de elegir** (Bloque 3): composición de bases y saturación. Luego deja que los criterios de información elijan el modelo.
- 3 **Consigue un árbol rápido** (Bloque 4) por distancias y por parsimonia. Sirve de punto de partida y de contraste.
- 4 **Haz la inferencia seria** (Bloques 5 y 6): máxima verosimilitud con su apoyo, y si el tiempo alcanza, también bayesiana. Que los dos coincidan es una información valiosa; que discrepen, más todavía.
- 5 **Pon el tiempo** (Bloque 7): raíz, prueba del reloj, calibraciones, fechas con sus intervalos.
- 6 **Pregúntale al árbol fechado** lo que quieras saber: cómo se diversificó el grupo (8), cómo evolucionaron sus caracteres (9), dónde estuvo (10).
- 7 **Confronta** (Bloque 11): ¿dicen lo mismo tus genes? ¿Y tu árbol con el publicado?
- 8 **Publica** (Bloque 12): figura, métodos y paquete reproducible.

No todos los estudios recorren los doce bloques, y no hace falta. Un trabajo de sistemática puede detenerse en el 5; uno de biogeografía necesitará hasta el 10. El informe del Bloque 12 se escribe con lo que efectivamente se corrió: si no hubo reloj, el informe no menciona el reloj.

1.9 Cómo leer este manual

Un capítulo por bloque, con el mismo número: el capítulo 7 explica el Bloque 7. Cada capítulo abre con una página que dice qué se decide ahí, sigue con la teoría mínima necesaria —no más—, luego el recorrido por los controles, y cierra con la lectura de los resultados y los errores frecuentes.

Tabla 1.4. Convenciones tipográficas.

Se ve así	Quiere decir
Construir el árbol	Un botón, una casilla o un menú, escrito tal como aparece en pantalla.
<i>Bursera simaruba</i>	Un nombre científico.
7	Un reenvío a otro bloque y a su capítulo.

I LOS CUATRO TIPOS DE RECUADRO

Nota, con información que ayuda. **Idea**, con algo que conviene recordar más allá del programa. **Aviso**, con una advertencia que puede costar caro si se ignora. Y **Error frecuente**, con una equivocación concreta que se comete a menudo y cómo se evita.

I.10 Lo que el programa no hace

Un manual honesto dice también dónde termina su programa. PhylogenyPro **no** hace nada de esto:

- **Filogenómica a gran escala.** Cientos de taxones y millones de sitios están fuera de su alcance por velocidad, no por método. La portada del programa trae una tabla de tamaños **medidos** en una computadora de escritorio común.
- **Coalescente multiespecie completo.** Hay árbol de especies por cuartetos, que es una heurística, no el algoritmo exacto de ASTRAL ni un modelo coalescente con verosimilitud.
- **Redes filogenéticas explícitas con hibridación.** Hay redes de divisiones, que **muestran** el conflicto sin explicarlo; no hay estimación de un número de eventos de hibridación.
- **Anotación ni búsqueda de secuencias.** No se conecta a GenBank ni a ninguna base de datos: no tiene red, por diseño.
- **Decidir por ti.** El programa calcula, compara y avisa; la interpretación, la elección de las calibraciones y la definición de las áreas siguen siendo tuyas, y son las que hay que defender ante un revisor.

♦ ANTES DE PASAR AL CAPÍTULO 1

Si algo de lo anterior parece demasiado cauteloso, conviene recordar de dónde viene la cautela. La filogenia molecular lleva cuarenta años descubriendo que sus certezas más firmes —el apoyo del 100 %, la fecha con tres decimales, el ancestro reconstruido con seguridad— eran, con frecuencia, artefactos de un supuesto que nadie había revisado. Este programa está escrito con esa memoria encima.

1

CAPÍTULO UNO · BLOQUE 1

La portada: lo que hay que creer antes de empezar

El primer bloque no calcula tu árbol: te prepara para calcularlo. Trae la ruta completa del estudio, el catálogo de lo que la aplicación sabe hacer, una comparación franca de los cuatro criterios de inferencia, una tabla de tamaños **medidos** y —lo más importante— dos laboratorios que calculan filogenia de verdad en la página, para que dos de las ideas más difíciles de la disciplina dejen de ser una advertencia y se vuelvan algo que viste ocurrir.

1.1 Para qué sirve una portada que calcula

1.3 Laboratorio 1: la zona de Felsenstein

1.5 Qué puedes analizar, y con qué marcador

1.7 Hasta dónde llega, y hasta dónde no

1.9 Las nueve secciones de teoría

1.2 La ruta del estudio en siete pasos

1.4 Laboratorio 2: saturación y corrección

1.6 Los cuatro criterios, comparados sin rodeos

1.8 La galería de métodos y las referencias

1.10 Errores frecuentes

1.1 Para qué sirve una portada que calcula

Casi todas las portadas de los programas científicos son un folleto: dicen lo que el programa hace y te invitan a empezar. Ésta hace otra cosa. Además de presentar la ruta, **calcula**: dos laboratorios corren filogenia real — probabilidades exactas, simulación, inferencia por tres métodos— cada vez que mueves un control. Nada de lo que verás ahí es una animación.

La razón de ese diseño es pedagógica y tiene que ver con la idea 3 de la introducción. Se puede advertir mil veces que «más datos no arreglan un modelo equivocado», y la advertencia resbala. Ver, en tu propia pantalla, cómo la parsimonia recupera el árbol falso **con más frecuencia conforme aumentas el número de sitios**, no resbala: eso ya no se olvida.

✦ QUÉ SE DECIDE EN ESTE BLOQUE

Nada, técnicamente: no produce ningún resultado que los demás bloques usen. Lo que se decide aquí es **qué esperas del estudio que estás a punto de hacer** y qué vas a creerle. Es el único bloque que conviene leer entero antes de cargar datos, y el único al que vale la pena volver cuando un resultado no cuadra.

Las seis tarjetas de la cabecera resumen las condiciones en que trabajarás: todo corre en el navegador, tus datos no salen de tu computadora, acepta ADN, proteínas, codones y morfología, trata por separado el cloroplasto, la mitocondria y el núcleo, está en español e inglés, y exporta figuras hasta 900 ppp.

1.2 La ruta del estudio en siete pasos

La franja «Cómo funciona» agrupa los doce bloques en los siete pasos que tiene un estudio filogenético de verdad, en el orden en que se hace:

Tabla 1.1. Los siete pasos de la franja y los bloques que los realizan.

Paso	Se llama	Qué ocurre	Bloques
1	Alinear	Secuencias, recorte de bloques ambiguos, particiones	2
2	Elegir modelo	Saturación, AIC y BIC	3
3	Inferir	Parsimonia, máxima verosimilitud y bayesiano	4 5 6
4	Medir el soporte	Bootstrap y probabilidades posteriores	5 6
5	Fechar	Reloj, fósiles, escala geológica	7
6	Interpretar	Caracteres, áreas, diversificación	8 9 10 11
7	Publicar	Figura, informe y paquete ZIP	12

Debajo, las doce tarjetas de bloque dicen qué hace cada uno. **Cada tarjeta corresponde a un capítulo de este manual, con el mismo número.** Pulsando una tarjeta se salta al bloque; si sus requisitos no están listos, el bloque lo dirá en vez de calcular algo sin sentido.

1.3 Laboratorio 1: la zona de Felsenstein

Éste es, probablemente, el rincón más importante del programa entero. Ilustra el resultado de Felsenstein (1978) que fundó la crítica moderna a la parsimonia, y lo hace calculando, no contando.

Qué muestra

Un árbol de **cuatro taxones** con la forma que hace daño: dos ramas largas que **no** son hermanas, separadas por ramas cortas. Con cuatro taxones sólo hay tres topologías sin raíz posibles, y con cuatro estados posibles por sitio hay 256 patrones; pero por simetría esos 256 se reducen a las **15 particiones del conjunto {A, B, C, D}**, de modo que la probabilidad de cada patrón bajo Jukes–Cantor se puede calcular **exactamente**, sin simular nada.

El panel usa esa exactitud para responder la pregunta con datos infinitos: ¿qué patrón informativo es el más probable? Si el patrón que más probabilidad acumula es el que agrupa a las dos ramas largas, entonces la parsimonia, con suficientes sitios, elegirá **con toda seguridad el árbol equivocado**. Eso es ser *inconsistente*: converger a la respuesta falsa.

Los controles

- **Ramas largas** y **Ramas cortas**: las dos longitudes que definen el escenario, en sustituciones por sitio.
- **Sitios**: cuántos sitios tiene cada alineamiento simulado.
- **Réplicas**: cuántos alineamientos se simulan para medir con qué frecuencia acierta cada método.
- **Otras réplicas**: vuelve a simular con otra semilla.

Qué leer

Tres cosas, en este orden:

- 1 **El árbol verdadero y Dónde falla la parsimonia**: el panel calcula por bisección la **frontera** del escenario, es decir el punto exacto donde la rama larga se vuelve demasiado larga y la parsimonia empieza a equivocarse. Mover los deslizadores a un lado y otro de esa frontera es la lección entera.
- 2 **Los tres patrones informativos** y su probabilidad exacta. Cuando el patrón «largas juntas» supera al patrón verdadero, ya está: la parsimonia perdió, por muchos datos que le des.
- 3 **Veces que cada método recuperó el árbol verdadero**, sobre las réplicas simuladas, con parsimonia, con unión de vecinos sobre distancias corregidas por Jukes–Cantor, y con máxima verosimilitud optimizando las longitudes en cada una de las tres topologías.

! EL EXPERIMENTO QUE HAY QUE HACER

Pon un escenario dentro de la zona —ramas largas de 0.6 y cortas de 0.03, por ejemplo— y luego **sube los sitios** de 100 a 2 000. La verosimilitud mejora, como uno esperarí. La parsimonia **empeora**: con más datos acierta menos, porque cada sitio nuevo refuerza la señal falsa. Ésa es la diferencia entre un método consistente y uno que no lo es, y es la idea 3 de la introducción vista en directo.

El panel «Por qué importa en tus datos» lo traduce: un género con una especie de evolución acelerada, un grupo externo muy lejano o un marcador saturado producen exactamente esta geometría sin que nadie la haya buscado. Si tu árbol junta el grupo externo con el taxón más divergente, sospecha de esto antes que de la biología.

1.4 Laboratorio 2: saturación y corrección de distancias

El segundo laboratorio hace visible la idea 2: un sitio que cambió varias veces sólo enseña el último cambio.

Dos secuencias divergen bajo el modelo de Kimura de dos parámetros, con tasas que varían entre sitios según una distribución gamma. El panel dibuja la **distancia estimada contra la distancia real**, con tres curvas superpuestas: las **diferencias crudas** (la proporción de posiciones distintas), la corrección del modelo, y la línea del **estimador perfecto**, que es la diagonal.

Lo que se ve es inmediato: las diferencias crudas empiezan pegadas a la diagonal y se despegan cada vez más, hasta aplanarse. Ésa es la saturación. La corrección las devuelve a la diagonal, pero sólo hasta donde tiene solución; más allá, la fórmula se rompe y el panel lo muestra.

Los controles

- **Divergencia máxima**: hasta dónde se dejan separar las dos secuencias.
- **Razón ts/tv**: cuántas transiciones hay por cada transversión. Súbela y verás que las transiciones se saturan mucho antes.
- **Forma de Γ** : la desigualdad de velocidades entre sitios. Valores bajos —unos pocos sitios rapidísimos y muchos casi congelados— adelantan la saturación.
- **Sitios**: cuántas posiciones tiene cada secuencia; con pocos, el ruido domina.
- **tasas variables entre sitios (+ Γ)**: apaga y enciende la heterogeneidad para ver cuánto cambia.

La segunda gráfica, **Transiciones y transversiones**, es la que usarás con tus propios datos en el Bloque 3. La regla se lee sola en la pantalla: **cuando la curva de transiciones deja de subir y empieza a bajar, el marcador está saturado**. No es una metáfora: las transiciones acumuladas se pierden porque los sitios vuelven a cambiar.

I SATURADO NO ES INSERVIBLE

Un marcador saturado sigue resolviendo bien los nodos recientes; lo que no se puede es usarlo para los nodos profundos y **crearle su apoyo**. La solución habitual no es tirar el gen: es quitar la tercera posición del codón, pasar a aminoácidos, o buscar un marcador más lento para la parte profunda del árbol.

1.5 Qué puedes analizar, y con qué marcador

La sección «Qué puedes analizar» enumera los tipos de dato que el mismo motor de verosimilitud maneja: ADN, proteínas, codones y morfología. No son cuatro programas por dentro, sino uno que trabaja con cuatro, veinte o los estados que haga falta.

Enseguida viene la lista de marcadores, y ahí conviene detenerse, porque es la que evita el error más caro de un estudio de plantas: **tratar todos los genes como si contaran la misma historia**.

Tabla 1.2. Los marcadores que la aplicación reconoce por su nombre, con su genoma y su carácter.

Genoma	Marcadores	Qué esperar
Cloroplasto	rbcl	El caballo de batalla: lento, fácil de amplificar, bueno de familia hacia arriba.
Cloroplasto	matK	Más variable que rbcl; el otro marcador del código de barras de plantas.
Cloroplasto	trnL-F	Espaciador no codificante: resuelve entre especies cercanas.
Cloroplasto	trnH-psbA	El espaciador más variable del cloroplasto; con muchos indeles.
Cloroplasto	ndhF, atpB, rpl16, rps16, ycf1	El resto del repertorio habitual en sistemática de plantas.
Nuclear ribosomal	ITS, ITS2, ETS	Rápido y muy usado, pero con copias divergentes y evolución concertada incompleta.
Nuclear de copia baja	waxy, PHYC, LEAFY, G3pdh	Biparentales: son los que detectan hibridación .
Mitocondria	matR, nad1, cox1, atp1	Los más lentos de la planta; útiles en filogenias profundas.

✦ POR QUÉ EL GENOMA NO ES UN ADORNO

El cloroplasto y la mitocondria de una planta se heredan **por un solo progenitor** —en la mayoría de las angiospermas, por la madre— y **no recombinan**: todo el genoma es un solo linaje, con una sola historia. El núcleo se hereda de los dos y sí recombina. Por eso un árbol de cloroplasto y uno nuclear **pueden discrepar sin que ninguno esté mal**: la captura de cloroplasto tras una hibridación antigua deja exactamente esa firma. Declarar el genoma de cada partición en el Bloque 2 es lo que permite que los bloques siguientes traten ese desacuerdo como información y no como ruido.

1.6 Los cuatro criterios, comparados sin rodeos

La tabla comparativa de la portada es deliberadamente franca: **no hay un método que gane siempre**. Ésta es su versión impresa.

Tabla 1.3. Los cuatro criterios de inferencia, lo que optimizan y dónde se rompen.

	Distancias (NJ)	Parsimonia	Máxima verosimilitud	Bayesiano
Qué optimiza	Ajuste a una matriz de distancias	El menor número de cambios	La probabilidad de los datos dado el árbol	La probabilidad del árbol dados los datos
Usa un modelo	Sí, al corregir las distancias	No, o sólo pesos	Sí, explícito	Sí, explícito y con previas
Consistente con ramas largas desiguales	Depende de la corrección	No: zona de Felsenstein	Sí, bajo el modelo correcto	Sí, bajo el modelo correcto
Longitudes en sustituciones	Sí	En pasos, no en sustituciones	Sí	Sí, con intervalo
Permite fechar	Sólo con métodos aproximados	No	Sí (reloj, LSD)	Sí, con incertidumbre
Costo	Segundos	Segundos a minutos	Minutos	De minutos a horas
Para qué sirve mejor	Un primer vistazo y el árbol de arranque	Morfología y datos con pocos cambios	El árbol que se publica	Incertidumbre, fechas y modelos complejos

Obsérvese que el renglón decisivo es el tercero, y que es exactamente lo que el laboratorio 1 deja ver. La parsimonia no es «peor»: es **inconsistente bajo una geometría concreta**, y sigue siendo la herramienta adecuada para morfología, donde no hay modelo de sustitución que valga y los cambios son pocos.

1.7 Hasta dónde llega, y hasta dónde no

La tabla de límites de la portada no es una promesa comercial: son **tiempos medidos** en una computadora de escritorio común, no estimaciones optimistas. Conviene mirarla antes de cargar una matriz grande.

Tabla 1.4. Tamaños que la aplicación maneja, medidos. «Cómodo» es lo que se hace sin pensarlo; «al límite» es lo que se puede hacer teniendo paciencia.

Análisis	Cómodo	Al límite	Tiempo
Distancias, NJ, parsimonia	≤ 300 taxones	≤ 1 000	Segundos
Verosimilitud + bootstrap ultrarrápido	≤ 120	≤ 300	Minutos
Verosimilitud + bootstrap clásico	≤ 60	≤ 120	Minutos, con varios hilos
Bayesiano (MC ³)	≤ 50	≤ 100	De minutos a horas
Datación por mínimos cuadrados	≤ 500	≤ 1 000	Segundos

Tabla 1.4. Tamaños que la aplicación maneja, medidos. «Cómodo» es lo que se hace sin pensarlo; «al límite» es lo que se puede hacer teniendo paciencia. (*continuación*)

Análisis	Cómodo	Al límite	Tiempo
Datación bayesiana	≤ 60	≤ 120	De minutos a horas
Biogeografía DEC	≤ 8 áreas	≤ 10 áreas	Minutos

El límite de la biogeografía es distinto de los demás y merece una nota: no depende del número de taxones sino del de **áreas**, porque el número de rangos posibles crece como 2 elevado al número de áreas. Con ocho áreas ya hay 256 estados; con doce, más de cuatro mil.

Bajo la tabla, la portada dice en una línea lo que hay que decir: para filogenómica de cientos de taxones y millones de sitios, sigue usando IQ-TREE o RAxML. Esto es JavaScript, y la diferencia con C no la arregla ninguna optimización.

1.8 La galería de métodos y las referencias

La galería lista **todo** lo que la aplicación calcula, agrupado por familia —datos, modelos, inferencia, soporte, tiempos, caracteres, biogeografía, comparación—, con un filtro para ver una sola familia. Sirve para dos cosas: comprobar de un vistazo si el método que necesitas está, y encontrar en qué bloque vive.

Al final de la portada hay **94 referencias**, también agrupadas por familia. No están de adorno: cada método que la aplicación implementa cita el artículo en que se publicó, y el informe del Bloque 12 arma su bibliografía tomando de esa misma lista **sólo lo que efectivamente se usó** en tu corrida.

I CITAR EL MÉTODO, NO SÓLO EL PROGRAMA

Cuando publiques, cita el programa y los artículos originales de los métodos que usaste. Un revisor con experiencia notará la diferencia entre «se usó el programa X» y «se ajustó un modelo GTR+Γ (Yang 1994) con búsqueda SPR y apoyo por bootstrap ultrarrápido (Minh et al. 2013)». La sección de métodos que escribe el Bloque 12 ya viene con esas citas puestas.

1.9 Las nueve secciones de teoría

La portada cierra con nueve secciones desplegables que son, en la práctica, un curso corto. Valen la pena aunque ya sepas el tema, porque fijan el vocabulario que usa el resto del programa.

1. **Qué es un árbol filogenético (y qué no es).** Topología, longitudes de rama, raíz; por qué un árbol sin raíz no tiene «ancestros».
2. **El alineamiento es una hipótesis de homología.** La idea 1 de la introducción, desarrollada.
3. **Los cambios que no se ven: modelos de sustitución.** Por qué hace falta corregir, y qué corrige cada modelo.

4. **Parsimonia, verosimilitud y bayes: en qué se diferencian de verdad.** Más allá del eslogan de «el árbol más simple».
5. **Qué significa realmente un valor de soporte.** La idea 4, con las escalas de cada medida.
6. **El reloj molecular y las calibraciones.** La idea 5.
7. **Cloroplasto, mitocondria y núcleo: tres historias en el mismo organismo.** Lo que hace que el Bloque 11 exista.
8. **Áreas ancestrales: cómo se reconstruye una historia biogeográfica.** El almacén del Bloque 10.
9. **Los ocho errores que más se ven en un manuscrito.** La sección que conviene leer *antes* de escribir, no después de que la rechacen.

1.10 Errores frecuentes

✗ SALTARSE LA PORTADA

Es el error que hace todo el mundo, incluidos los que llevan años haciendo filogenia. Los dos laboratorios tardan diez minutos y cambian la forma de mirar los resultados de los once bloques siguientes. Si sólo tienes tiempo para uno, que sea el de la zona de Felsenstein.

✗ LEER LA TABLA DE LÍMITES COMO UNA PROMESA

Los tiempos se midieron en una computadora concreta con un alineamiento concreto. Tu máquina y tus datos son otros. La tabla sirve para saber si estás en el orden de magnitud correcto, no para planear una fecha de entrega.

✗ CONCLUIR QUE «LA PARSIMONIA ES MALA»

El laboratorio 1 no demuestra eso. Demuestra que la parsimonia es **inconsistente bajo una geometría concreta** de ramas. Fuera de esa geometría se comporta bien, es rapidísima, y para matrices morfológicas — donde no hay un modelo de sustitución creíble— sigue siendo la herramienta correcta. El capítulo 4 vuelve sobre esto.

✗ ELEGIR EL MARCADOR POR COSTUMBRE DEL LABORATORIO

«Siempre usamos ITS» no es un argumento. ITS es rápido y resuelve entre especies cercanas, pero tiene copias divergentes y evolución concertada incompleta, y para un nodo profundo dará una respuesta segura y equivocada. La lista de marcadores de la portada dice, para cada uno, en qué rango de profundidad es informativo.

2

CAPÍTULO DOS · BLOQUE 2

Datos y alineamiento

El bloque más importante del programa y el que menos atención suele recibir. Aquí se leen las secuencias, se alinean, se revisan **a mano**, se recortan las columnas dudosas y se arma el mapa de particiones declarando de qué genoma viene cada una. Todo lo que hagan los diez bloques siguientes descansa sobre lo que se decida en éste, y ningún método posterior puede corregir un error cometido aquí.

2.1 Por qué este bloque decide el estudio

2.3 Particiones: el mapa del estudio

2.5 Alinear por codón

2.7 Editar a mano

2.9 Control de calidad: once cosas que se revisan

2.11 Errores frecuentes

2.2 Cargar los datos: formatos y lo que se adivina

2.4 Alinear: el alineador y sus opciones

2.6 El visor: mirar el alineamiento de verdad

2.8 Recorte de bloques ambiguos

2.10 Exportar, y qué se lleva al Bloque 3

2.1 Por qué este bloque decide el estudio

Alinear dos columnas es afirmar que **descienden del mismo sitio ancestral**. No es una preparación de los datos: es la primera hipótesis del trabajo, y es la única que ningún bloque posterior puede poner a prueba. La máxima verosimilitud del Bloque 5 tomará tu alineamiento como un hecho y calculará sobre él con toda seriedad; si las columnas están mal, calculará con toda seriedad una respuesta falsa.

✦ LA CONSECUENCIA QUE HAY QUE ENTENDER

Un alineamiento malo **no produce un árbol con poco apoyo**, que sería el resultado honesto. Produce un árbol **firmeramente equivocado**: las columnas mal alineadas se convierten en sitios informativos falsos, y esos sitios apoyan con entusiasmo agrupaciones que no existen. El bootstrap las respaldará, porque el bootstrap mide la consistencia de la señal, y la señal está ahí — sólo que es artificial.

Por eso este bloque no se limita a alinear: trae un visor para mirar el resultado columna por columna, un editor para corregirlo a mano, un recorte con vista previa y un control de calidad que busca once problemas concretos. La frase que encabeza la sección de alineamiento en la pantalla lo dice sin rodeos: *el ojo de quien conoce el grupo gana muchas veces al algoritmo*.

2.2 Cargar los datos: formatos y lo que se adivina

Cada archivo que cargues entra como una **partición**: un gen, una región o una matriz. Puedes cargar varios a la vez, arrastrándolos al recuadro, eligiéndolos con **Elegir archivos...** o pegando el texto con **Pegar secuencias**.

Tabla 2.1. Formatos que el programa lee, y lo que hay que saber de cada uno.

Formato	Detalle
FASTA	El más sencillo y el más seguro. Si tienes dudas, convierte a FASTA.
PHYLIP	Estricto y relajado, secuencial e intercalado. El estricto corta los nombres a diez caracteres; el programa detecta cuál es cuál y lo dice.
NEXUS	Bloques DATA, CHARACTERS, SETS (con <i>charsets</i> , que se convierten en particiones) y TREES. También entiende MATCHCHAR.
Clustal	La salida clásica de ClustalW y ClustalΩ.
MEGA	El formato de MEGA, con sus encabezados #MEGA .
GenBank	Archivos planos. Los nombres se toman del campo ORGANISM, y del gen cuando está.
Hoja de cálculo	.csv y .tsv, para matrices morfológicas: una fila por taxón, una columna por carácter.

! LO QUE ADIVINA, LO DICE

El programa deduce el formato y el tipo de dato —ADN, proteína o morfología— y **reporta todo lo que tuvo que adivinar**. Cuando un archivo de GenBank obliga a tomar los nombres del campo ORGANISM, lo avisa y pide que los revises antes de seguir: ahí es donde se cuelan los nombres duplicados y los sinónimos.

Si prefieres empezar sin datos propios, los cuatro botones de ejemplo cargan los conjuntos descritos en la sección I.7: **Bursera · 3 genes sin alinear**, **Bursera · concatenado y alineado**, **Familia génica · proteínas** y **Matriz morfológica**. Los tres genes sin alinear son los indicados para practicar todo este capítulo, porque traen su alineamiento verdadero guardado y permiten comprobar qué tan bien lo hiciste.

2.3 Particiones: el mapa del estudio

La lista de particiones es el mapa de lo que vas a analizar. Cada renglón trae el nombre, cuántos taxones y posiciones tiene, si está alineada, y dos menús: el **genoma** y el **tipo de dato**.

! EL GENOMA NO ES UN ADORNO

Declarar si una partición viene del **cloroplasto**, de la **mitocondria**, del **ADN ribosomal nuclear** o del **núcleo de copia baja** es la decisión de este bloque que más lejos llega. El cloroplasto y la mitocondria se heredan por un solo progenitor y no recombinan: todo el genoma es un linaje con una sola historia. El núcleo se hereda de los dos y recombina. Esa declaración viaja a todos los bloques siguientes y es la que permite que el Bloque 11 trate un desacuerdo entre genes como **información** —captura de cloroplasto, hibridación— y no como ruido que hay que promediar.

Tres botones operan sobre el conjunto:

- **Concatenar todas** reúne las particiones alineadas en una matriz única, rellenando con datos faltantes los taxones que no estén en alguna. La concatenada conserva el mapa de dónde empieza y termina cada gen, que es lo que el Bloque 3 usará para el esquema de particiones. Hace falta que haya **al menos dos particiones alineadas**.
- **Separar por posición de codón** parte un gen codificante en tres particiones —primera, segunda y tercera posición—, que es lo que se hace cuando la tercera está saturada y se quiere modelar aparte o descartarla.
- **Importar esquema de particiones...** lee un esquema ya escrito, del estilo de los de RAxML.

2.4 Alinear: el alineador y sus opciones

El alineador es progresivo, de la escuela que Clustal hizo estándar y MUSCLE refinó. Trabaja en cuatro pasos:

- 1 **Distancias rápidas** entre cada par de secuencias a partir de los k -meros que comparten, sin alinear nada todavía.
- 2 **Árbol guía** por UPGMA sobre esas distancias.
- 3 **Alineamiento perfil contra perfil** recorriendo el árbol guía de las hojas a la raíz, con huecos afines (Gotoh 1982) y con la penalización reducida donde el perfil ya tiene huecos.
- 4 **Refinamiento iterativo**, opcional: cada rama del árbol guía parte las secuencias en dos, se realinean los dos subalineamientos y el resultado se conserva **sólo si mejora** el puntaje de pares. Es la tercera etapa de MUSCLE.

Los controles son cuatro: **por codón**, **refinar**, **abrir hueco** y **extender**. Los dos últimos son las penalizaciones de Gotoh: abrir un hueco cuesta mucho, extenderlo cuesta poco, porque una inserción de seis bases es un solo evento y no seis.

1 QUÉ TAN BUENO ES

Medido contra el alineamiento verdadero de los ejemplos simulados, el alineador recupera el **99.98 %** de los pares en rbcL, el **98.14 %** en trnL-F —que es el que lleva indeles—, el **98.93 %** en ITS y el **99.60 %** en la familia de proteínas. Alineando rbcL **por codón**, el **100 %**. Esas cifras están en la carpeta de validación y se pueden reproducir.

2.5 Alinear por codón

Si la partición es codificante, ésta es la casilla más útil de todo el bloque. Con **por codón** activada, el programa traduce, alinea como proteína y devuelve los huecos a los nucleótidos **de tres en tres**.

La consecuencia es que **no puede aparecer un hueco de una o dos bases**, y un hueco así, en una región codificante, es casi siempre un artefacto del alineador: implicaría un corrimiento del marco de lectura que la selección habría eliminado. Alinear por codón no mejora un poco el resultado: elimina de raíz una clase entera de error, y por eso el ejemplo de rbcL pasa de 99.98 % a 100 %.

2.6 El visor: mirar el alineamiento de verdad

El visor dibuja el alineamiento sobre un lienzo y aguanta miles de columnas sin ponerse lento. Tres menús cambian lo que se ve:

- **color** : **por residuo** (cada base o aminoácido con el suyo), **diferencias con el consenso** —que es la vista que delata una columna mal alineada, porque las diferencias se apelotonan— o **sin color** .
- **marcar variables e informativos** : señala qué columnas cambian y cuáles son informativas para parsimonia. Recuerda que las informativas son las que eligen topología; las demás no.
- **posiciones de codón** : marca primera, segunda y tercera. Sirve para ver de un vistazo si la tercera es un desorden, que es la firma de la saturación.

! DIEZ MINUTOS AQUÍ VALEN MÁS QUE CUALQUIER OTRA COSA

Recorre el alineamiento de principio a fin con el color por diferencias con el consenso. Busca regiones donde una sola secuencia se desvía por completo —suele ser una secuencia mal orientada, o de otro gen—, bloques donde los huecos se escalonan sin ton ni son, y extremos con datos de un solo taxón. Son minutos que evitan semanas.

2.7 Editar a mano

El editor tiene **deshacer y rehacer ilimitados**, que es lo que permite atreverse a probar. Las operaciones son ocho:

Tabla 2.2. Las operaciones del editor.

Operación	Qué hace
Hueco en esta secuencia	Inserta un hueco en la posición marcada, sólo en esa secuencia.
Hueco en todas	Inserta una columna de huecos en todas: desplaza el alineamiento sin romperlo.
Quitar este hueco	Cierra un hueco de una secuencia.
Borrar columna(s)	Elimina las columnas seleccionadas.
Quitar columnas vacías	Borra las que quedaron sin ningún residuo, que suelen aparecer tras editar.
Ordenar por nombre	Reordena las filas alfabéticamente, para encontrar un taxón.
Quitar taxón	Saca una secuencia entera de la partición.
↶ Deshacer / ↷ Rehacer	Sin límite de pasos.

Editar a mano no es hacer trampa: es lo que hace cualquier sistemático con experiencia, porque un algoritmo no sabe que esa región es un microsatélite ni que ese taxón tiene una duplicación conocida. Lo que sí es obligatorio es **decirlo en los métodos**, y el informe del Bloque 12 registra que el alineamiento fue editado.

2.8 Recorte de bloques ambiguos

Hay regiones —espaciadores muy variables, extremos mal secuenciados— donde el alineamiento simplemente no es creíble. Quitarlas reduce el ruido; quitar de más borra justo lo que informa. El programa ofrece dos escuelas:

Gblocks (Castresana 2000)

Escoge por reglas de **vecindad**: una columna se conserva si ella y sus vecinas cumplen ciertos requisitos. Sus parámetros son **conservada** y **muy conservada** (cuántas secuencias deben coincidir), **máx. contiguas** (cuántas columnas no conservadas seguidas se toleran), **bloque mínimo** (el largo mínimo de un bloque que se conserva) y **huecos permitidos**, con tres niveles: **ninguno**, **hasta la mitad** y **todos**.

Umbral por columna, al estilo de trimAl

Deciden columna por columna: **por proporción de huecos**, **por similitud de la columna**, o **huecos y similitud** a la vez, con los deslizadores **máx. huecos** y **mín. similitud**.

Sea cual sea el método, el programa **muestra primero lo que va a quitar**. La vista previa pinta las columnas condenadas sobre el alineamiento, y hasta que no pulses **Aplicar el recorte** no se toca nada; **Quitar la vista previa** cancela. La casilla **respetar codones** obliga a quitar codones completos, para no romper el marco.

✗ RECORTAR SIEMPRE, POR COSTUMBRE

Recortar no siempre mejora el árbol. Hay trabajos publicados donde quitar columnas **empeora** la inferencia, porque junto con el ruido se van sitios informativos. La comprobación honesta es hacer el análisis **con y sin recorte** y ver si el árbol cambia. Si perdiste más de la mitad de las columnas, el problema no era el ruido: era el alineamiento.

2.9 Control de calidad: once cosas que se revisan

La última sección del bloque busca «lo que arruina un análisis sin que se note en una hoja de cálculo». Éstas son las comprobaciones, con lo que significa cada aviso:

Tabla 2.3. Las comprobaciones del control de calidad.

Comprobación	Por qué importa
Nombres repetidos	Dos taxones con el mismo nombre rompen cualquier análisis posterior, y el error aparece mucho más tarde.
Nombres con caracteres difíciles	Paréntesis, comas y acentos que otros programas no aceptan: importa si vas a exportar a NEXUS o a Newick.

Tabla 2.3. Las comprobaciones del control de calidad. (continuación)

Comprobación	Por qué importa
Secuencias muy cortas	Las que miden menos de la mitad que la más larga quedarán colgando de casi nada y su posición será inestable.
Secuencias idénticas	No es un error, pero sus ramas quedan en cero y algunos análisis se comportan mal. Conviene saberlo antes.
Caracteres inesperados	Letras que no corresponden al tipo de dato declarado: casi siempre, una proteína marcada como ADN o al revés.
Taxones con muchos huecos	Más de la mitad de huecos o datos faltantes en un taxón.
Columnas vacías	Sin ningún residuo; suelen quedar tras editar y conviene quitarlas.
Cuántas columnas son constantes	La proporción de columnas que no cambian, y cuántas son variables. Es la materia prima real del análisis.
Codones de paro internos	En una región codificante indican un marco de lectura equivocado o un pseudogén. El programa prueba los tres marcos y dice cuál es el bueno.
Longitud múltiplo de tres	Si no lo es, el último codón queda incompleto.
G+C desigual entre secuencias	El aviso más sutil y el más importante: una composición desigual rompe el supuesto de casi todos los modelos, y hace que dos taxones no emparentados se atraigan en el árbol. El Bloque 3 lo somete a una prueba formal.

✦ LOS DOS AVISOS QUE NUNCA HAY QUE IGNORAR

Los **codones de paro internos** y la **composición desigual de G+C**. El primero significa casi siempre que algo está mal en los datos —marco equivocado, secuencia invertida, pseudogén— y es fácil de arreglar. El segundo no se arregla cambiando de modelo de sustitución: se aborda quitando la tercera posición del codón, pasando a aminoácidos o recodificando, y el capítulo 3 explica por qué.

2.10 Exportar, y qué se lleva al Bloque 3

El bloque escribe FASTA, PHYLIP, NEXUS con sus *charsets*, esquemas de partición del estilo de RAxML y CSV. Sirve tanto para guardar el trabajo como para llevarlo a otro programa.

Al Bloque 3 pasa el conjunto de particiones alineadas, cada una con su **genoma**, su **tipo de dato**, y —si es codificante— su marco de lectura. Si vuelves a este bloque y cambias el alineamiento, los bloques que dependían de él te lo dirán en lugar de seguir mostrando un resultado viejo.

2.11 Errores frecuentes

✗ ALINEAR Y PASAR AL SIGUIENTE BLOQUE SIN MIRAR

Es el error más caro de todo el programa, y el más común. El alineamiento es la única hipótesis que ningún bloque posterior puede poner a prueba. Diez minutos en el visor valen más que cualquier refinamiento de modelo.

✗ NO ALINEAR POR CODÓN UNA REGIÓN CODIFICANTE

Cuesta una casilla y elimina una clase entera de error. Si tu partición codifica y la alineaste por nucleótido, vuelve y hazlo otra vez.

✗ DEJAR EL GENOMA EN EL VALOR POR OMISIÓN

Los menús de genoma empiezan con una suposición basada en el nombre del marcador. Si tu partición se llama «gen1», esa suposición será mala. Corrígela: el Bloque 11 depende de ella para distinguir un conflicto biológico real de un error.

✗ CONCATENAR ANTES DE HABER MIRADO CADA GEN POR SEPARADO

La concatenación promedia. Si dos genes tienen historias distintas —que es justo lo que este programa sabe detectar en el Bloque 11—, concatenar primero esconde el hallazgo. Alinea y revisa cada partición por su cuenta, y concatena después.

✗ CONFUNDIR «MUCHAS POSICIONES» CON «MUCHOS DATOS»

Mil posiciones de las cuales treinta son informativas para parsimonia resuelven poco. El control de calidad dice cuántas columnas son constantes y cuántas variables; ésa es la cifra que hay que mirar, y la que conviene reportar en el artículo.

3

CAPÍTULO TRES · BLOQUE 3

Modelos de sustitución

Un sitio que cambió dos veces sólo enseña el último cambio. Este bloque se ocupa de eso: primero pone a prueba los supuestos que todos los modelos dan por buenos —composición homogénea y señal no saturada—, y luego ajusta 56 modelos de ADN, doce matrices de proteína o Mk y Mkv para morfología, y deja que los criterios de información elijan. No es un trámite: el modelo elegido determina las longitudes de rama, el apoyo y, en los casos difíciles, la topología misma.

3.1 Qué se decide en este bloque

3.3 Los supuestos, puestos a prueba

3.5 Cómo se elige: AIC, AICc, BIC y pesos

3.7 Las pruebas jerárquicas de razón de verosimilitud

3.9 Errores frecuentes

3.2 Qué traen tus datos

3.4 El catálogo de modelos

3.6 Leer el modelo ganador

3.8 El esquema de particiones

3.1 Qué se decide en este bloque

Las diferencias que se observan entre dos secuencias **subestiman** los cambios que de verdad ocurrieron, porque un sitio que cambió de A a G y luego a T se cuenta como un cambio, no como dos, y si volvió a A no se cuenta ninguno. Un modelo de sustitución es la herramienta que convierte lo observado en una estimación de lo ocurrido.

Elegirlo bien importa tanto como elegir el método de inferencia. Un modelo demasiado simple subestima las ramas largas —y con ello alimenta la atracción de ramas largas del capítulo 1—; uno demasiado complejo gasta parámetros que los datos no pueden estimar y aumenta la varianza sin quitar sesgo.

✦ POR QUÉ NO BASTA CON «USAR SIEMPRE GTR+I+G»

Es lo que hace mucha gente, y con miles de sitios rara vez sale mal. Pero con pocos datos el GTR+I+G tiene ocho parámetros libres más las longitudes de rama, y estimarlos todos sobre doscientas posiciones produce estimaciones muy imprecisas. Además, **+I y +G compiten por explicar lo mismo**: juntos suelen dar valores extremos de ambos que no significan lo que parecen. Este bloque existe para que la elección sea del ajuste y no de la costumbre.

El bloque trabaja sobre **una partición alineada** a la vez, que se elige en el menú **partición**. Si tienes varias, la sección 4 del panel busca además cómo agruparlas.

3.2 Qué traen tus datos

La primera sección resume la partición antes de tocar nada: cuántos taxones, cuántos sitios, cuántas columnas son **constantes**, cuántas **variables** y cuántas **informativas**, el contenido de G+C y la proporción de huecos.

La frase que encabeza la sección dice algo que conviene entender bien: *los sitios constantes no informan de la topología pero sí del modelo*. Una columna donde todos los taxones tienen A no elige entre topologías, pero sí dice que en ese sitio no hubo cambios, y eso es información directa sobre las tasas y sobre la proporción de sitios invariables. Por eso **quitar los sitios constantes «porque no aportan» sesga las longitudes de rama hacia arriba**: el modelo cree que hubo más cambio del que hubo.

3.3 Los supuestos, puestos a prueba

Antes de elegir modelo, el bloque comprueba los dos supuestos que **ningún** modelo de la lista relaja.

Composición por secuencia

Todos los modelos habituales suponen que la composición de bases es la misma en todas las secuencias y en todo el árbol. La gráfica muestra la composición de cada secuencia, y una prueba χ^2 contrasta cada una contra la media.

! QUÉ HACER SI LA COMPOSICIÓN ES HETEROGÉNEA

Lo que **no** funciona es cambiar de modelo de sustitución: ninguno de los 56 lo arregla, porque todos comparten ese supuesto. Dos secuencias con composición parecida se atraen en el árbol aunque no sean parientes, y el apoyo será alto. Las salidas reales son tres: **quitar la tercera posición del codón**, que suele ser la culpable; **pasar a aminoácidos**, cuya composición varía menos; o **recodificar** los nucleótidos en purinas y pirimidinas. La ficha de ayuda de la prueba χ^2 lo dice también en pantalla.

Saturación

La segunda gráfica es la que practicaste en el laboratorio 2 del capítulo 1, ahora sobre tus datos: transiciones y transversiones contra la distancia corregida. La regla se lee igual: **mientras la nube siga una recta, el marcador informa; cuando se dobla y se aplana, está saturado**. Las transiciones se saturan antes que las transversiones, y la tercera posición del codón antes que la primera y la segunda.

Recuerda lo que saturado significa y lo que no significa: el marcador sigue resolviendo bien los nodos recientes; lo que no puede es sostener los nodos profundos **y su apoyo**.

3.4 El catálogo de modelos

Para ADN, el catálogo se construye combinando tres cosas: siete **esquemas de tasas**, dos formas de tratar las **frecuencias de base** y cuatro **variantes de variación entre sitios**. Siete por dos por cuatro son **56 modelos**.

Tabla 3.1. Los siete esquemas de tasas. El nombre de la izquierda es el que lleva con frecuencias iguales; el de la derecha, con frecuencias empíricas.

Frec. iguales	Frec. empíricas	Tasas libres	Qué distingue
JC	F81	0	Todos los cambios a la misma tasa.
K80	HKY	1	Transiciones y transversiones a tasas distintas: el parámetro κ .
TrNef	TrN	2	Las dos clases de transición se separan.
K81	K81uf	2	Dos clases de transversión.
TMef	TIM	3	Transiciones separadas y transversiones separadas.
TVMef	TVM	4	Todas las transversiones libres, transiciones iguales.
SYM	GTR	5	Las seis tasas libres: el más general.

Y las cuatro variantes, que se aplican a cualquiera de los catorce:

Tabla 3.2. Las cuatro variantes de variación de tasas entre sitios.

Variante	Qué añade
(ninguna)	Todos los sitios cambian a la misma velocidad. Casi nunca es cierto.
+I	Una proporción de sitios incapaces de cambiar, no simplemente sitios que no cambiaron.
+G	Las velocidades se reparten según una gamma discreta (Yang 1994), con forma α . Es la variante que más suele importar.
+I+G	Las dos a la vez. Compiten por explicar lo mismo; véase el aviso de la sección 3.6.

Para **proteínas**, el catálogo son doce matrices empíricas —LG, WAG, JTT, Dayhoff, cpREV, mtREV24, VT, RtREV, Blosum62, FLU, HIVb y mtmam—, también con las cuatro variantes. El conjunto **rápido** prueba seis (LG, WAG, JTT, cpREV, Dayhoff y VT) y el **estándar** las doce. **cpREV está ahí por una razón concreta**: se estimó con proteínas codificadas por el cloroplasto, que es de donde vienen la mayoría de los marcadores de sistemática vegetal.

1 DE DÓNDE SALEN ESAS DOCE MATRICES

Son las matrices publicadas en sus artículos originales, cada una citada en el código junto a sus números, y verificadas valor por valor contra cinco distribuciones canónicas independientes —PAML, IQ-TREE, MrBayes, RAXML y el archivo que los propios autores de WAG pusieron en el EBI—. El archivo **PROCEDENCIA.md** documenta la comprobación.

Para **morfología**, el modelo es **Mk** (Lewis 2001): un modelo de k estados con todas las tasas iguales. Su variante **Mkv** añade la corrección para el hecho de que las matrices morfológicas casi nunca incluyen caracteres constantes —nadie codifica el carácter «tiene células»—, y sin esa corrección las ramas salen infladas.

Los controles

- **conjunto**: **rápido** o **estándar**, según cuántos candidatos quieras probar.
- **criterio**: AIC, AICc o BIC, que es el que ordena la tabla.
- **categorías de Γ** : en cuántas clases discretas se parte la gamma. Cuatro es lo habitual y lo que casi todo el mundo reporta.
- **árbol de partida**: **BIONJ**, **optimizado por ML**, **vecino más cercano** o **UPGMA**. Todos los candidatos se ajustan **sobre el mismo árbol**, que es lo que hace comparable la comparación.

3.5 Cómo se elige: AIC, AICc, BIC y pesos

Un modelo con más parámetros **siempre** da mejor verosimilitud, aunque los parámetros de más no sirvan de nada. Por eso no se compara la lnL a secas, sino una cantidad que premia el ajuste y castiga los parámetros:

Σ LAS TRES FÓRMULAS

$$\text{AIC} = -2 \cdot \ln L + 2k \quad \cdot \quad \text{AICc} = \text{AIC} + 2k(k+1)/(n-k-1) \quad \cdot \quad \text{BIC} = -2 \cdot \ln L + k \cdot \ln(n)$$

donde k es el número de parámetros y n el de sitios. En los tres, **menor es mejor**. AICc corrige para muestras pequeñas y se acerca a AIC cuando n es grande. BIC castiga más fuerte y por eso suele elegir modelos más simples.

Lo que se lee en la tabla no es el valor absoluto sino la **diferencia con el mejor**, ΔAIC . La convención de Burnham y Anderson: por debajo de 2, el modelo es prácticamente indistinguible del ganador; entre 4 y 10, claramente peor; por encima de 10, descartado.

La columna de **pesos de Akaike** convierte esas diferencias en probabilidades que suman uno: el peso de un modelo es la probabilidad de que sea el mejor **del conjunto comparado**. Un ganador con peso 0.9 zanja la cuestión; varios modelos repartiéndose el peso significa que los datos no distinguen entre ellos, y entonces conviene comprobar que el árbol no cambia según cuál se use.

! «EL MEJOR DEL CONJUNTO» NO ES «BUENO»

Si todos los candidatos son malos para estos datos —por ejemplo, porque la composición es heterogénea y ninguno lo modela—, el peso 0.99 se lo lleva el menos malo. Elegir el modelo no es el análisis, y un GTR+ Γ ajustado sobre un alineamiento torcido sigue siendo un GTR+ Γ ajustado sobre un alineamiento torcido.

3.6 Leer el modelo ganador

Elegido el modelo, el programa lo **reajusta en serio**, con todas las ramas optimizadas, y muestra sus piezas.

La matriz de tasas

Las seis tasas de intercambiabilidad entre pares de bases y las cuatro frecuencias de equilibrio. Vale la pena mirar la razón entre transiciones y transversiones: en ADN nuclear y de cloroplasto lo normal ronda 2, y un valor cercano a 1 en un gen que debería tener más es una señal de saturación —las transiciones, que se saturan primero, ya se borraron—.

La forma de la gamma (α)

Describe cuán desigual es el reparto de velocidades entre sitios. Por debajo de 1 la heterogeneidad es fuerte: unos pocos sitios muy rápidos y muchos casi congelados. Por encima de 3, las velocidades son casi iguales y +G apenas aporta. La gráfica **Tasas entre sitios** dibuja las categorías discretas con su velocidad relativa.

**INTERPRETAR A Y LA PROPORCIÓN DE INVARIABLES POR SEPARADO EN UN +I+G**

+I y +G explican el mismo fenómeno por dos caminos, y cuando se ajustan juntos se reparten el trabajo de forma inestable: es corriente obtener una proporción de invariables alta y una α baja, y que ninguno de los dos valores signifique lo que parece. Muchos autores recomiendan usar +G sola. Si necesitas reportar I y α , hazlo diciendo que provienen de un ajuste conjunto.

El veredicto en palabras

Bajo las tablas, el panel escribe en prosa qué modelo ganó, por cuánto, y qué significan sus parámetros. Es el texto que se puede llevar casi tal cual a la sección de métodos, y es el que el Bloque 12 reutiliza al escribir el informe.

3.7 Las pruebas jerárquicas de razón de verosimilitud

La otra manera de elegir, anterior a los criterios de información y todavía muy pedida por los revisores. Compara modelos **anidados** —uno es caso particular del otro— con el estadístico $2\Delta\ln L$ contra una χ^2 con tantos grados de libertad como parámetros de diferencia, y encadena las pruebas hasta quedarse con el modelo más simple que no se rechaza.

El programa la ofrece porque se sigue pidiendo, y al mismo tiempo dice por qué los criterios de información son la vía preferida hoy:

- El resultado **depende del orden** en que se encadenan las pruebas, y no hay un orden canónico.
- Sólo compara modelos anidados, de modo que deja fuera comparaciones perfectamente sensatas.
- La χ^2 es una aproximación asintótica y **no vale cuando un parámetro queda en el borde de su rango**, que es exactamente el caso de +I: la proporción de invariables se prueba contra cero, que es su límite.

3.8 El esquema de particiones

Con varias particiones la pregunta no es sólo qué modelo, sino **cuántos modelos distintos hacen falta**. Dar a cada gen el suyo es lo más flexible y lo más caro en parámetros; darles uno solo a todos es lo más barato y puede ser falso.

Buscar el esquema hace una **fusión codiciosa** al estilo de PartitionFinder: empieza con una partición por gen, prueba en cada paso la fusión de dos que mejore el criterio de información, y se detiene cuando ninguna fusión mejora. El resultado dice qué particiones comparten modelo y cuáles merecen el suyo.

Con un gen partido por posición de codón, el resultado típico es que la primera y la segunda posición se fusionan y la tercera se queda sola, que es exactamente lo que la biología predice.

El botón **Exportar el modelo elegido** guarda el esquema y el modelo para llevarlos a otro programa o para dejar constancia.

3.9 Errores frecuentes

✗ ELEGIR EL MODELO SIN MIRAR ANTES LOS SUPUESTOS

Las dos gráficas de la sección 2 del panel son más importantes que toda la tabla de modelos. Si la composición es heterogénea o el marcador está saturado, el modelo ganador será el menos malo de una lista de modelos inadecuados, y su peso de Akaike de 0.99 no dirá nada al respecto.

✗ REPORTAR SÓLO EL NOMBRE DEL MODELO

«Se usó GTR+I+G» es la mitad de la información. Faltan el criterio con que se eligió, el número de categorías de la gamma, y —si hubo particiones— el esquema. El informe del Bloque 12 lo escribe completo.

✗ QUITAR LOS SITIOS CONSTANTES

No informan de la topología, pero sí del modelo. Quitarlos infla las longitudes de rama. La única situación en que se quitan es cuando el modelo lo sabe y lo corrige, que es lo que hace Mkv en morfología.

✗ CREER QUE ELEGIR BIEN EL MODELO ARREGLA EL ÁRBOL

Mejora las longitudes de rama, el apoyo y, en los casos difíciles, la topología. No arregla un alineamiento malo, ni una composición heterogénea, ni un muestreo de taxones que deja una rama larga sola. El orden de importancia es: datos, alineamiento, muestreo, modelo.

4

CAPÍTULO CUATRO · BLOQUE 4

Parsimonia y distancias

Los árboles rápidos: los que salen en segundos y sirven de punto de partida para la verosimilitud y de contraste para todo lo demás. Un árbol de distancias no es una hipótesis débil si el modelo que corrige las distancias es el adecuado, y la parsimonia sigue siendo la herramienta correcta para morfología. Este capítulo explica los dos, sus índices, cómo se mide el soporte de una rama y qué dice un consenso cuando hay muchos árboles igual de cortos.

4.1 Para qué sirven los árboles rápidos

4.3 Máxima parsimonia

4.5 Los índices: CI, RI, RC y HI

4.7 Consensos y comparación

4.9 Qué tan bien lo hace, medido

4.2 Árboles de distancia

4.4 La búsqueda: NNI, SPR y TBR

4.6 El soporte de las ramas

4.8 La figura

4.10 Errores frecuentes

4.1 Para qué sirven los árboles rápidos

Este bloque produce árboles en segundos, y eso hace fácil menospreciarlos. No conviene. Tienen tres usos legítimos:

- **Punto de partida.** La búsqueda de máxima verosimilitud del Bloque 5 necesita un árbol inicial, y cuanto mejor sea, menos riesgo hay de quedarse en un óptimo local.
- **Contraste.** Si el árbol de distancias, el de parsimonia y el de verosimilitud coinciden en los clados principales, eso es información. Si discrepan, también, y hay que entender por qué antes de publicar cualquiera de ellos.
- **La herramienta adecuada para morfología.** Con caracteres discretos y pocos cambios, la parsimonia no es una aproximación barata a la verosimilitud: es el método que la disciplina usa, y con razón.

✦ UN ÁRBOL DE DISTANCIAS NO ES UNA HIPÓTESIS DÉBIL

Lo es cuando las distancias están mal corregidas, que es distinto. Con el modelo adecuado, la unión de vecinos es un **estimador consistente**: con suficientes datos converge al árbol verdadero. Su mala fama viene de usarlo con distancias sin corregir, que es lo que sí falla en cuanto hay saturación.

4.2 Árboles de distancia

El método consta de dos decisiones: **cómo se mide la distancia** entre cada par de secuencias y **cómo se construye el árbol** a partir de la matriz.

Las distancias

Tabla 4.1. Las distancias que ofrece el menú **distancia**.

Distancia	Qué corrige y cuándo usarla
sin corregir (p)	La proporción de posiciones distintas. Útil sólo para ver cuánto corrige el resto; no para inferir.
JC69	Cambios múltiples, suponiendo que todos los cambios son igual de probables.
K80	Separa transiciones de transversiones. El mínimo razonable para ADN.
F81	Admite frecuencias de base desiguales.
TN93	Frecuencias desiguales y dos clases de transición. El más completo de la lista.
LogDet (Lockhart)	El único que tolera composición heterogénea entre secuencias. Si la prueba χ^2 del Bloque 3 salió mal, ésta es la distancia a usar.
paralineal (Lake)	Pariente cercana de LogDet, con las frecuencias observadas.
Poisson y Kimura	Para proteínas: la primera sin corrección de composición, la segunda con la aproximación clásica de Kimura.

! DOS NOMBRES PARA DOS FÓRMULAS DISTINTAS

Lo que *ape* llama **logdet** es la distancia de Lockhart et al. (1994); la fórmula con las frecuencias observadas es la **paralineal** de Lake. Se confunden con frecuencia porque comparten el apodo. Aquí aparecen por separado y con su nombre, para que se pueda reportar cuál se usó.

Dos casillas modifican el cálculo. **corregir con Γ** aplica la corrección gamma con la α que estimó el Bloque 3, y **borrado completo** decide qué hacer con los huecos: activada, quita toda columna que tenga algún hueco antes de calcular cualquier par; desactivada, cada par usa las columnas que ambos tienen. Con muchos datos faltantes, el borrado completo puede dejarte con muy pocas columnas.

Los métodos

El menú **método** ofrece **unión de vecinos (NJ)**, **BIONJ**, **UPGMA** y **mínima evolución**.

! UPGMA SUPONE UN RELOJ MOLECULAR

Y la mayoría de los datos no lo cumplen. UPGMA produce un árbol **ultramétrico** —todas las puntas a la misma altura—, lo que es correcto para un dendrograma de agrupamiento y falso para una filogenia con tasas desiguales. Úsalo para ver estructura, no para inferir relaciones. NJ y BIONJ no suponen reloj.

La **mínima evolución balanceada** busca el árbol cuya longitud total, calculada con los promedios balanceados de Desper y Gascuel (2002) sobre el criterio de Pauplin (2000), sea la menor. Es un criterio de optimalidad de verdad, con búsqueda por NNI y SPR desde varios arranques, y no un simple algoritmo de agrupamiento.

4.3 Máxima parsimonia

El árbol que necesita menos cambios para explicar la matriz. Transparente, sin supuestos de modelo... **y por eso mismo vulnerable**, como viste en el laboratorio 1 del capítulo 1: sin un modelo que corrija los cambios múltiples, la parsimonia interpreta la convergencia como parentesco.

Los controles

- caracteres**: **no ordenados (Fitch)**, donde cualquier estado puede pasar a cualquier otro con un paso; **ordenados (Sankoff)**, donde el costo depende del par de estados y se puede imponer un orden —útil en morfología, cuando un carácter tiene estados graduales—; o **transversiones con más peso**, que penaliza las transversiones más que las transiciones.
- peso tv:ts**: cuánto más cuesta una transversión. Con 2:1, una transversión vale dos pasos. Es la forma que tiene la parsimonia de reconocer que las transiciones son más frecuentes.
- intercambio**: NNI, SPR o TBR (sección 4.4).

- **arranques**: cuántos órdenes de adición distintos se prueban. Varios arranques que lleguen al mismo árbol es la mejor señal de que la búsqueda fue suficiente.
- **máx. árboles**: cuántos árboles igual de cortos se conservan. Las matrices morfológicas producen a veces miles.

4.4 La búsqueda: NNI, SPR y TBR

El número de topologías crece más rápido que factorialmente: con veinte taxones hay más de 10^{20} árboles sin raíz. No se pueden evaluar todos, así que se parte de uno y se prueban reordenamientos.

Tabla 4.2. Los tres tipos de reordenamiento, de menor a mayor alcance.

Tipo	Qué hace	Cuándo
NNI	Intercambia los dos grupos vecinos a una rama interna. Movimientos pequeños.	Rápido; se queda en óptimos locales con facilidad.
SPR	Arranca una rama con todo lo que cuelga de ella y la reinjerta en otro sitio.	El equilibrio habitual entre alcance y tiempo.
TBR	Corta el árbol en dos y los vuelve a unir por todos los pares de ramas posibles.	El más exhaustivo y el más lento.

Ninguna búsqueda heurística **garantiza** el óptimo. Que dos programas den árboles distintos con el mismo criterio suele ser esto y no un desacuerdo de método: son dos óptimos locales.

4.5 Los índices: CI, RI, RC y HI

Cuando el árbol está, cuatro índices describen cuánta homoplasia —convergencia y reversión— contiene.

Σ LAS CUATRO DEFINICIONES

CI = m/s , el mínimo de cambios posible entre los que el árbol necesita. Vale 1 sin homoplasia.

HI = $1 - CI$, el índice de homoplasia: lo mismo dicho al revés.

RI = $(g-s)/(g-m)$, donde g es la longitud en el peor árbol posible: cuánta de la similitud que **podría** ser sinapomorfía lo es.

RC = $CI \times RI$, el índice de consistencia reescalado.

! EL CI BAJA CON EL NÚMERO DE TAXONES

Sistemáticamente, y sin que la homoplasia haya aumentado. Un CI de 0.8 con quince taxones y uno de 0.4 con doscientos pueden describir la misma matriz. Por eso **no se comparan CI entre estudios de tamaño distinto**, y por eso el RI, que corrige parte del problema, es el que conviene reportar.

4.6 El soporte de las ramas

La frase que encabeza esta sección en la pantalla merece repetirse: *un clado sin soporte no es un error del programa: es una politomía que tus datos no resuelven*. El programa ofrece tres medidas.

Bootstrap

Se remuestran las columnas del alineamiento **con reemplazo**, se rehace el árbol cientos de veces y se cuenta en qué porcentaje de las réplicas aparece cada rama. Mide la **consistencia de la señal** en los datos, no la probabilidad de que la rama sea correcta. La convención: 70 % para «bien apoyada», 95 % para fuerte.

Jackknife

Igual, pero en vez de remuestrear con reemplazo se **elimina** una fracción de las columnas en cada réplica. Da resultados parecidos al bootstrap y es algo más conservador.

Soporte de Bremer

Distinto en naturaleza: cuántos **pasos de más** hay que aceptar antes de encontrar un árbol donde esa rama ya no aparece. Se lee en pasos, no en porcentaje, y depende del tamaño de la matriz: en una matriz grande, un Bremer de 5 puede ser poco. Un valor de 1 significa que basta un paso para deshacer la rama.



CREER QUE EL BOOTSTRAP PROTEGE DEL ERROR SISTEMÁTICO

No lo hace, y es importante entenderlo. El bootstrap mide si la señal se sostiene al remuestrear los mismos datos bajo el mismo método. Si el método está sesgado —atracción de ramas largas, composición heterogénea—, la señal errónea está en **todas** las réplicas, y el bootstrap apoyará la rama equivocada con un 100 %. Con más datos, la apoyará más.

4.7 Consensos y comparación

Cuando la búsqueda devuelve varios árboles igual de cortos, la pregunta es en qué coinciden. El menú ofrece cuatro consensos:

Tabla 4.3. Los cuatro consensos.

Consenso	Conserva
estricto	Sólo los clados presentes en todos los árboles. El más conservador y el que se publica por omisión.
mayoría (50 %)	Los clados presentes en más de la mitad, con su frecuencia anotada.
semiestricto	Los clados que no contradice ningún árbol, aunque no estén en todos. Útil cuando faltan taxones en algunos.
codicioso	Añade clados por frecuencia mientras sean compatibles. El más resuelto y el menos conservador.

Las politomías de un consenso estricto **son el resultado**: dicen exactamente dónde los datos no deciden. Un consenso muy colapsado no es un fracaso del análisis; es un análisis honesto sobre datos que no alcanzan.

La tabla **En qué se parecen los árboles obtenidos** compara por distancia de Robinson–Foulds todo lo que el bloque ha producido —distancias, parsimonia, consensos— para ver de un vistazo qué métodos coinciden.

4.8 La figura

El dibujo es el mismo motor que usará el estudio de árboles del Bloque 12: forma **rectangular**, **circular** o **no enraizado**; **cladograma** para dibujar sin longitudes; soportes como **números**, **puntos de color** o **ninguno**; y raíz **como está**, **punto medio** o **grupo externo...**, con selección múltiple usando Ctrl.

I UN ÁRBOL SIN RAÍZ NO TIENE ANCESTROS

Los métodos de este bloque producen árboles **sin raíz**: describen relaciones, no dirección. Poner la raíz es una decisión adicional, y con un grupo externo es una hipótesis que se puede equivocar. Si eliges un grupo externo que no es monofilético en ese árbol, el programa lo dice y deja el árbol como estaba, en vez de enraizar mal en silencio.

4.9 Qué tan bien lo hace, medido

Todo lo de este bloque se comprobó contra *ape* y *phangorn*, y los resultados están en la carpeta de validación. Tres merecen mencionarse:

- La búsqueda de parsimonia alcanza **1916 pasos** en el ejemplo, **el mismo óptimo que pratchet** de *phangorn*, y trece pasos mejor que **optim.parsimony** con SPR.
- La longitud de mínima evolución balanceada reproduce la de **ape: :fastme.bal** a $5 \cdot 10^{-9}$ sobre el mismo árbol, de modo que la fórmula coincide exactamente.
- Con su propia búsqueda desde tres arranques, el programa llega a un árbol **más corto** (2.899076) que el de *ape* (2.901969). No es que uno esté mal: son dos óptimos locales del mismo criterio, y dónde cae una heurística depende de dónde empiece.

4.10 Errores frecuentes

✗ USAR DISTANCIAS SIN CORREGIR

Es lo que le dio mala fama a los métodos de distancia. Con saturación, la distancia *p* subestima la divergencia justo donde más importa, y el árbol se deforma. Corrige siempre, y con el modelo que eligió el Bloque 3.

❌ PUBLICAR UN UPGMA COMO FILOGENIA

UPGMA supone reloj molecular. Si tus tasas son desiguales —y casi siempre lo son—, el árbol estará mal en una forma sistemática y predecible: los linajes rápidos saldrán más «derivados» de lo que son.

❌ REPORTAR UN SOLO ÁRBOL MÁS CORTO SIN DECIR CUÁNTOS HABÍA

Si la búsqueda encontró 4 800 árboles igual de cortos y publicas uno, estás presentando como resultado una elección arbitraria entre 4 800. Lo que se reporta es el consenso, el número de árboles óptimos y su longitud.

❌ COMPARAR EL CI CON EL DE OTRO TRABAJO

Sólo es comparable entre matrices del mismo tamaño. Reporta el RI, y en cualquier caso di cuántos taxones y cuántos caracteres tenía la matriz.

❌ DAR POR BUENA LA BÚSQUEDA CON UN SOLO ARRANQUE

Un solo punto de partida y NNI es la receta para quedarse en un óptimo local. Sube los arranques, usa SPR o TBR, y comprueba que varios arranques llegan a la misma longitud. Si no llegan, la búsqueda no ha terminado.

5

CAPÍTULO CINCO · BLOQUE 5

Máxima verosimilitud

El árbol que se publica. Bajo un modelo explícito, la verosimilitud busca la topología y las longitudes que hacen más probables los datos observados, y —a diferencia de la parsimonia— es **consistente** mientras el modelo sea razonable. Este capítulo explica la búsqueda, el ajuste con un modelo por partición, las **cuatro** medidas de apoyo con sus cuatro umbrales distintos, y cómo poner formalmente a prueba la hipótesis de otro autor.

5.1 Qué optimiza, y por qué importa

5.3 La búsqueda: NNI, SPR y el radio

5.5 Un modelo por partición

5.7 Poner a prueba una hipótesis

5.9 Qué tan bien lo hace, medido

5.2 El modelo y el árbol inicial

5.4 Leer el resultado

5.6 Las cuatro medidas de apoyo

5.8 Los hilos, y por qué tarda lo que tarda

5.10 Errores frecuentes

5.1 Qué optimiza, y por qué importa

La verosimilitud de un árbol es la probabilidad de haber observado **estos datos** si ese árbol y ese modelo fueran ciertos. El árbol de máxima verosimilitud es el que hace esa probabilidad más alta. Se reporta como logaritmo, siempre negativo, y menos negativo es mejor.

! UNA LNL SOLA NO SIGNIFICA NADA

Su valor absoluto depende del número de sitios y de taxones. Sólo tiene sentido **comparar** verosimilitudes calculadas sobre exactamente los mismos datos. Una lnL de -18 674 no es «mala» ni «buena»: es la de estos datos bajo este modelo, y sólo sirve frente a otra del mismo alineamiento.

La ventaja decisiva sobre la parsimonia es la del capítulo 1: bajo el modelo correcto, la verosimilitud es **consistente**, es decir, con suficientes datos converge al árbol verdadero incluso cuando hay ramas largas desiguales. La parsimonia, en esa misma geometría, converge con seguridad creciente al árbol falso.

La condición «bajo el modelo correcto» no es retórica. Si el modelo está mal especificado —composición heterogénea sin modelar, saturación no corregida—, la verosimilitud también se equivoca, y con más datos se equivoca con más confianza. Por eso el Bloque 3 va antes que éste.

5.2 El modelo y el árbol inicial

La primera fila de controles fija el modelo: **modelo** (GTR, HKY, LG...), **+Γ** con tantas **categorías**, **+I**, y las **frecuencias**, que pueden ser **empíricas** —contadas en el alineamiento— o **iguales**. El botón **Usar el modelo elegido en el Bloque 3** copia lo que ganó allí, que es lo que conviene hacer casi siempre.

I LA CASILLA ESTIMARLAS (+F)

Por omisión las frecuencias de base se toman **contadas** del alineamiento, que es lo que hace `phangorn::optim.pml` sin `optBf`, y por eso los resultados del programa coinciden con los suyos. Activando **+F** se estiman por máxima verosimilitud junto con todo lo demás, lo que suele dar una lnL algo mejor. Está apagada por omisión para conservar esa comparabilidad, no porque sea peor.

El **árbol inicial** puede ser el de **parsimonia (Bloque 4)**, el de **distancias (Bloque 4)**, BIONJ, o uno **al azar**. No es un detalle menor: la búsqueda es heurística, y de dónde parte determina en qué óptimo local puede quedarse. Probar dos puntos de partida distintos y llegar a la misma lnL es la mejor prueba de que la búsqueda fue suficiente.

5.3 La búsqueda: NNI, SPR y el radio

La búsqueda parte del árbol inicial y prueba reordenamientos: primero **NNI**, que intercambia ramas vecinas, y después **SPR**, que corta una rama entera y la vuelve a pegar en otro sitio. El menú **reordenamientos** permite usar sólo NNI o NNI + SPR.

Dos controles gobiernan el costo:

- **radio del SPR**: a qué distancia máxima, en número de ramas, se permite reinjertar. Un radio pequeño es rápido y explora poco; uno grande explora mucho y tarda. Cinco es un punto de equilibrio razonable.
- **rondas máx.**: cuántas pasadas completas de reordenamientos se hacen antes de parar.

Σ POR QUÉ LA BÚSQUEDA ES RÁPIDA SIN SER TRAMPOSA

Puntuar cada candidato reoptimizando el árbol entero sería inviable. El programa hace lo que hacen PhyML y RAxML: para cada movimiento, **reoptimiza sólo las ramas que el movimiento tocó**, apoyándose en el cálculo incremental del motor de verosimilitud. El SPR va además en **dos pasadas**: primero se puntúan todos los candidatos con las longitudes heredadas —el «SPR perezoso» de RAxML—, y después sólo la docena mejor se vuelve a puntuar con su vecindario reoptimizado. El árbol ganador se reajusta entero al final.

5.4 Leer el resultado

Los mosaicos resumen la corrida: la **log-verosimilitud**, el número de **parámetros** (ramas más modelo), **AIC** y **BIC**, cuántas **rondas** hicieron falta y cuántas topologías se evaluaron, el **tiempo**, y los parámetros estimados del modelo —la **α** de la gamma y la **κ** o las tasas relativas—.

Bajo los mosaicos, el panel escribe en prosa qué significan. Conviene fijarse en dos cosas:

- El número de **rondas**. Si la búsqueda terminó en una sola ronda, quizá no exploró nada; si agotó el máximo, probablemente aún mejoraba y conviene subirlo.
- La **α** . Por debajo de 1 hay heterogeneidad fuerte entre sitios, y no modelarla habría deformado las ramas largas.

5.5 Un modelo por partición

Un gen de cloroplasto y el ITS nuclear no evolucionan al mismo ritmo ni con la misma composición. El ajuste particionado reconoce eso sin romper el árbol: todas las particiones **comparten la topología y las proporciones de las ramas**, pero cada una tiene su propio modelo y un **multiplicador de velocidad**, normalizado a media uno pesada por sitios.

Así, una partición con multiplicador 0.3 evoluciona a un tercio de la velocidad media, y una con 2.5, dos veces y media más rápido.

❗ POR QUÉ EL AJUSTE ARRANCA «ATADO»

Soltar todas las particiones desde el primer momento hacía que la búsqueda cayera en un óptimo peor. El programa arranca con todas compartiendo un mismo modelo durante las primeras pasadas y las va soltando después. Es un detalle de implementación, pero explica por qué el resultado particionado nunca queda por debajo del modelo único que lo contiene.

! PARTICIONAR NO RESUELVE UN CONFLICTO REAL

Dar a cada gen su velocidad no lo libera de **compartir el árbol**. Si dos genes tienen historias genuinamente distintas —captura de cloroplasto, hibridación—, el análisis particionado las promedia con más elegancia, pero las promedia igual. Destaparlas es el trabajo del Bloque 11.

5.6 Las cuatro medidas de apoyo

Ésta es la sección del capítulo que más errores evita. El programa calcula cuatro medidas, y **no significan lo mismo ni se leen con el mismo umbral**.

Tabla 5.1. Las cuatro medidas de apoyo, con su umbral convencional.

Medida	Umbral	Qué mide
Bootstrap clásico	≥ 70	En qué porcentaje de alineamientos remuestreados con reemplazo reaparece la rama. Conservador: 70 ya es bastante apoyo.
Bootstrap ultrarrápido (UFBoot)	≥ 95	Una aproximación por RELL, construida para ser casi insesgada . Su escala no es la del bootstrap clásico.
SH-aLRT	≥ 80	Compara la verosimilitud del árbol con la de las dos reorganizaciones NNI de esa rama. Otra pregunta, no otra versión de la misma.
aBayes	—	Una aproximación bayesiana rápida sobre la misma comparación local.

✗ EL ERROR MÁS FRECUENTE CON EL UFBOOT

Leerlo con el umbral del bootstrap clásico. Como el UFBoot es casi insesgado, es **menos conservador**: un 90 % de UFBoot no equivale a un 90 % de bootstrap sino a bastante **menos** apoyo. Por eso su umbral es 95 y no 70. El encabezado de la tabla en pantalla lleva el umbral escrito, precisamente para que no se confundan.

La costumbre en la literatura reciente es exigir **las dos cosas**: SH-aLRT ≥ 80 y UFBoot ≥ 95 . Son información distinta —una mide si la rama mejora la verosimilitud, la otra si la señal se sostiene al remuestrear— y una rama que pasa ambas está mucho mejor sostenida que una que pasa sólo una.

✦ LO QUE NINGUNA DE LAS CUATRO MIDE

Si el árbol es correcto. Las cuatro miden la **consistencia interna** de la señal bajo el método y el modelo empleados. Si el modelo está mal, las cuatro apoyarán la rama equivocada, y con más datos la apoyarán más. El apoyo alto es necesario, no suficiente.

5.7 Poner a prueba una hipótesis

Aquí el bloque deja de describir y empieza a contrastar. La pregunta es: ¿**rechazan** mis datos el árbol que propone otro autor, o el que propone mi hipótesis?

Se hace en dos pasos:

- 1 Seleccionar los **taxones del grupo que se pone a prueba** y pulsar **Buscar el mejor árbol con esa restricción**: el programa busca el mejor árbol **obligando** a que ese grupo sea monofilético. Ése es el mejor caso posible para la hipótesis.
- 2 Pulsar **Comparar los árboles (KH, SH, AU)**: las tres pruebas contrastan el árbol restringido contra el sin restricción, usando réplicas RELL.

Un valor p por debajo de 0.05 rechaza el árbol alternativo. De las tres, la prueba **AU** es la que mejor corrige el sesgo de selección y es la que conviene reportar; KH y SH están porque se siguen pidiendo.

! «NO RECHAZADO» NO ES «IGUAL DE BUENO»

Con pocos datos no se rechaza casi nada, y con muchos se rechaza casi todo. Un resultado no significativo dice que **tus datos no alcanzan para descartar** esa hipótesis, no que sea correcta. Y el conjunto de árboles a comparar hay que fijarlo **antes** de mirar los resultados: elegir después qué comparar es exactamente el sesgo que la prueba AU trata de corregir.

5.8 Los hilos, y por qué tarda lo que tarda

El bootstrap y las cadenas bayesianas se reparten en **hilos** del navegador, contruidos a partir del propio código del programa. Dos cosas medidas que conviene saber:

- Un hilo recién creado **corre interpretado** y sólo alcanza el código optimizado tras unos segundos de repetir los mismos bucles. Por eso **16 réplicas en 16 hilos tardan más que las mismas 16 en seis**: cada hilo paga su calentamiento entero y lo tira. El programa nunca reparte menos de tres trabajos por hilo.
- Cien réplicas de bootstrap por máxima verosimilitud tardan minutos. Es JavaScript, no C, y la página lo dice antes de empezar, con una estimación y un botón de cancelar.

Si el navegador no permite hilos —algunas configuraciones los bloquean—, el trabajo se hace en la página, más lento pero sin fallar.

5.9 Qué tan bien lo hace, medido

La validación de este bloque contrasta contra *phangorn* sobre el mismo alineamiento de *rbcl*. El resultado, que está en la carpeta de validación y se puede reproducir:

Tabla 5.2. La búsqueda de máxima verosimilitud comparada con *phangorn* 2.12.1, sobre *rbcl*.

Búsqueda	lnL alcanzada	Comentario
<code>phangorn::optim.pml</code> con NNI	-7126.989550	La búsqueda estándar del paquete.
<code>phangorn</code> , búsqueda estocástica	-7108.802104	Su búsqueda más exhaustiva.
PhylogenyPro , NNI + SPR, 52 s	-7108.800752	Mejor que la NNI por 18 unidades, y algo mejor que la estocástica.

La diferencia con la búsqueda NNI —dieciocho unidades de log-verosimilitud— no es un matiz: es la diferencia entre quedarse en un óptimo local y salir de él, y es exactamente lo que el SPR compra.

5.10 Errores frecuentes

✗ LEER EL UFBOOT CON EL UMBRAL DEL BOOTSTRAP

Ya dicho, y se repite porque es el más común: 70 para el bootstrap clásico, **95** para el ultrarrápido, 80 para SH-aLRT. Tres medidas, tres umbrales.

✗ BUSCAR UNA SOLA VEZ, DESDE UN SOLO ÁRBOL INICIAL

La búsqueda es heurística y no garantiza el óptimo. Si dos puntos de partida distintos llegan a lnL distintas, la mayor manda y la búsqueda no había terminado. Que lleguen a la misma es la única evidencia razonable de que sí.

✗ COMPARAR LNL ENTRE ALINEAMIENTOS DISTINTOS

Quitar tres columnas cambia la lnL, y no porque el árbol sea peor. Las verosimilitudes sólo se comparan sobre exactamente los mismos datos: mismo alineamiento, mismas columnas, mismos taxones.

✗ PRESENTAR UN ÁRBOL RESTRINGIDO COMO «EL ÁRBOL»

El árbol con restricción es el mejor caso **para la hipótesis que se pone a prueba**, no una estimación. Se calcula para compararlo, y lo que se publica es la comparación —la lnL de los dos y el valor p de la prueba AU—, no el árbol restringido a secas.

 CREER QUE EL APOYO ALTO VALIDA EL MODELO

Es al revés: el apoyo se calcula **suponiendo** el modelo. Si el Bloque 3 avisó de composición heterogénea o de saturación, un UFBoot de 100 no lo desmiente; lo repite con más seguridad.

6

CAPÍTULO SEIS · BLOQUE 6

Inferencia bayesiana

No «el mejor árbol», sino la probabilidad de cada árbol dados los datos **y lo que se supuso antes de verlos**. Ese segundo término es lo que distingue al método y lo que obliga a escribir los supuestos que en los demás quedan implícitos. Este capítulo explica los priors, la cadena y su acoplamiento, las cuatro cifras que dicen si convergió, cómo se leen las probabilidades posteriores —que no son bootstrap— y los factores de Bayes.

6.1 Qué cambia respecto de la verosimilitud

6.3 La cadena y su acoplamiento

6.5 Las probabilidades posteriores

6.7 Llevarse el resultado

6.9 Errores frecuentes

6.2 Lo que se supone antes de ver los datos

6.4 ¿Convergió? Las cuatro cifras

6.6 Factores de Bayes

6.8 Cómo se comprobó que el muestreador es correcto

6.1 Qué cambia respecto de la verosimilitud

La máxima verosimilitud pregunta: *¿qué árbol hace más probables estos datos?* La inferencia bayesiana pregunta lo contrario: *¿qué tan probable es cada árbol, dados estos datos?* Para poder responder eso hace falta algo más: una **distribución previa** que diga qué se creía antes de mirar los datos.

El resultado no es un árbol sino una **distribución** sobre árboles, longitudes y parámetros. De ella salen las probabilidades posteriores de cada clado y los intervalos de credibilidad de cada edad, que es lo que hace de este bloque el compañero natural del Bloque 7.

♦ EL PRIOR NO ES UNA DEBILIDAD DEL MÉTODO: ES UNA OBLIGACIÓN DE ESCRIBIRLO

Quien critica el bayesiano por «depender de supuestos» suele olvidar que la verosimilitud también supone —el modelo, la independencia entre sitios, la homogeneidad de composición—, sólo que no obliga a declararlo. Aquí hay que escribirlo, y eso es una ventaja: los supuestos quedan a la vista y se pueden discutir.

6.2 Lo que se supone antes de ver los datos

La primera sección del panel es la lista de priors. El botón **Usar el modelo del Bloque 5** copia el modelo ya elegido; los tres campos siguientes fijan las previas:

- **longitud media de rama (exponencial)**: la media de la exponencial sobre cada longitud de rama.
- **media de α (exponencial)**: la previa sobre la forma de la gamma.
- **media de las tasas (exponencial)**: la previa sobre las tasas del modelo de sustitución.

Además, el programa usa una **uniforme sobre topologías** —todas igual de probables antes de ver los datos— y una **Dirichlet** sobre las frecuencias de base.

! LA PREVIA DE LAS RAMAS NO ES INOCUA

Es el supuesto que más silenciosamente tuerce un resultado. Con la exponencial de media 0.1 —la de MrBayes por omisión— y datos **divergentes**, el posterior de la longitud total del árbol sale **a la mitad** de la del árbol de máxima verosimilitud: el prior tira de las ramas hacia abajo y gana. Está documentado (Brown et al. 2010; Marshall 2010) y el panel lo avisa antes de correr, comparando la previa con la longitud que midió el Bloque 5.

La solución no es quitar la previa —no se puede—, sino **elegirla a conciencia** y comprobar que el resultado no cambia con otra razonable.

6.3 La cadena y su acoplamiento

El muestreador es Metropolis–Hastings sobre topologías, longitudes y parámetros del modelo. En cada paso propone un cambio y lo acepta o lo rechaza según una regla que garantiza que, a la larga, la frecuencia con que visita cada árbol sea su probabilidad posterior.

Los controles son seis:

Tabla 6.1. Los controles de la cadena.

Control	Qué es
generaciones	Cuántos pasos da cada cadena. Más es mejor y más lento.
descarte inicial	La quema : las primeras generaciones, mientras la cadena sube desde donde la soltaron, se tiran.
muestrear cada	Cada cuántos pasos se guarda una muestra. Guardarlas todas no añade información, porque están correlacionadas.
corridas	Cuántas cadenas independientes , arrancadas por separado. Con menos de dos no se puede comprobar la convergencia.
cadenas por corrida	Las cadenas acopladas (MC ³) de cada corrida.
calentamiento	Cuánto se «aplana» el posterior de las cadenas calientes.

Σ PARA QUÉ SIRVE EL ACOPLAMIENTO (MC³)

Una sola cadena puede quedarse atrapada en un pico del posterior y no salir nunca, porque para llegar a otro pico tendría que atravesar un valle de baja probabilidad. El acoplamiento corre varias cadenas a la vez: una **fría**, que es la que muestrea, y varias **calientes** que ven un posterior aplanado y se mueven con mucha más libertad. Cada tanto, dos cadenas intercambian su posición. Así la fría puede saltar a un pico que la caliente encontró, sin dejar de muestrear la distribución correcta.

Cada corrida se ejecuta en su propio hilo del navegador, así que cuatro corridas aprovechan cuatro núcleos.

6.4 ¿Convergió? Las cuatro cifras

El programa pone los diagnósticos **antes** que el árbol, y no por capricho: un árbol bayesiano de una cadena que no convergió es un dibujo bonito de nada.

Tabla 6.2. Las cuatro cifras de convergencia y su umbral.

Cifra	Se busca	Qué dice
ESS	≥ 200	Cuántas muestras independientes equivalen a las que la cadena tomó. Diez mil muestras correlacionadas pueden valer por treinta.
PSRF ($\hat{R}$)	< 1.01	Compara la varianza dentro de cada cadena con la varianza entre cadenas independientes. Si todas exploran lo mismo, tiende a 1.
ASDSF	< 0.01	Cuánto se contradicen dos corridas sobre el apoyo de cada rama. Es la cifra que MrBayes imprime mientras corre.
La traza	—	El dibujo del logaritmo de la verosimilitud contra la generación. Donde deja de subir y empieza a oscilar, ahí acaba la quema.

❌ CONFIAR EN UNA TRAZA PLANA

Una traza plana no prueba convergencia: puede ser una cadena **atascada**, que lleva un millón de generaciones sin moverse de un óptimo local. Por eso hacen falta **varias corridas independientes** y el PSRF, que compara entre ellas. Y el PSRF necesita que las corridas empiecen en sitios **distintos**: arrancadas todas del mismo árbol pueden dar 1.00 y estar todas igual de equivocadas.

Un ESS alto tampoco basta por sí solo: dice que la cadena **mezcló bien donde estuvo**, no que haya recorrido todo el espacio.

6.5 Las probabilidades posteriores

El árbol que se reporta es el **consenso de mayoría** de las muestras, con la frecuencia de cada clado como probabilidad posterior. El umbral convencional de apoyo es **0.95**.

! UNA POSTERIOR NO ES UN BOOTSTRAP

Son escalas distintas y no se comparan. Para una misma rama, la probabilidad posterior suele ser **bastante más alta** que el bootstrap: no es que el bayesiano «apoye más», es que responde otra pregunta. Además, la posterior es conocida por ser **demasiado segura** cuando el modelo está mal especificado: puede dar 1.00 a una rama que el bootstrap apoya al 60 %. Un 1.00 no es una garantía; es una afirmación condicionada al modelo y a los priors.

El panel muestra además el **conjunto creíble** de árboles: cuántos árboles distintos hacen falta para acumular el 95 % del posterior. Si hacen falta tres, el resultado es firme; si hacen falta ochocientos, la topología está lejos de resolverse, por más que el consenso salga bien apoyado en algunas ramas.

6.6 Factores de Bayes

El AIC y el BIC comparan modelos con un atajo: castigan el número de parámetros. El factor de Bayes los compara **integrando sobre todos los valores posibles de esos parámetros** según el prior, que es más costoso y más correcto.

La cantidad que se integra es la **verosimilitud marginal**, y el programa la estima por **piedras de paso** (Xie et al. 2011): una serie de distribuciones intermedias entre el prior y el posterior, con los controles **escalones** y **generaciones por escalón**. Nunca por la media armónica, que es notoriamente mala.

Tabla 6.3. La escala de Kass y Raftery sobre $2 \cdot \ln(\text{BF})$.

$2 \cdot \ln(\text{BF})$	Evidencia a favor del mejor modelo
menos de 2	Nada que decir.
2 a 6	Positiva.
6 a 10	Fuerte.
más de 10	Muy fuerte.

⊗ COMPARAR FACTORES DE BAYES CALCULADOS CON PRIORS DISTINTOS

La verosimilitud marginal es **mucho más sensible al prior** que el posterior, porque integra sobre él. Dos personas con el mismo modelo y priors distintos pueden obtener factores de Bayes opuestos. Y la estimación tiene su propio error: repetirla con otra semilla dice cuánto, y conviene hacerlo antes de publicar un $2 \cdot \ln(\text{BF})$ de 7.

6.7 Llevarse el resultado

El bloque exporta el árbol de consenso con sus probabilidades posteriores y un **registro compatible con Tracer**, de modo que los diagnósticos se pueden revisar con la herramienta que la comunidad usa. El árbol pasa al Bloque 7 igual que el de máxima verosimilitud, y para datar es a menudo el preferible, porque el reloj relajado bayesiano da una distribución por nodo en vez de un punto.

6.8 Cómo se comprobó que el muestreador es correcto

Un muestreador MCMC es difícil de validar: no hay un número de referencia contra el que comparar, porque el resultado es una distribución. Este bloque se comprobó de tres maneras distintas, y las tres están en la carpeta de validación.

1 · Apagar la verosimilitud

Si se desconecta la verosimilitud, el muestreador **debe reproducir exactamente su propio prior**, porque ya no hay datos que lo desvíen. Es la prueba más severa que se le puede hacer, y la pasa. En la corrida registrada — 400 000 generaciones; el banco es estocástico, así que otra corrida da los últimos decimales distintos—:

- Las **tres topologías** sin raíz de cuatro taxones salen a 0.3374, 0.3335 y 0.3292, contra 1/3 esperado.
- Con seis taxones se visitan **las 105** topologías posibles, con frecuencia media 0.00952, contra $1/105 = 0.00952$.
- Las longitudes de rama dan media 0.10060 contra la exponencial de media 0.1, y la longitud total del árbol 0.50302 contra los 0.5 de la $\text{Gamma}(5, 0.1)$ que le corresponde.

2 · Comparar los diagnósticos con *coda*

El HPD y el PSRF se calculan sobre una serie que R y el navegador construyen igual, y salen **idénticos** a los de **coda**, que es la implementación de referencia.

3 · Auditar la cadena movimiento a movimiento

Una auditoría compara la verosimilitud que la cadena lleva apuntada —calculada de forma incremental, por velocidad— con un cálculo desde cero, en cada movimiento. El desajuste es **cero** en todos.

! UN HALLAZGO QUE SÓLO EL MUESTREADOR PODÍA DESTAPAR

Durante esas pruebas la cadena daba verosimilitudes **treinta unidades por encima** del supuesto máximo del Bloque 5. No era un error: la cadena **estima las frecuencias de base**, mientras que el ajuste de máxima verosimilitud las mantenía fijas en las empíricas. De ahí salió la casilla +F del Bloque 5, que ahora permite estimarlas también allí.

6.9 Errores frecuentes

✗ MIRAR EL ÁRBOL ANTES QUE LOS DIAGNÓSTICOS

El panel los pone en ese orden a propósito. Con ESS por debajo de 200, PSRF por encima de 1.01 o ASDSF por encima de 0.01, el árbol no se mira: se alarga la corrida.

✗ CORRER UNA SOLA CADENA

Sin al menos dos corridas independientes no hay PSRF ni ASDSF, y por tanto no hay forma de saber si convergió. Una sola cadena con una traza preciosa puede llevar un millón de generaciones atascada.

✗ REPORTAR UNA POSTERIOR COMO SI FUERA UN BOOTSTRAP

«Apoyo del 95 %» sin decir de qué medida es, invita a que el lector lo lea en la escala equivocada. Se escribe «probabilidad posterior de 0.95», y si también hay bootstrap, se dan los dos por separado.

✗ DEJAR LA PREVIA DE LAS RAMAS POR OMISIÓN SIN MIRARLA

Con datos divergentes, la exponencial de media 0.1 puede reducir a la mitad la longitud del árbol. El panel compara la previa con lo que midió el Bloque 5 y avisa **antes** de correr: ese aviso hay que leerlo.

✗ DESCARTAR EL 25 % POR COSTUMBRE

Descartar un cuarto de las generaciones es la convención, pero **mirar la traza es mejor que la convención**. A veces la quema acaba en el 2 % y se están tirando datos buenos; a veces no ha acabado en el 50 %.

7

CAPÍTULO SIETE · BLOQUE 7

El reloj molecular y los tiempos

Un filograma mide cambio; un cronograma mide tiempo. Pasar de uno al otro necesita tres cosas que los datos moleculares **no** contienen: una raíz, un modelo de cómo varía la velocidad, y al menos una calibración externa. Este capítulo recorre esos tres pasos en orden, explica el asistente que revisa las calibraciones antes de usarlas, y termina insistiendo en lo único que nunca debe faltar en una fecha publicada: su intervalo.

7

7.1 Lo que el reloj no puede darte solo

7.3 ¿Se sostiene el reloj?

7.5 El asistente de calibración

7.7 Leer el cronograma

7.9 Errores frecuentes

7.2 La raíz

7.4 Las calibraciones

7.6 Los tres métodos de datación

7.8 Qué tan bien lo hace, medido

7.1 Lo que el reloj no puede darte solo

Las ramas del árbol que produjeron los bloques 5 y 6 están medidas en **sustituciones por sitio**. No en años. Una rama de 0.08 puede ser un millón de años de evolución rápida o cincuenta de evolución lenta, y las secuencias, por sí solas, **no distinguen** esos dos casos.

LA CONFUSIÓN ENTRE TASA Y TIEMPO

Lo que una rama mide es **tasa × tiempo**. Con un solo número observado y dos incógnitas, hace falta información de fuera para separarlas. Ésa es toda la dificultad de la datación molecular, y explica por qué una fecha depende más de sus calibraciones que de cualquier refinamiento estadístico.

El bloque pide, por eso, tres cosas en este orden: **raíz**, porque sin ella no hay dirección ni edades; una respuesta a **¿se sostiene el reloj?**, que decide qué método usar; y al menos una **calibración**, sin la cual las edades salen en proporciones de la profundidad del árbol y no en años.

7.2 La raíz

Un árbol sin raíz no tiene dirección y por tanto no tiene edades. El menú **enraizar por** ofrece cuatro caminos:

Tabla 7.1. Las cuatro formas de poner la raíz.

Método	Cuándo y con qué cuidado
grupo externo	La forma honesta cuando se tiene uno. Es una hipótesis, y se puede equivocar: un grupo externo demasiado lejano introduce una rama larga y puede atraer al taxón más divergente del grupo interno.
punto medio	Pone la raíz en el centro del camino más largo. Cómodo, pero supone reloj — justo lo que se va a poner a prueba. Úsalo para explorar, no para publicar.
fechas de las puntas	Cuando las puntas tienen fechas distintas —virus, ADN antiguo, fósiles datados—, los propios datos dicen dónde va la raíz. Se escribe una fecha por taxón, una por línea.
dejarlo como está	Si el árbol ya venía enraizado de otro bloque o de un archivo.

La regresión raíz–punta

Con fechas en las puntas, el programa dibuja la distancia desde la raíz hasta cada punta contra su fecha. Si hay reloj, las dos suben juntas en línea recta y **la pendiente es la tasa**. El r^2 dice cuánta de la variación explica el tiempo.

! EL R^2 DE ESTA REGRESIÓN ES OPTIMISTA

Las distancias raíz–punta de dos taxones hermanos **no son independientes**: comparten casi todo el camino. Por eso el r^2 sale más alto de lo que corresponde y **no debe usarse como una prueba formal** de reloj. Sirve para mirar, para detectar puntas raras y para estimar una tasa aproximada.

7.3 ¿Se sostiene el reloj?

La prueba compara dos ajustes del **mismo árbol**: uno con las ramas libres, una longitud por rama, y otro forzado a ser **ultramétrico**, donde todas las puntas quedan a la misma altura. La diferencia de log-verosimilitud, multiplicada por dos, se contrasta contra una χ^2 con $n-2$ grados de libertad.

Un valor p pequeño rechaza el reloj estricto y manda usar un reloj relajado.

✗ LEER «NO RECHAZADO» COMO «HAY RELOJ»

No lo demuestra. La prueba tiene **poca potencia con pocos taxones**: con doce especies no rechaza casi nada. Y al revés, con muchos sitios rechaza casi siempre, porque detecta desviaciones diminutas y sin importancia práctica. El panel lo dice con esas palabras cuando el resultado no es significativo.

7.4 Las calibraciones

Sin al menos una, las edades no existen: las sustituciones por sitio y los millones de años son dos escalas distintas y nada las une. El programa acepta cuatro fuentes de años y cuatro formas de prior.

Tabla 7.2. Las cuatro formas de prior y lo que afirman.

Forma	Qué dice del nodo
edad fija	Tiene exactamente esta edad, sin incertidumbre. Casi nunca es cierto en biología.
intervalo uniforme	Está entre estas dos edades, sin preferir ningún punto. La forma de un acontecimiento geológico.
lognormal desplazada	No es más joven que el desplazamiento, con una cola larga hacia atrás. La forma de un fósil.
exponencial desplazada	Igual, con la masa más concentrada cerca del desplazamiento.

! UN FÓSIL DA LA EDAD MÍNIMA, NO LA EDAD

Es la idea que hay que llevarse de este capítulo. Cuando ese individuo murió, el linaje **ya existía**, y pudo existir mucho antes: lo que el fósil demuestra es que el nodo no es más joven que él. Por eso se usan priors asimétricos y desplazados, que permiten que el nodo sea mucho más viejo pero no más joven. Poner la edad del fósil como **edad fija** afirma que el linaje nació justo cuando ese individuo murió, y comprime todo el árbol hacia el presente.

Para seleccionar el nodo se eligen los **taxones del clado** —ninguno significa la raíz—. Si esos taxones no forman un clado en el árbol, el programa lo dice en vez de calibrar algo distinto de lo que se pidió.

7.5 El asistente de calibración

Sobre los controles de la calibración hay un asistente cuyo propósito es que nadie tenga que adivinar qué significan M y S. **No decide nada**: dice lo que acabas de escribir.

Propone la forma según de dónde viene la edad

Se elige en **la edad viene de** y el programa explica por qué esa procedencia pide esa forma:

Tabla 7.3. Lo que el asistente propone según la procedencia.

La edad viene de	Propone	Porque
Un fósil asignado al clado	lognormal desplazada	Es una cota mínima, no un punto.
Un acontecimiento geológico	intervalo uniforme	Es una ventana con principio y fin.
Una edad tomada de otro estudio	normal	Arrastra la incertidumbre de aquel trabajo, y conviene ensancharla , no estrecharla.
Una edad conocida con certeza	edad fija	Sólo para fijar una escala de referencia.

Dice, en años, lo que el prior afirma

Ésta es la parte más útil. «Lognormal desplazada, M = 1.6, S = 0.7, desplazamiento 20» no le dice nada a casi nadie; bajo los controles aparece la traducción, recalculada con cada tecla:



LO QUE SE LEE EN PANTALLA

*Este prior dice que la edad del nodo está, con 95 % de probabilidad, entre **21.3** y **39.7 Ma**, con mediana **25.0 Ma**, y no puede ser más joven que 20 Ma.*

Y avisa de los errores que arruinan una datación

- Un **fósil puesto como edad fija**, o con un prior normal simétrico, que permitiría un nodo más joven que el fósil.
- Un **desplazamiento en cero**, que no impone ninguna edad mínima: permite que el nodo sea de ayer.
- Una **normal cuya cola inferior llega al futuro**, es decir a edades negativas.
- Un prior **tan ancho que apenas informa**, o tan estrecho que finge una certeza que nadie tiene.
- La confusión de **corona y tallo**: los taxones que seleccionas calibran el nodo de corona —el ancestro común más reciente del grupo—. Si tu fósil es **hermano** del grupo y no un miembro suyo, lo que calibra es el **tallo**, que es más viejo, y para eso hay que seleccionar también al grupo hermano.
- Que ésta vaya a ser la **única** calibración, y por tanto que toda la escala del árbol dependa de ella.

! POR QUÉ NO HAY UNA BASE DE FÓSILES

Y no la habrá. Asignar un fósil a un nodo es un juicio taxonómico sobre los caracteres de ese fósil y sobre de qué clado es hermano: es la parte que se discute en los artículos y la que un revisor examina. Una tabla de consulta invitaría a publicar una fecha que nadie miró. El programa ayuda con todo lo que rodea a ese juicio; el juicio es tuyo.

7.6 Los tres métodos de datación

Tres caminos, del más rápido al más honesto con la incertidumbre.

Mínimos cuadrados

Ajusta las edades minimizando una función de mínimos cuadrados sobre las longitudes de rama (To et al. 2016). Da una estimación puntual en segundos, incluso con quinientos taxones. Es lo que se usa para ver el orden de magnitud, o cuando el árbol es demasiado grande para lo demás.

Verosimilitud penalizada

Permite que la tasa cambie entre ramas pero **penaliza** los cambios bruscos (Sanderson 2002). El parámetro **suavizado λ** controla cuánto: λ grande se acerca a un reloj estricto, λ pequeña deja que cada rama tenga su tasa.

! A NO SE ELIGE A OJO

Se elige por **validación cruzada**, quitando una rama a la vez y viendo qué λ predice mejor. El botón **elegirlo por validación cruzada** hace justo eso y dibuja la curva. Si el mínimo de esa curva cae en un extremo del rango probado, el rango era demasiado estrecho y hay que ampliarlo.

Reloj relajado bayesiano

Un reloj lognormal no correlacionado (Drummond et al. 2006): cada rama toma su tasa de una lognormal, de forma independiente de su vecina. Es el más lento y el único que devuelve una **distribución por nodo** en vez de un punto, que es lo que se debería publicar cuando las calibraciones son inciertas — es decir, casi siempre.

7.7 Leer el cronograma

Los mosaicos resumen: la **edad de la raíz**, el **método**, el **tiempo** de cómputo, la **tasa media** en sustituciones por sitio y por unidad de tiempo, y la **variación de la tasa**, un coeficiente de variación que dice cuánto se aparta el árbol de un reloj estricto: cerca de 0, prácticamente había reloj; por encima de 0.5, las tasas son muy desiguales y un reloj estricto habría dado fechas equivocadas.

El cronograma se dibuja sobre la **escala de tiempo geológico** —las franjas de la Carta Cronoestratigráfica Internacional— con barras de incertidumbre por nodo.

✗ PUBLICAR UNA EDAD SIN SU INTERVALO

Un nodo fechado en 30 Ma con un intervalo de 28 a 32 está bien determinado; el mismo 30 Ma con un intervalo de 8 a 70 no dice casi nada, aunque la media se vea igual de redonda. **Una edad sin intervalo no es un resultado.** Y el intervalo sólo recoge la incertidumbre *dentro* del modelo y de las calibraciones que diste: no incluye el error de haber elegido mal una calibración, que suele ser el mayor de todos.

Sin ninguna calibración, el panel fija la raíz en 1 y avisa de que las edades son **proporciones de la profundidad del árbol**, no años: sirven para comparar nodos entre sí, no para escribir «hace X millones de años».

7.8 Qué tan bien lo hace, medido

Comprobado contra *ape* y *phangorn*, con los resultados en la carpeta de validación:

- El enraizado por fechas de las puntas reproduce `ape : rtt` : pendiente -0.00158106 contra -0.00158106 , con una diferencia de $3 \cdot 10^{-9}$, y r^2 0.783919 contra 0.783919.
- La verosimilitud penalizada coincide con `ape : chronos` : sobre 15 clados, la diferencia máxima de edad es 0.0382 con la raíz en 1, y la correlación entre las dos series de edades es $r^2 = 0.9906$.
- En la prueba del reloj, el ajuste ultramétrico propio es mejor que el de `optim.pml(optRooted = TRUE)` por **11.8 unidades** de log-verosimilitud sobre el mismo árbol enraizado, y ambos rechazan el reloj.

1 UN ERROR QUE LA VALIDACIÓN DESTAPÓ

La búsqueda del enraizado filtraba por el **signo** de la pendiente, suponiendo que la distancia raíz–punta crece con la fecha. Crece con fechas de calendario y **decrece** con edades hacia atrás, así que el filtro descartaba todos los enraizados correctos: daba r^2 de 0.006 donde *ape* llega a 0.784. Ahora el signo sólo indica qué convención siguen las fechas, y la tasa es el valor absoluto de la pendiente.

7.9 Errores frecuentes

✗ USAR EL PUNTO MEDIO Y LUEGO PROBAR EL RELOJ

El enraizado por punto medio **supone** reloj. Probar el reloj sobre un árbol enraizado así es preguntarle al método lo que el método ya dio por hecho. Con grupo externo, la prueba es legítima.

✗ UNA SOLA CALIBRACIÓN

Toda la escala del árbol cuelga de ella y su error se propaga a cada nodo sin nada que lo contrapesa. Dos o tres calibraciones repartidas son mucho mejores que una, por buena que sea, porque además se contrastan entre sí.

✗ CALIBRAR CON UNA EDAD SECUNDARIA SIN ENSANCHAR SU INCERTIDUMBRE

Una edad tomada de otro estudio arrastra el árbol, el modelo y las calibraciones de aquel trabajo. Copiar su intervalo tal cual finge que esa incertidumbre no existe. El asistente propone una desviación del 12 % y recomienda ampliarla, no reducirla.

✗ CONFUNDIR LA EDAD DE CORONA CON LA DE TALLO

La corona es el ancestro común más reciente de las especies vivas del grupo; el tallo, su divergencia respecto del grupo hermano, y siempre es más viejo. Las tasas de diversificación del Bloque 8 se calculan con una u otra y **dan resultados distintos**. Hay que decir cuál se usó.

✗ REPORTAR LA TASA DE OTRO ESTUDIO COMO SI FUERA UN DATO

Una tasa publicada para «el mismo marcador» se estimó en otro grupo, con otro muestreo y otras calibraciones. Es la fuente de error más grande de una datación y la que menos se reporta.

8

CAPÍTULO OCHO · BLOQUE 8

Diversificación

Un cronograma no sólo dice cuándo: la forma en que se reparten sus tiempos de ramificación dice a qué ritmo se diversificó el grupo, y si ese ritmo cambió. Este capítulo explica la curva de linajes, el estadístico γ y la trampa que lo acompaña —**faltar especies imita exactamente una desaceleración**—, los cinco modelos que se comparan, los estimadores que funcionan con una sola edad y una riqueza, y por qué las tasas de extinción de un árbol de especies vivas no son de fiar.

8.1 Qué se lee en los tiempos de ramificación

8.3 La trampa del muestreo incompleto

8.5 λ , μ , r y ϵ : qué se puede creer

8.7 Una tasa para cada especie: el DR

8.9 Errores frecuentes

8.2 Linajes en el tiempo y el estadístico γ

8.4 Los cinco modelos

8.6 Cuando sólo hay una edad y una riqueza

8.8 Qué tan bien lo hace, medido

8.1 Qué se lee en los tiempos de ramificación

Todo este bloque se lee sobre los **tiempos de ramificación** del cronograma, así que hace falta haber pasado por el Bloque 7. Sin fechas no hay nada que analizar: las longitudes en sustituciones no dicen a qué ritmo apareció la diversidad.

La pregunta que se responde es una sola, con muchas formas: ¿el grupo se diversificó siempre al mismo ritmo, o hubo una explosión inicial que se frenó, o una aceleración reciente? Y detrás de ella, la incómoda: ¿cuánta extinción hubo, y se puede saber?

! EL ÁRBOL QUE SE ANALIZA ES EL DE LOS SUPERVIVIENTES

Un cronograma de especies vivas es un **árbol reconstruido**: los linajes que se extinguieron no dejaron puntas y no están. De esa amputación viene casi toda la dificultad del bloque, y explica por qué la diversificación neta se estima bien y la extinción, mal.

8.2 Linajes en el tiempo y el estadístico γ

La curva de **linajes en el tiempo** cuenta cuántos linajes existían en cada momento del pasado. Dibujada en **escala logarítmica**, una tasa constante da una **recta**: ésa es la referencia contra la que se mira todo lo demás.

- Si la curva **se dobla hacia abajo** cerca del presente, los nodos se acumularon temprano: el grupo se diversificó pronto y luego se frenó.
- Si se dobla hacia arriba, ocurrió lo contrario.

El estadístico γ de Pybus y Harvey (2000) pone un número a eso. Compara dónde caen los nodos respecto de dónde caerían con tasa constante. Bajo tasa constante γ se distribuye normal estándar, de modo que:

Σ CÓMO SE LEE γ

$\gamma < -1.645$ rechaza la tasa constante a favor de una **desaceleración**, con una cola, al 5 %.

Entre -1.645 y 1.645 , compatible con tasa constante.

Por encima de 1.645 , aceleración hacia el presente.

Si hay varios árboles —de un bootstrap o de un posterior—, el panel dibuja además una **banda** sobre la muestra, que es mucho más informativa que la curva de un solo árbol.

8.3 La trampa del muestreo incompleto

Ésta es la sección que salva artículos.

**FALTAR ESPECIES IMITA EXACTAMENTE UNA DESACELERACIÓN**

Cuando no se muestrea todo el grupo, las especies que faltan son sobre todo **de los nodos recientes**, porque los clados jóvenes tienen pocas especies y basta perder una para borrar un nodo. El resultado es una curva que se aplana cerca del presente — indistinguible de una desaceleración real. Con un muestreo del 60 %, γ saldrá negativo aunque la tasa haya sido perfectamente constante.

Por eso existe la **prueba MCCR** (Monte Carlo constant rates). En vez de comparar γ contra la normal estándar, simula árboles de tasa constante **con el mismo muestreo incompleto que los datos**, mide su γ , y compara el γ observado contra esa distribución. El panel pide:

- **especies en el grupo (en total, no las del árbol)**: el número real de especies descritas, que es el dato que hay que buscar en la literatura.
- **réplicas**: cuántos árboles se simulan para construir la distribución nula.

El resultado es un **valor crítico al 5 %** que será **más negativo** que -1.645 , y cuánto más lo sea dice cuánta desaceleración explicaba el muestreo por sí solo. Si tu γ observado no cruza ese valor crítico, no hay desaceleración que reportar.

**DAR MAL EL NÚMERO TOTAL DE ESPECIES**

La prueba entera depende de esa cifra. Si pones las del árbol en vez de las del grupo, la prueba corrige de menos y volverás a «encontrar» la desaceleración falsa. Si exageras el total, corrige de más y perderás una desaceleración real.

8.4 Los cinco modelos

El botón **Ajustar los cinco modelos** compara sobre los mismos tiempos de ramificación:

Tabla 8.1. Los cinco modelos de diversificación.

Modelo	Qué supone
Nacimiento puro (Yule)	Una sola tasa de especiación y ninguna extinción .
Nacimiento—muerte	Especiación y extinción constantes, con la verosimilitud de Nee et al. para el árbol reconstruido.
Dependiente de la densidad, logístico	La tasa baja conforme se llenan los nichos, hacia una capacidad de carga (Rabosky & Lovette 2008).
Dependiente de la densidad, exponencial	Lo mismo, con un decaimiento exponencial en vez de logístico.
Dos tasas	La tasa cambia una vez, en un momento que se estima a partir de los datos.

Se comparan por AIC con pesos de Akaike, como en el Bloque 3: lo que se lee es la diferencia con el mejor y el peso del ganador, no el valor absoluto.

! EL MODELO DE DOS TASAS ESTIMA DÓNDE ESTÁ EL CAMBIO

Y por eso tiene una ventaja injusta: siempre encontrará el mejor sitio posible para poner el salto, incluso en datos generados con tasa constante. El AIC castiga el parámetro de más, pero no el hecho de haberlo buscado. Un peso alto de este modelo es una pista, no una demostración.

8.5 λ , μ , r y ε : qué se puede creer

El modelo de nacimiento–muerte estima cuatro cantidades relacionadas:

Tabla 8.2. Los cuatro parámetros, y cuánto se les puede creer.

Símbolo	Qué es	Fiabilidad
λ	Tasa de especiación	Razonable.
μ	Tasa de extinción	Muy poco fiable con árboles sólo de especies vivas.
$r = \lambda - \mu$	Diversificación neta	La que mejor se estima y la que conviene reportar.
$\varepsilon = \mu/\lambda$	Recambio	Se estima mal, y con frecuencia sale 0.

✦ UNA E ESTIMADA EN CERO NO SIGNIFICA QUE NO HUBO EXTINCIÓN

Significa que **el árbol de los supervivientes no puede verla**. Es el mismo problema que la e de la biogeografía en el capítulo 10: los linajes que desaparecieron no dejaron rastro en las puntas. Con fósiles, la estimación cambia por completo. Reportar r con confianza y ε con reservas es lo honesto.

El panel ofrece además el **tiempo de duplicación**, $\ln(2)/r$: cuánto tarda el grupo en duplicar su número de linajes a la tasa estimada. Es la misma información que r , dicha en unidades que se pueden imaginar — y comparada con la edad del grupo, dice enseguida si la tasa explica la diversidad actual.

8.6 Cuando sólo hay una edad y una riqueza

A veces no hay árbol del grupo: sólo se sabe su edad y cuántas especies tiene. Los estimadores de **Magallón y Sanderson (2001)** bastan con eso, y son los que se usan para comparar cientos de clados a la vez.

El panel pide el número de **especies**, la edad, y —crucial— si **la edad es de** la **corona** o del **tallo**.

✗ CONFUNDIR CORONA CON TALLO

La **corona** es el ancestro común más reciente de las especies vivas del grupo; el **tallo** es su divergencia respecto del grupo hermano, y siempre es más viejo. Con el tallo, la misma riqueza se reparte en más tiempo y **la tasa sale menor**. Los dos estimadores son distintos y el programa pide explícitamente cuál es. Una «edad del grupo» sin apellido, tomada de otro artículo, no se puede reutilizar.

El estimador necesita además un valor de ε supuesto, precisamente porque no se puede estimar: la costumbre es reportar el resultado con $\varepsilon = 0$ y con $\varepsilon = 0.9$, para enseñar cuánto depende del supuesto.

8.7 Una tasa para cada especie: el DR

Los modelos anteriores dan una tasa para todo el grupo. El estadístico **DR** (Jetz et al. 2012) reparte una tasa entre las **puntas**: para cada especie pesa las ramas del camino hasta la raíz, dando más peso a las recientes.

Se lee **en relativo**: qué puntas tienen DR alto frente a las demás **del mismo árbol**. Los valores absolutos dependen de la escala del árbol y no se comparan entre estudios.

! EL DR NO ES UNA TASA DE DIVERSIFICACIÓN POR ESPECIE

Aunque se use así muy a menudo. Se ha demostrado que estima mejor la **especiación** que la diversificación neta, y que se comporta mal cuando la extinción es alta (Title & Rabosky 2019). Como medida descriptiva para ordenar puntas es útil; como estimador de r , no.

8.8 Qué tan bien lo hace, medido

Comprobado contra *ape* y *geiger*, con los resultados en la carpeta de validación:

- El estadístico **γ** da **0.44734655**, idéntico al de `ape::gammaStat`.
- El modelo de **nacimiento puro** reproduce λ , su error estándar y su log-verosimilitud idénticos a `ape::yule`.
- El de **nacimiento–muerte** da 0.24684678 contra 0.24684645 de `ape::birthdeath`, y $r = 0.20638381$ contra 0.20638489, con la misma log-verosimilitud.
- Los estimadores de **Magallón y Sanderson** coinciden con `geiger::bd.ms` a 10^{-7} , y los tiempos de ramificación a $1.2 \cdot 10^{-9}$.

I UN ERROR QUE SÓLO SE VEÍA EN EL SESGO

El simulador de árboles, usado por la prueba MCCR, dejaba dentro los linajes extintos —con lo que salían más puntas de las pedidas y árboles no ultramétricos— y, peor, **paraba el reloj justo en la última especiación** en vez de sortear un presente. Eso último sesgaba γ : daba una media de **+0.32** sobre árboles de tasa constante, donde debería dar 0, y habría torcido toda prueba de Monte Carlo en la misma dirección. Con el presente sorteado bien, γ da media -0.066 y desviación 0.9999, contra los 0.073 y 0.952 de `ape::rphylo`.

8.9 Errores frecuentes

✗ REPORTAR UN Γ NEGATIVO SIN LA PRUEBA MCCR

Es el error más común del bloque y el más fácil de evitar. Si no muestreaste el 100 % del grupo, tu γ negativo puede ser enteramente artefacto del muestreo. La prueba MCCR está a dos clics.

✗ INTERPRETAR M O E COMO CANTIDADES BIOLÓGICAS

De un árbol de especies vivas, la tasa de extinción no se estima: se supone. Reporta r , di qué ε supusiste, y enseña cómo cambia el resultado con otro.

✗ COMPARAR DR ENTRE ESTUDIOS

Depende de la escala del árbol y del muestreo. Sirve para ordenar las puntas de **tu** árbol, no para decir que tu género diversifica más rápido que el del vecino.

✗ ANALIZAR UN CRONOGRAMA CUYAS FECHAS NO SE SOSTIENEN

Todo este bloque hereda la incertidumbre del Bloque 7. Si las edades tienen intervalos del ancho del árbol, γ y los cinco modelos están describiendo ruido. Antes de interpretar una desaceleración, mira los intervalos de las edades que la producen.

✗ CONTAR UNA DESACELERACIÓN COMO «RADIACIÓN ADAPTATIVA»

Una curva que se aplanas es compatible con la saturación de nichos, pero también con muestreo incompleto, con extinción reciente y con un cronograma mal calibrado. El patrón no identifica el proceso, y el bloque mide el patrón.

9

CAPÍTULO NUEVE · BLOQUE 9

Evolución de caracteres

Dos especies hermanas no son dos observaciones independientes: comparten casi toda su historia. Todo este bloque sale de esa frase. Ajusta tres modelos de evolución continua, mide la señal filogenética de dos maneras que no preguntan lo mismo, compara una regresión ordinaria con la que corrige el parentesco, y reconstruye estados ancestrales discretos con sus pasteles y con historias completas sorteadas sobre el árbol.

9.1 Por qué las especies no son datos independientes

9.3 Tres modelos para un carácter continuo

9.5 Dos caracteres, una relación

9.7 Estados ancestrales y mapeo estocástico

9.9 Errores frecuentes

9.2 La tabla de caracteres

9.4 Cuánta señal filogenética hay

9.6 Un carácter discreto: el modelo Mk

9.8 Qué tan bien lo hace, medido

9.1 Por qué las especies no son datos independientes

Supón que mides el tamaño de la semilla en cuarenta especies y lo relacionas con la altura de la planta. Una regresión ordinaria trata esas cuarenta especies como cuarenta observaciones independientes. No lo son: si treinta pertenecen al mismo género y heredaron de su ancestro común tanto la semilla grande como la altura, lo que tienes no son treinta datos sino, en el fondo, **uno** repetido treinta veces.

✦ LA CONSECUENCIA PRÁCTICA

Ignorar el parentesco **infla la significancia**: los valores *p* salen mucho más pequeños de lo que corresponde, y se publican relaciones que no resisten. Los métodos de este bloque no son un refinamiento estadístico: son la corrección de un error de conteo.

Se trabaja sobre un árbol, preferiblemente el **fechado** del Bloque 7, porque los modelos hablan de tasas por unidad de tiempo.

9.2 La tabla de caracteres

Una fila por especie y una columna por carácter, separadas por comas, punto y coma o tabuladores. El programa deduce el tipo de cada columna —continua o discreta—, reconoce los datos ausentes y empareja los nombres con el árbol **perdonando la diferencia entre** `Bursera_palmeri` y `Bursera palmeri`, que es la que más tiempo hace perder.

Lo que no cuadra se **lista**, no se traga en silencio. Y cada análisis **poda el árbol** a las puntas que tienen el carácter que necesita, y dice con cuántas se quedó.

9.3 Tres modelos para un carácter continuo

Tabla 9.1. Los tres modelos, en la parametrización de *geiger*.

Modelo	Qué proceso describe
Movimiento browniano (BM)	Deriva pura: el carácter se aleja al azar, y la varianza entre dos especies crece con el tiempo que llevan separadas. Un solo parámetro, σ^2 .
Ornstein–Uhlenbeck (OU)	Una fuerza, α , que jala el carácter hacia un óptimo. Es el modelo de la selección estabilizadora.
Estallido temprano (EB)	La tasa decae con el tiempo: mucho cambio al principio y poco después. Es el modelo de la radiación adaptativa.

Se comparan por AIC con pesos de Akaike, y el panel escribe el veredicto en palabras.

La vida media, en vez de α

El parámetro α del OU no se interpreta bien a ojo. El programa reporta la **vida media**, $\ln(2)/\alpha$: el tiempo que tarda el carácter en recorrer la mitad del camino hacia su óptimo. Y se lee **comparándola con la profundidad del árbol**:

- Vida media mucho menor que la profundidad: selección estabilizadora fuerte, y el árbol casi no importa para predecir el valor de una especie.
- Vida media mayor que la profundidad: el OU es **indistinguible** de un browniano, y su α no significa nada.

! DOS ADVERTENCIAS SOBRE EL OU

Primera: el OU y el estallido temprano **suponen puntas contemporáneas**. Sobre un filograma no ultramétrico sus parámetros no significan lo que dicen, y el bloque mide la dispersión de las alturas de las puntas y avisa.

Segunda: con menos de cincuenta especies el OU se prefiere a menudo por razones **estadísticas y no biológicas**. Es un modelo muy hábil para ajustar ruido, y ganar por AIC no es lo mismo que describir un proceso real (Cooper et al. 2016).

Cuando α toca el límite del rango explorado, la ficha no imprime un número: escribe «—» y dice que α quedó en el límite, porque un número ahí sería una invención.

El traitgram

La figura que pone el carácter y el árbol **en el mismo plano**: el tiempo en un eje, el valor del carácter en el otro, y las ramas del árbol dibujadas entre los valores reconstruidos. Es la mejor forma de ver de un vistazo si hubo convergencia, y las etiquetas de las puntas se reparten para no encimarse.

9.4 Cuánta señal filogenética hay

«Señal filogenética» es cuánto se parecen los parientes más de lo que cabría esperar por azar. Las dos medidas usuales **no preguntan lo mismo**, y por eso pueden parecer contradictorias sin serlo.

Tabla 9.2. Las dos medidas de señal filogenética.

Medida	Qué manipula	Cómo se lee
λ de Pagel	La forma del árbol: multiplica las covarianzas entre especies sin tocar las varianzas.	$\lambda = 1$ es browniano puro; $\lambda = 0$, un carácter repartido como si la filogenia no existiera. Se prueba contra 0 y contra 1 con una razón de verosimilitudes.
K de Blomberg	La magnitud de la varianza: compara la observada con la que el browniano predice sobre ese árbol.	$K = 1$ es exactamente browniano; $K > 1$, los parientes se parecen más de lo que el browniano espera. Va con una prueba de permutación.

! $K < 1$ CON $\lambda \approx 1$ NO ES UNA CONTRADICCIÓN

Son preguntas distintas sobre los mismos datos: λ mira la **forma** del árbol y K la **magnitud** de la varianza. Un carácter puede repartirse exactamente como el árbol predice — $\lambda = 1$ — y a la vez variar menos entre especies de lo que el browniano esperaba — $K < 1$ —. El panel lo explica cuando ocurre, porque es una de las lecturas que más desconcierta.

La gráfica de **K bajo la hipótesis nula** dibuja la distribución de K cuando los valores se barajan entre especies, y sitúa el observado sobre ella. Sin ese dibujo, un K de 0.8 no dice si es mucho o poco.

! SEÑAL ES PATRÓN, NO PROCESO

$\lambda = 1$ **no demuestra** deriva neutra, y un λ bajo puede deberse a error de medición y no a la biología. Con menos de veinte especies, además, ambas medidas se estiman con muy poca precisión.

9.5 Dos caracteres, una relación

El panel ajusta **tres** regresiones sobre los mismos dos caracteres y las pone lado a lado:

- 1 La **ordinaria**, que cuenta cada especie como un dato nuevo.
- 2 Los **contrastes independientes** de Felsenstein: convierten los valores de n especies en $n-1$ diferencias entre nodos hermanos, cada una escalada por sus longitudes de rama. Esas diferencias **sí** son independientes, y su regresión se ajusta **forzada por el origen**, porque el signo de un contraste es arbitrario y una ordenada al origen no significaría nada.
- 3 **PGLS**, que resuelve lo mismo por otro camino: una regresión generalizada cuya matriz de covarianzas es la del árbol.

Σ LA IDENTIDAD DE GARLAND E IVES

Los contrastes y el PGLS **no son dos aproximaciones parecidas**: bajo movimiento browniano dan **exactamente la misma pendiente**. El programa lo comprueba en la propia interfaz y lo muestra: la pendiente de los contrastes por el origen y la del PGLS con $\lambda = 1$ tienen que ser el mismo número. Cuando no lo son, algo está mal, y es una comprobación que conviene mirar.

Comparar el valor p de la regresión ordinaria con el del PGLS enseña, en un solo vistazo, cuánto se estaba exagerando la significancia.

✗ CREER QUE PGLS ARREGLA OTRAS COSAS

Corrige la **no independencia**. No corrige la causalidad, ni una variable omitida, ni un error de medición. Y si la señal filogenética del residuo resulta nula, PGLS y mínimos cuadrados dan lo mismo: la corrección no siempre cambia la conclusión, y eso también es un resultado.

9.6 Un carácter discreto: el modelo Mk

El modelo Mk de Lewis (2001) trata los estados de un carácter como el modelo de sustitución trata los nucleótidos: una matriz de tasas de paso entre estados. Tres variantes:

- **ER**: una sola tasa para todos los cambios.
- **SYM**: la tasa de i a j igual que la de j a i .
- **ARD**: todas distintas. Con k estados son $k(k-1)$ parámetros: con cuatro estados, doce.

Se comparan por AIC. Con pocas especies casi siempre gana ER, y no porque la biología sea simple: porque no hay datos para estimar más.

✗ NO MIRAR SI LA TASA SE DISPARÓ

Una tasa que se va a infinito es el síntoma de un carácter **saturado**: ha cambiado tantas veces que el árbol ya no guarda memoria de su historia. Los nodos salen todos al 0.5 y la reconstrucción no dice nada. Eso no es un fallo del programa: es el dato diciendo que no sabe.

ℹ UN CONVENIO QUE CONVIENE CONOCER

La log-verosimilitud que reporta `ape::ace` es la de `phytools::fitMk` más $\log(k)$, y toda la diferencia es el prior plano en la raíz. No es que uno esté mal: son dos convenios. El programa informa las dos, para que se pueda comparar con cualquiera de los dos paquetes sin sobresaltos.

9.7 Estados ancestrales y mapeo estocástico

Los pasteles

Cada nodo interno lleva un pastel con la probabilidad de cada estado. La versión que se reporta es la **marginal**, que integra sobre todo lo demás del árbol. Un pastel casi de un solo color es una reconstrucción firme; uno repartido significa que **los datos no saben**, y ese reparto **es el resultado**, no un defecto del dibujo.

El programa dibuja los pasteles a propósito, en vez de escribir el estado ganador: así un nodo al 55 % **se ve** como lo que es. La incertidumbre crece hacia la raíz, que suele ser justo el nodo que interesa.

El mapeo estocástico

En vez de dar una probabilidad por nodo, sortea **historias completas** del carácter sobre el árbol —dónde y cuándo ocurrió cada cambio— coherentes con las puntas y con el modelo (Huelsenbeck et al. 2003). Quinientas historias en menos de un segundo.

Lo que se reporta es el **promedio sobre las historias**: el número esperado de cambios, cuánto tiempo pasó el árbol en cada estado, y con qué frecuencia cada rama contiene un cambio. Eso es bastante más informativo que un solo estado por nodo: convierte «el ancestro probablemente era amarillo» en «el linaje pasó el 70 % de su historia en amarillo y hubo unos cuatro cambios».

! LAS HISTORIAS SON TAN BUENAS COMO EL MK QUE LAS GENERA

Si las tasas están mal estimadas, **todas** las historias lo estarán en la misma dirección, y el promedio no lo revela. La dispersión entre historias mide la incertidumbre *dentro* del modelo, no la del modelo.

9.8 Qué tan bien lo hace, medido

Este bloque es el que más implementaciones de referencia tiene enfrente, y se comprobó contra las cuatro: **geiger**, **ape**, **nlme** y **phytools**, con **42 comprobaciones** y ningún desacuerdo.

- Los **contrastes independientes** reproducen `ape::pic`.
- El **PGLS** es idéntico a `nlme::gls` en pendiente, error estándar, t y p.
- Su pendiente coincide con la de los contrastes por el origen, tal como exige la **identidad de Garland e Ives**.
- Los **estados marginales** coinciden con `ape::ace` y con `phytools::ancr`, que a su vez concuerdan entre sí.
- Los tres modelos continuos reproducen la parametrización de `geiger::fitContinuous`.

I TRES ERRORES QUE LA VALIDACIÓN DESTAPÓ

El **estallido temprano perdía todas sus cifras** cuando el parámetro era pequeño: la expresión $(e^{a \cdot s} - 1)/a$ se calculaba tal cual, y para $|a|$ diminuta eso es restar dos números casi iguales. Se sustituyó por la función que existe justo para eso.

La **función de distribución t salía simétrica respecto de cero**, porque la beta incompleta sólo ve t^2 . Los valores p eran correctos de milagro, porque siempre se la llamaba con $|t|$.

La **α del OU estaba acotada entre números fijos** en vez de relativos a la profundidad del árbol, y llegó a informar una vida media de **691 179 sustituciones** en un árbol de 0.08 de profundidad. Ahora el límite es relativo, y si α lo toca, la ficha lo dice en vez de imprimir la cifra.

9.9 Errores frecuentes

✗ PUBLICAR UNA REGRESIÓN ORDINARIA ENTRE ESPECIES

Sigue apareciendo en revistas. Si los datos son especies y hay una filogenia disponible, la regresión ordinaria cuenta mal y su valor p es demasiado pequeño. El panel enseña las tres regresiones juntas precisamente para que la diferencia se vea.

✗ AJUSTAR OU SOBRE UN ÁRBOL NO ULTRAMÉTRICO

El OU y el estallido temprano suponen que todas las puntas son contemporáneas. Sobre un filograma, sus parámetros no significan lo que dicen. El bloque avisa; hay que leer el aviso.

✗ CONCLUIR «SELECCIÓN ESTABILIZADORA» PORQUE GANÓ EL OU

Con pocas especies el OU gana con frecuencia por razones estadísticas. Mira la **vida media** frente a la profundidad del árbol: si es mayor, el OU es indistinguible de un browniano y no hay nada que concluir.

✗ REPORTAR EL ESTADO ANCESTRAL GANADOR SIN SU PROBABILIDAD

«El ancestro era amarillo» es muy distinto de «el ancestro era amarillo con probabilidad 0.55». Los pasteles están dibujados para que esa diferencia no se pueda esconder, y la figura completa es lo que se publica.

✗ OLVIDAR QUE EL ÁRBOL SE PODÓ

Cada análisis usa sólo las puntas que tienen el carácter que necesita. Si de ochenta especies sólo cuarenta tienen medida la semilla, tu λ se estimó sobre cuarenta. El panel lo dice; conviene reportarlo también.

10

CAPÍTULO DIEZ · BLOQUE 10

Biogeografía histórica

Un rango geográfico también es un carácter, pero con una diferencia que lo cambia todo: cuando un linaje se divide, el rango **se reparte** entre las dos hijas, y cómo se reparte es justamente lo que separa a unos modelos de otros. Este bloque ajusta seis, reconstruye dónde estuvo cada linaje —incluidas las esquinas que casi nadie dibuja— y convierte las probabilidades en cuentas de dispersiones, extinciones y divisiones.

10.1 El carácter que se parte en dos

10.3 Cuántos rangos puede tener un linaje

10.5 Por qué +J casi siempre gana

10.7 Cuántas veces pasó cada cosa

10.9 Errores frecuentes

10.2 Las áreas y quién vive en cuáles

10.4 Los seis modelos

10.6 Dónde estuvo cada linaje, y las esquinas

10.8 Qué tan bien lo hace, medido

10.1 El carácter que se parte en dos

En el Bloque 9 un carácter discreto cambia a lo largo de una rama y, al llegar a un nodo, las dos hijas heredan lo mismo que tenía el padre. Un rango geográfico no se comporta así. Si el ancestro vivía en las islas A, B y C, y el linaje se divide, lo normal **no** es que las dos hijas hereden las tres islas: lo normal es que una se quede con A y la otra con BC, o que una se quede con todo y la otra con una sola.

Eso obliga a dos cosas a la vez. Primero, los **estados** del modelo no son las áreas, sino los **subconjuntos** de áreas. Segundo, hace falta describir dos procesos distintos: qué le pasa al rango **a lo largo de una rama** y qué le pasa **en el nodo**.

Tabla 10.1. Los dos procesos y sus parámetros.

Cuándo	Qué pasa
A lo largo de una rama (anagénesis)	Con tasa d , el rango gana un área: dispersión. Con tasa e , la pierde : extinción local. Un rango de una sola área que la pierde desaparece , y por eso el rango nulo es un estado y es absorbente.
En el nodo (cladogénesis)	El rango ancestral se reparte entre las dos hijas. Qué repartos están permitidos es lo único que distingue a los tres modelos base.

! PRIMERO NECESITAS UN ÁRBOL, Y CONVIENE QUE ESTÉ FECHADO

Las tasas de dispersión y de extinción se estiman **por unidad de tiempo**. Sobre un filograma medido en sustituciones no significan lo que dicen. El panel te manda al Bloque 7 si aún no tienes cronograma, y con razón: una d de 0.035 sólo quiere decir algo si el eje del árbol son millones de años.

10.2 Las áreas y quién vive en cuáles

El programa lee el **formato de LAGRANGE**, que es el mismo que usa BioGeoBEARS: una línea de encabezado con el número de taxones, el de áreas y sus nombres entre paréntesis, y luego una fila por especie con ceros y unos.

También acepta una **tabla separada por comas** con una columna por área, que es más cómoda de armar en una hoja de cálculo, y exporta en formato LAGRANGE por si quieres llevar los mismos datos a otro programa. El ejemplo incluido es de *Bursera*, y sirve para recorrer el bloque entero sin traer nada propio.

Los nombres tienen que casar con las puntas del árbol. El bloque dice con cuántas especies se quedó y cuáles no encontró, en vez de seguir adelante en silencio.

10.3 Cuántos rangos puede tener un linaje

Con n áreas hay 2^n subconjuntos. Con cinco áreas son 32 estados; con ocho, 256. La matriz de transición crece con el cuadrado de eso, y ahí es donde el análisis se vuelve imposible.

El remedio es el **tamaño máximo del rango**. Si ninguna especie viva ocupa más de tres áreas, limitar los estados a rangos de tres áreas o menos recorta el problema muchísimo.

! EL TOPE NO ES UN AJUSTE TÉCNICO: ES UN SUPUESTO

Un linaje que estuvo en cinco de seis áreas **no se puede reconstruir** si pusiste el tope en tres. Has decidido de antemano que eso no ocurrió. Con frecuencia es razonable —los rangos muy amplios son raros—, pero es una decisión biológica y hay que reportarla junto con los resultados.

El rango nulo

Viene activado. Es el estado al que llega un linaje que perdió su única área, y es **absorbente**: no se sale de él. Tenerlo es lo que permite que la extinción sea un proceso real dentro del modelo y no sólo una etiqueta.

Los multiplicadores de dispersión

La matriz de multiplicadores entre áreas es, de todo el bloque, lo que más se parece a hacer biogeografía de verdad. Cada casilla multiplica la tasa de dispersión *de* un área *a* otra: un 0 la prohíbe, un 0.1 la vuelve difícil, un 1 la deja como las demás. **Ahí entra un istmo que se cerró, un puente de tierra que se abrió o un océano que nunca se cruzó.** Se edita haciendo clic en la casilla, y hay un botón para fijar los dos sentidos a la vez y otro para devolverlo todo a uno.

I GEOGRAFÍA QUE CAMBIA CON EL TIEMPO

El motor sabe trabajar con **estratos temporales** —una rama que cruza un límite recibe el producto de las matrices de los periodos que atraviesa, cada uno con sus propios multiplicadores y sus propias áreas existentes—, pero la interfaz de este bloque todavía **no expone** esos controles. Lo que puedes editar hoy es una sola matriz, constante para todo el árbol.

10.4 Los seis modelos

Tres modelos base, cada uno con y sin +J. Los tres comparten d y e; lo que cambia es qué repartos permiten en el nodo.

Tabla 10.2. Los tres modelos base y qué reparto permiten al dividirse un linaje.

Modelo	Repartos permitidos
DEC Ree y Smith 2008	Simpatría estrecha (un ancestro de una sola área se copia en las dos hijas), simpatría de subconjunto (una hija se queda con todo el rango y la otra con una sola área) y vicarianza estrecha : el rango se corta en dos, pero una de las hijas se queda con una sola área.
DIVALIKE	Sólo vicarianza, pero de cualquier corte : el rango se parte en dos mitades complementarias del tamaño que sean. No hay simpatría de subconjunto.

Tabla 10.2. Los tres modelos base y qué reparto permiten al dividirse un linaje. (*continuación*)

Modelo	Repartos permitidos
BAYAREALIKE	Ninguna de las dos: las dos hijas heredan el rango entero . La división geográfica no ocurre en el nodo; si ocurre, es después, por dispersión y extinción a lo largo de las ramas.
+J Matzke 2013	Se añade a cualquiera de los tres: el salto fundador , una hija que se marcha a una sola área fuera del rango del ancestro. Es el modelo de la colonización a larga distancia.

Puedes ajustar los seis, sólo los tres sin J, o sólo DEC y DEC+J. Se comparan por **AICc con pesos de Akaike**, y cada +J lleva además una razón de verosimilitudes contra el modelo que contiene.

❗ SI E SALE CERO

El panel lo dice con todas sus letras: una tasa de extinción estimada en cero **no significa que no hubo extinción**; significa que en este árbol no quedó ninguna huella de ella. Con árboles pequeños es lo habitual.

10.5 Por qué +J casi siempre gana

Es el punto más delicado del bloque, y el programa no lo esconde: **siempre que gana un modelo +J, el panel explica por qué eso es lo esperable y no es prueba de nada por sí solo.**

Σ LA OBJECCIÓN DE REE Y SANMARTÍN (2018)

La comparación no es limpia. El parámetro **j compra probabilidad en la cladogénesis**, que es un evento instantáneo y no cuesta nada a lo largo de las ramas; **d y e la pagan** integrando por todo el tiempo del árbol. No están compitiendo en las mismas condiciones.

El dato que cierra el argumento: en los casos que ellos examinaron, **+J ganaba incluso sobre datos simulados sin ningún salto.**

Lo que sí se puede afirmar, y es lo que el bloque pone en la tabla, es **cuánto gana y sobre qué modelo**. La razón de verosimilitudes se reporta con la advertencia de que **j queda en el borde del espacio de parámetros**, y una p calculada así es conservadora.

10.6 Dónde estuvo cada linaje, y las esquinas

Elegido un modelo, se reconstruyen los rangos ancestrales **marginales**. Cada nodo lleva un pastel con los rangos que tienen alguna probabilidad; todo lo que no llega al umbral —0.05 de entrada, y se puede cambiar— se junta en una rebanada gris, para que el dibujo no se vuelva ilegible con treinta rangos de probabilidad 0.001.

Las esquinas

Ésta es la parte que muchas figuras publicadas no traen. Un pastel sobre el nodo dice qué rango tenía el **ancestro**; no dice **con qué se quedó cada hija**, que es justo el evento biogeográfico. Las cajitas pequeñas sobre las dos ramas hijas —las **esquinas**— muestran el rango con el que cada una arranca inmediatamente después de la división.

✦ LA MITAD DE LA HISTORIA QUE SE SUELE PERDER

Saber que el ancestro estaba en ABC no dice si hubo vicarianza AB|C, simpatría de subconjunto ABC|A o un salto a D. Esa distinción **está en las esquinas**, y es lo que se cuenta en el artículo. Vienen activadas; déjalas activadas.

10.7 Cuántas veces pasó cada cosa

Una probabilidad por nodo no dice cuántas dispersiones hubo ni cuántas veces se partió un rango. El **mapeo estocástico biogeográfico** sorteá historias completas —un rango para cada nodo, una división para cada bifurcación y los movimientos a lo largo de cada rama— condicionadas a lo que se ve en las puntas, y al repetirlo convierte la reconstrucción en **cuentas de eventos**, que es de lo que está hecha una historia biogeográfica. Quinientas réplicas de entrada.

Lo que se reporta, promediado sobre las historias, son seis cantidades:

- **Dispersiones y extinciones locales** a lo largo de las ramas.
- Los nodos internos repartidos entre los **cuatro tipos de división**: simpatría, simpatría de subconjunto, vicarianza y salto fundador.

Y con ellas, dos avisos que conviene leer. Si la **desviación** de las dispersiones es grande frente a su media, los datos no fijan cuántas hubo: sólo el orden de magnitud. Y si en alguna rama el sorteo agotó sus intentos, el panel dice **en cuántas ocasiones** pasó y advierte que eso subestima un poco las cuentas —suele ocurrir con ramas largas y muchas áreas—, en vez de devolver un número limpio que estaría mal.

Todo sale en cuatro archivos: la tabla de modelos, los rangos ancestrales, los eventos del mapeo y las áreas en formato LAGRANGE.

10.8 Qué tan bien lo hace, medido

Se validó contra **BioGeoBEARS 1.1.3** sobre las *Psychotria* de Hawái: el conjunto de datos que LAGRANGE y BioGeoBEARS distribuyen, y el que vuelve a analizar cada artículo que discute DEC+J. **41 comprobaciones** y ningún desacuerdo.

Tabla 10.3. Log-verosimilitudes de los seis modelos en las *Psychotria* de Hawái.

Modelo	PhylogenyPro	BioGeoBEARS 1.1.3
DEC	-34.54195625	-34.54195758
DEC+J	-20.94758871	-20.94758855
DIVALIKE	-33.14967582	-33.14967538
DIVALIKE+J	-21.08620942	-21.08620912
BAYAREALIKE	-40.33442556	-40.33442795
BAYAREALIKE+J	-21.55262993	-21.55262941

Las tasas d y e coinciden hasta cerca de $1 \cdot 10^{-5}$ (en DEC, 0.03505 y 0.02831 frente a 0.03505 y 0.02836), y los **rangos ancestrales** coinciden hasta $1.75 \cdot 10^{-8}$ en los dieciocho nodos internos cuando ambos se evalúan con los mismos parámetros; la raíz sale en KO con 0.51655966 frente a 0.51655968.

1 EL CONVENIO DE LA RAÍZ

LAGRANGE y BioGeoBEARS pesan por uno cada rango permitido en la raíz, y eso es lo que significa **toda log-verosimilitud DEC publicada**. Un prior plano de verdad difiere por exactamente el logaritmo del número de rangos —aquí, **2.708050**—. Es la misma constante para todos los modelos sobre las mismas áreas, así que ninguna comparación cambia; pero el número que un lector coteja con un artículo, sí. El programa informa el convenio de BioGeoBEARS y lo dice.

1 LO QUE APARECIÓ AL VALIDAR

La referencia estaba mal antes que el código. DIVALIKE discrepaba por 0.033, y la causa estaba en el guion de R: BioGeoBEARS lee el parámetro `mx01v`, no `maxent01v`. Poner el segundo no hace absolutamente nada y deja a DIVALIKE sin sus vicarianzas 2–2, que es tanto como no ser DIVALIKE.

El mensaje que subía en la reconstrucción incluía la verosimilitud de la propia hija, contándola dos veces. El síntoma es el que hay que recordar: reconstrucciones **demasiado seguras** y sesgadas hacia rangos amplios —un nodo al 0.96 para KOMH donde lo cierto era 0.11—. El mensaje que baja a una hija tiene que llevar todo **menos** el subárbol de esa hija; la probabilidad de la esquina, que es la que se lee, sí usa todos los datos. Son dos cantidades distintas y ahora se calculan las dos.

Y velocidad, tres veces. Ajustar un modelo tardaba 7.4 s. Reutilizar los búferes dentro de la exponencial de matrices lo bajó a 0.3 s —el recolector de basura estaba haciendo casi todo el trabajo—; atar los valores iniciales del optimizador a la profundidad del árbol quitó casi todas las iteraciones restantes; y sustituir la exponencial por rama por **uniformización** lo dejó en **0.1 s, unas setenta veces más rápido**, sin que cambiara un solo dígito. Como todos los términos de esa suma son no negativos, además ya no puede producir las probabilidades ligeramente negativas que la serie de Taylor sí producía.

10.9 Errores frecuentes

✗ CONCLUIR «HUBO DISPERSIÓN A LARGA DISTANCIA» PORQUE GANÓ +J

Es el error central de este bloque, y por eso el panel lo advierte solo. +J gana casi siempre, incluso con datos simulados sin un solo salto. Reporta cuánto gana y sobre qué modelo; no lo conviertas en una conclusión biogeográfica.

✗ PONER UN TOPE DE RANGO BAJO Y NO DECIRLO

El tope decide de antemano que ningún linaje estuvo en más áreas que esas. Es un supuesto fuerte y barato de reportar: basta una frase en los métodos.

✗ CORRERLO SOBRE UN FILOGRAMA

d y e son tasas por unidad de tiempo. Sobre un árbol en sustituciones por sitio los números salen, pero no significan dispersiones por millón de años. Usa el cronograma del Bloque 7.

✗ PUBLICAR SÓLO LOS PASTELES DE LOS NODOS

El nodo dice dónde estaba el ancestro; la **esquina** dice qué le tocó a cada hija, que es el evento. Sin las esquinas, la figura no distingue una vicarianza de una simpatría de subconjunto.

✗ LEER UN PASTEL REPARTIDO COMO UN FRACASO

Como en el Bloque 9: un nodo con cinco rangos al 0.2 **es** el resultado. La rebanada gris no es ruido que estorba, es la parte del espacio de rangos que los datos no descartan.

✗ DEJAR TODOS LOS MULTIPLICADORES EN UNO Y LLAMARLO MODELO

Con la matriz plana estás afirmando que moverse entre dos islas vecinas cuesta lo mismo que cruzar un océano. A veces es la hipótesis nula que quieres; casi nunca es la historia que quieres contar.

11

CAPÍTULO ONCE · BLOQUE 11

Comparar árboles

Cada bloque anterior produce un árbol. Éste pregunta qué hacer cuando dos de ellos no son el mismo, que con datos reales es siempre. Mide distancias que no se rompen igual, dibuja el desacuerdo en vez de esconderlo, separa **estar bien estimada** de **estar bien respaldada**, arma un árbol de especies con los cuartetos y distingue —hasta donde se puede— la clasificación incompleta de linajes de la introgresión.

11.1 Los árboles que se van a comparar

11.3 El tanglegrama, y su trampa

11.5 Un árbol de especies con los cuartetos

11.7 La prueba ABBA-BABA

11.9 Errores frecuentes

11.2 Cuánto se parecen

11.4 Concordancia no es apoyo

11.6 Dibujar el conflicto en vez de resolverlo

11.8 Qué tan bien lo hace, medido

11.1 Los árboles que se van a comparar

Sirve cualquier combinación: los que hicieron los Bloques 4, 5, 6 y 7, y los que pegues en Newick, uno por línea —los de cada gen por separado, los de un colega, los de un artículo—. Hacen falta al menos dos.

Todos tienen que tener los mismos nombres de punta, y lo que no case **se dice por su nombre**. Es una de esas comprobaciones que parecen burocracia hasta el día en que un guion bajo de más te hace comparar quince especies creyendo que comparas dieciséis.

11.2 Cuánto se parecen

El menú ofrece seis medidas, todas sobre el árbol **no enraizado**, y el bloque las calcula para cada par y las pone en una tabla y en un mapa de calor.

Tabla 11.1. Las medidas de distancia entre árboles.

Medida	Qué cuenta
Robinson–Foulds	Cuántas divisiones tiene uno y no el otro. Sólo topología.
Robinson–Foulds normalizada	La misma, dividida por su máximo posible, para poder comparar árboles de tamaños distintos.
Cuartetos discrepantes	De todos los grupos de cuatro puntas, cuántos se resuelven de manera distinta en un árbol y en el otro.
Robinson–Foulds pesada	Como la primera, pero cada división pesa lo que mida su rama.
Puntaje de rama Kuhner y Felsenstein	La diferencia entre las longitudes de rama de las divisiones compartidas, sumada en cuadrado.
Diferencia de caminos Steel y Penny	Cuánto cambia la distancia entre cada par de puntas al pasar de un árbol al otro.

✦ NO SE ROMPEN IGUAL, Y EL BLOQUE LO DICE AL LADO

Una sola punta mal colocada puede llevar la Robinson–Foulds a su máximo, mientras la distancia de cuartetos apenas se mueve. Cuando eso pasa, el desacuerdo es **una punta, no una historia**, y confundir las dos cosas es el error más caro de esta sección.

La lectura práctica: si RF sale enorme y la de cuartetos pequeña, busca el taxón saltarín antes de escribir que los dos análisis dan historias distintas.

11.3 El tanglegrama, y su trampa

Dos árboles enfrentados con una línea por punta. Las líneas se cruzan justo donde los árboles discrepan, así que la figura enseña **dónde** está el desacuerdo y no sólo cuánto hay.

Antes de leer nada hay que **desenredar**, y viene activado. Desenredar es **rotar ramas** alrededor de sus nodos hasta que las líneas se crucen lo menos posible. Una rotación **no cambia ninguno de los dos árboles**: es la misma topología dibujada de otra manera. Sin ese paso, un tanglegrama de dos árboles idénticos puede parecer un ovillo.

! UN TANGLEGRAMA SIN CRUCES NO SIGNIFICA QUE LOS ÁRBOLES SEAN IGUALES

Es la advertencia que casi ningún programa imprime, y va en el bloque. Una rotación puede alinear **dos topologías distintas**: las líneas salen paralelas y el ojo concluye «son el mismo árbol». Para eso están las distancias de la sección anterior. El tanglegrama dice **dónde**; el número dice **cuánto**.

11.4 Concordancia no es apoyo

El apoyo de arranque dice con qué seguridad **esos datos** sostienen una rama. No dice cuántos genes la ven. Son dos preguntas distintas, y con genomas completos la segunda suele importar más.

Los **factores de concordancia** de Minh y colaboradores (2020) responden la segunda, rama por rama:

- **gCF**: qué porcentaje de los **árboles de genes** contiene esa rama.
- **sCF**: qué porcentaje de los **sitios** del alineamiento la apoya, estimado sobre cuartetos tomados al azar alrededor de la rama —cien por rama de entrada—.

Se dibujan como barras apiladas contra el tercio que daría el **puro azar**, que es la referencia correcta cuando hay tres resoluciones posibles, y como una dispersión de gCF frente a sCF.

Σ BIEN ESTIMADA Y MAL RESPALDADA A LA VEZ

Una rama con **100 % de arranque** y **35 % de concordancia** no es una contradicción: quiere decir que los datos que tienes la sostienen sin dudar y que dos de cada tres genes ven otra cosa. Está bien estimada y mal respaldada al mismo tiempo, y las dos mitades de esa frase tienen que aparecer en el artículo. El bloque lo repite donde hace falta.

I LA RAMA MÁS PROFUNDA

Una rama que cuelga directamente de una raíz bifurcante **no tiene nada «arriba»**: la raíz no es un nodo del árbol no enraizado. Los cuatro grupos que rodean la rama se forman entonces con las hijas de la hermana. Es un caso fácil de pasar por alto —y lo pasamos por alto, como cuenta la §11.8—, pero el conteo de hoy lo contempla, y por eso la tabla de concordancia trae **todas** las ramas internas y no todas menos la más profunda. Vale la pena mirarla: la rama más profunda suele ser la que separa los dos grandes grupos del estudio, es decir, justo la que se discute en el resumen del artículo.

11.5 Un árbol de especies con los cuartetos

Cuando los genes discrepan por **clasificación incompleta de linajes**, concatenarlos no arregla nada: puede dar con mucha confianza un árbol que ningún gen sostiene. La salida es trabajar con los cuartetos.

- 1 De cada grupo de cuatro especies hay **tres** resoluciones posibles. Se cuenta con qué frecuencia aparece cada una entre los árboles de genes.
- 2 Cada árbol candidato recibe un **puntaje**: cuántos cuartetos de los observados es capaz de explicar.
- 3 Se busca el mejor con una búsqueda de vecinos más cercanos, empezando desde el árbol que elijas.

! ES UNA HEURÍSTICA, Y SE LLAMA A SÍ MISMA HEURÍSTICA

La búsqueda puede quedarse en un óptimo local. **No es el programa exacto de ASTRAL**, y el bloque no finge que lo sea. Para un artículo sobre discordancia de genes, usa ASTRAL; esto sirve para ver el problema, entenderlo y comparar con lo que ya tienes.

11.6 Dibujar el conflicto en vez de resolverlo

Un consenso tiene que **tirar** las divisiones que se contradicen. Una red las **conserva todas** y las dibuja como cajas: cuanto más ancha la caja, más peso tiene el conflicto. Dos caminos:

Tabla 11.2. Las dos redes que construye el bloque.

Construcción	De qué parte y qué enseña
Red de consenso de los árboles	Toma las divisiones que aparecen en bastantes árboles —el umbral viene en 0.3— y las dibuja todas. Los pares incompatibles se encuentran y se marcan en color: ésas son las cajas.
Descomposición circular de las distancias	Parte de una matriz de distancias en vez de árboles. Si le das las distancias de un árbol, devuelve ese árbol exactamente ; si le das cualquier otra cosa, la diferencia se ve como anchura.

✦ POR QUÉ VALE LA PENA DIBUJAR EL CONFLICTO

Un consenso con politomías dice «aquí no sé». Una red dice «aquí hay **dos** señales, y éstas son». Es mucha más información, y es honesta: no obliga a escoger antes de tiempo.

11.7 La prueba ABBA-BABA

Con el árbol $((P1,P2),P3),O$, un sitio en el que **P2 y P3** comparten el estado derivado —**ABBA**— y otro en el que lo comparten **P1 y P3** —**BABA**— son igual de incongruentes con ese árbol. Y bajo clasificación incompleta de linajes son **igual de probables**.

Ahí está toda la idea: la clasificación incompleta de linajes es simétrica, y la introgresión no. Que uno de los dos patrones sea mucho más frecuente que el otro es la huella de la hibridación. La **D de Patterson** mide ese desequilibrio, y el bloque le pone un intervalo del 95 % por **jackknife por bloques** —veinte bloques de entrada—, porque los sitios vecinos no son independientes y una desviación estándar calculada sitio a sitio sale demasiado pequeña.

Se puede probar un trío concreto o barrer **todos** los tríos contra un exogrupo.

! D ≠ 0 TIENE TRES EXPLICACIONES Y SÓLO UNA ES INTROGRESIÓN

El mismo desequilibrio lo producen un **exogrupo mal elegido**, **tasas de evolución muy desiguales** entre P1 y P2, y un **error de alineamiento**. Los tres hay que descartarlos antes de escribir «hibridación». El panel lo dice cada vez, no una sola vez en la ayuda.

Todo se lleva en cinco archivos: la matriz de distancias, la concordancia por rama, las divisiones de la red, el ABBA-BABA y todos los árboles juntos en **.tre**.

11.8 Qué tan bien lo hace, medido

Se comprobó contra **ape 5.8.1** y **phangorn 2.12.1**: **25 comprobaciones** y ningún desacuerdo.

- **Las distancias sobre 36 pares cada una**, 216 números: RF y RF normalizada **exactas**; la RF pesada hasta $4.5 \cdot 10^{-10}$, el puntaje de rama hasta $1.5 \cdot 10^{-10}$, la diferencia de caminos hasta $5 \cdot 10^{-14}$ y su forma pesada hasta $8 \cdot 10^{-10}$.
- **La distancia de cuartetos** contra un conteo por fuerza bruta sobre los 1820 cuartetos de dieciséis taxones, podando los dos árboles a cada uno: 1767/53, 1691/129 y 1820/0, **exacta**.
- **gCF** contra la misma definición recalculada en R sobre las trece ramas internas, con diferencia **cero**.
- **La red de consenso** división por división contra **phangorn : : consensusNet** : las trece divisiones no triviales, idénticas.
- **La D de Patterson** contra la definición calculada en R sobre un alineamiento de 60 000 sitios con 15 % de introgresión: ABBA 1089, BABA 753, D 0.18241042, error estándar del jackknife 0.07884390 y z 2.31356419, **cada dígito**.

! CUANDO NO HAY PAQUETE CONTRA EL CUAL COMPARAR

Para la **descomposición circular** no hay ninguno instalado, así que se comprobó contra una **identidad**: alimentada con las distancias de caminos de un árbol de dieciséis taxones devuelve exactamente sus 13 divisiones internas y sus 16 terminales, con las longitudes de rama hasta $3 \cdot 10^{-16}$ y las distancias reconstruidas hasta $9 \cdot 10^{-16}$, sin recortar nada; y el ciclo exterior de la red cierra sobre sí mismo hasta $3 \cdot 10^{-16}$. Una identidad que tiene que cumplirse es una prueba tan buena como un paquete, y a veces mejor.

I LO QUE APARECIÓ AL VALIDAR

Las medidas pesadas leían media rama. Un árbol enraizado tiene dos aristas bajo su raíz, y son **una sola** arista del árbol no enraizado; tomar la longitud del nodo que el mapa de divisiones hubiera conservado la partía por la mitad. Todas las comparaciones pesadas heredaban el error: la RF pesada salía 2.54 donde phangorn dice 3.78. Ahora las longitudes se acumulan **por división**, no se leen de un nodo.

La diferencia de caminos contaba la raíz. Medido en aristas, el camino entre dos puntas depende de dónde esté la raíz, y dos árboles idénticos enraizados distinto salían a 7.94 en vez de 0. La medida es del árbol no enraizado, así que ahora lo primero que se hace es quitar la raíz.

Un árbol enraizado en una sola punta criaba una rama interna de más. La rama sobre su hermana contiene $n-1$ puntas, y la prueba de «trivial» sólo miraba el lado de abajo. Uno de los árboles de ejemplo de la propia app mostraba 16 divisiones internas donde hay 15, lo que infla en uno cada comparación con un árbol enraizado en otro sitio. **Apareció corriendo el bloque sobre salida real**, no en el banco, cuyos árboles de referencia nunca se enraízan así.

Los cuatro grupos alrededor de una rama eran tres bajo la raíz, por lo dicho en la §11.4: faltaba exactamente una rama, siempre la más profunda, en cada tabla de concordancia. Doce ramas donde hay trece.

La descomposición circular tenía sus cuatro términos emparejados al revés. El peso de una división es una diferencia de cuatro puntos a través de los **dos huecos** que la limitan, y emparejar las distancias por hueco en vez de por extremo da un número que parece un peso y no lo es: 91 divisiones donde un árbol de dieciséis taxones tiene 29, y distancias que no podía reproducir.

Y uno pequeño con moraleja grande: `opts.minSites || 20` convertía un cero deliberado en veinte, así que pedir el barrido de todos los tríos no devolvía ninguno.

11.9 Errores frecuentes

✗ REPORTAR UNA ROBINSON-FOULDS GRANDE COMO «HISTORIAS DISTINTAS»

Mira antes la distancia de cuartetos. Si ésta es pequeña, lo que tienes es **una punta inestable**, no dos hipótesis en conflicto. Reportar las dos medidas cuesta una línea y evita la conclusión equivocada.

✗ LEER UN TANGLEGRAMA SIN CRUCES COMO PRUEBA DE IGUALDAD

Una rotación puede alinear dos topologías distintas. El tanglegrama enseña dónde discrepan; quien dice si discrepan es el número.

✗ CONFUNDIR CONCORDANCIA CON APOYO

100 % de arranque y 35 % de gCF describen cosas distintas y las dos son verdad. Publicar sólo la primera da una idea muy optimista de lo que sabes.

✗ CONCATENARLO TODO CUANDO LOS GENES DISCREPAN DE VERDAD

Bajo clasificación incompleta de linajes, la concatenación puede dar con altísima confianza un árbol que **ningún gen** sostiene. Ahí es donde hacen falta los cuartetos.

✗ ANUNCIAR HIBRIDACIÓN CON UNA D SIGNIFICATIVA Y NADA MÁS

Descarta primero el exogrupo, las tasas desiguales y el alineamiento. Una D significativa es el **principio** de la investigación, no su conclusión.

✗ PRESENTAR EL ÁRBOL DE CUARTETOS COMO SI FUERA ASTRAL

Es una búsqueda heurística y puede quedarse en un óptimo local. Dilo en los métodos, o corre ASTRAL.

12

CAPÍTULO DOCE · BLOQUE 12

Figuras e informe

Un resultado que no puede salir del programa no es un resultado. Aquí se arma la figura —con todas sus decisiones a la vista y reversibles—, se escriben los métodos con los números de la corrida y no con los de una plantilla, y se empaqueta todo para que otra persona pueda repetirlo. Es el bloque que entrega el trabajo.

12.1El estudio de árboles

12.3Imágenes de las OTU y de los clados

12.5Los tres formatos de árbol

12.7La resolución que pida la revista

12.9El paquete reproducible

12.11Errores frecuentes

12.2Cortar el árbol en grupos

12.4Etiquetas que no se encimen

12.6El estudio de figuras

12.8Los métodos, escritos con los números de la corrida

12.10Qué tan bien lo hace, medido

12.1 El estudio de árboles

La figura de un árbol tiene más decisiones de las que parece, y **casi todas cambian lo que el lector entiende**: si se dibuja con longitudes de rama o sin ellas, qué apoyo se muestra y desde qué umbral, dónde va la raíz, en qué orden se escalonan las ramas. Todas se cambian aquí y el dibujo se rehace al momento.

Tabla 12.1. Las decisiones que más cambian la lectura de la figura.

Control	Por qué importa
Cladograma (sin longitudes)	Un cladograma sólo afirma el parentesco. Un filograma afirma además cuánto cambio hubo en cada rama. Dibujar uno y hablar del otro es el malentendido más común de una figura filogenética.
Apoyo y umbral	Esconder los apoyos bajos de la figura es legítimo si se dice; esconderlos y no decirlo convierte un árbol dudoso en uno firme a la vista.
Raíz y exogrupo	La raíz no sale de los datos: se pone. Cambiarla cambia qué grupo es hermano de cuál, y es la decisión con más consecuencias del dibujo entero.
Escalonar	Ordena las ramas por tamaño. Es puramente estético —no cambia el árbol— y hace legible una figura que sin ello parece un desorden.
Barra de escala	Sin ella, un filograma no dice en qué unidades está. Con un cronograma, el eje ya lo dice.

Lo demás es acabado: ancho, alto de fila, letra de las puntas y su grosor, cursivas para los nombres científicos, título, alineación de los nombres con su guía punteada, y color para los clados que marques a mano.

12.2 Cortar el árbol en grupos

Se pide un número de grupos, k , y el programa corta el árbol de una de tres maneras:

- Por las **ramas más largas**, que sirve en cualquier árbol.
- Por **profundidad**, que sólo tiene sentido en un árbol ultramétrico: si el tuyo no lo es, **lo dice y cambia de método** en vez de devolver un corte sin significado.
- A partir de **clados** o a mano.

El color se puede llevar a las ramas, a los nombres, a una franja lateral o a bandas suaves de fondo, con su leyenda y con los nombres de grupo que tú pongas.

✦ DICE SI CADA GRUPO ES REALMENTE UN CLADO

Junto a los tamaños, el panel informa de la **monofilia** de cada grupo. Colorear un grupo parafilético y no decir nada es una de las maneras más limpias de que una figura engañe: el lector ve un color y entiende «linaje», cuando lo que hay es un corte por conveniencia.

Y las bandas de fondo sólo se dibujan para los grupos cuyas puntas quedan **seguidas** en la figura, porque una banda que abarcara puntas de otro grupo estaría afirmando que le pertenecen.

12.3 Imágenes de las OTU y de los clados

Se pueden colgar fotografías o dibujos de cada punta, de cada grupo o de los clados que marques, en el tamaño que quieras, como círculos, cuadros o cuadros de esquinas suaves, con marco o sin él. Las imágenes se arrastran al gestor, y **un archivo que se llama como su taxón encuentra su sitio solo**.

Cada imagen tiene su recorte, su acercamiento, su giro y sus ajustes de brillo, contraste, saturación, temperatura y nitidez, además de un **quitafondos** que inunda desde el borde hacia dentro —así las zonas claras *dentro* del objeto sobreviven, cosa que un umbral de brillo destruiría—. Cada una lleva su crédito y su licencia.

! NADA SE DIBUJA HASTA QUE CONFIRMAS QUE LA FOTO ES DE ESA ESPECIE

Es una casilla deliberada y no se puede saltar. **Una fotografía colgada de la rama equivocada es una afirmación, no un adorno**, y es una afirmación que el lector va a creer sin comprobarla.

I DÓNDE VIVEN Y ADÓNDE VIAJAN

Las imágenes se guardan en el navegador —en IndexedDB, separadas por conjunto de datos— y **no salen de tu computadora**. Al exportar, viajan **dentro** del SVG, así que la figura no depende de ningún archivo suelto que se quede atrás al mandar el artículo.

12.4 Etiquetas que no se encimen

Dos cosas hace el programa cuando las etiquetas se estorban. La primera es **separarlas**: empujarlas a lo largo de un eje hasta que ninguna quede más cerca de otra que la separación pedida, sin salirse del marco. La segunda, cuando ya no cabe ninguna más, es **quitar las menos importantes** y quedarse con las que más dicen.

✦ Y AVISA DE CUÁNTAS QUITÓ

Ésa es la parte que importa. Perder etiquetas en silencio es peor que no dibujarlas: el lector no sabe que faltan. El panel dice **cuántas escondió y dónde encontrarlas** —siempre están en la tabla y en el paquete— y qué cambiar si las quieres todas.

En el diseño no enraizado nada impide que dos puntas caigan una junto a otra, así que ahí se descartan las que sigan chocando y se conservan las más periféricas, otra vez con la cuenta a la vista.

12.5 Los tres formatos de árbol

Tabla 12.2. Los tres formatos y para qué sirve cada uno.

Formato	Qué carga
Newick	Universal y estrecho. Lo lee todo, y por eso es el que se manda cuando sólo hace falta el árbol.
NEXUS	Con su bloque <code>TRANSLATE</code> y el bloque que FigTree lee.
phyloXML	El único de los tres que puede llevar a la vez el apoyo de un nodo, su edad y su intervalo de confianza , que es justo lo que producen los Bloques 5, 6 y 7. Si tu árbol está fechado, es el formato que no pierde nada.

Se elige si van las longitudes de rama, si van los valores de apoyo, con cuántos decimales, y si se escribe sólo el árbol elegido o todos. Se descarga o se copia al portapapeles.

12.6 El estudio de figuras

Lo que se cambie aquí vale para **todas las figuras de los doce bloques**, no sólo para el árbol: paleta, familia y tamaño de letra, grosor del trazo y fondo. Los diez colores se pueden editar uno por uno —son los que usan los grupos del árbol, las series de las curvas, los estados de un carácter y las áreas de la biogeografía—, y aparte van los del texto, los ejes y los apoyos.

Σ POR QUÉ BASTA UNA REGLA

Ninguna figura de este programa escribe un color literal: todas dibujan a través de propiedades de CSS, y su texto a través de dos o tres clases. Eso se hizo para que las figuras siguieran el tema claro y el oscuro, y tiene una segunda consecuencia que valía la pena aprovechar: **redefinir esas propiedades restila la aplicación entera de una vez**. El estudio escribe **una sola regla**, y ningún módulo de dibujo sabe que existe. La regla se limita a los `svg` a propósito: las etiquetas de colores de la interfaz usan los mismos tokens, y una paleta de figuras no tiene por qué recolorear los menús.

Las **nueve paletas** incluyen la propia del programa, **Okabe–Ito** (segura para daltonismo), viridis, tierra, frías, cálidas, pasteles, alto contraste y **escala de grises**, que está ahí para una pregunta muy concreta: si la revista cobra por el color, ¿tu figura se sigue entendiendo?

Las **siete familias de letra** están todas en cualquier computadora normal: no se descarga ninguna de la red, porque una figura que en la máquina del revisor cae en otra tipografía es una figura que no diseñaste. El tamaño va de 0.7 a 1.6 veces, el trazo de 0.5 a 3, y hay cuatro fondos, entre ellos transparente y blanco. Un botón devuelve todo al original.

I LO QUE SE EXPORTA ES LO QUE SE VE

Un SVG cargado como imagen **no tiene hoja de estilo**, así que al exportar hay que resolver los colores a mano. El estudio se engancha ahí: sus colores ganan sobre el tema, su tipografía sustituye a la que va escrita en el código, y el fondo elegido se escribe como un rectángulo debajo de todo. Se comprobó exportando un árbol y **buscando el azul de Okabe y el fondo blanco en los píxeles del PNG**.

12.7 La resolución que pida la revista

Todas las figuras del programa son **SVG**, que no tiene resolución: se imprime a cualquier tamaño sin perder nada, y es lo que conviene mandar cuando la revista lo acepta.

Cuando pide PNG a tantos puntos por pulgada, lo que pide en realidad es **un número concreto de píxeles**. El bloque hace esa cuenta **antes** de generar nada y la enseña: a 900 ppp una figura de media página son varios miles de píxeles por lado. Y si la cifra pasa de lo que un navegador puede dibujar, **lo dice y explica por qué**, en vez de devolver una imagen en blanco que parece un error del programa.

12.8 Los métodos, escritos con los números de la corrida

La sección de métodos es la parte del artículo que permite a otra persona llegar al mismo resultado, y es la que se escribe al final, de memoria, semanas después. Aquí la escribe el programa a partir de lo que **realmente corrió**:

- Un bloque que no se usó **no deja párrafo**.
- Un apoyo que no se calculó **no se menciona**.
- El número de réplicas viene de la corrida, **no de una plantilla**.
- La bibliografía se arma con lo que se citó y con nada más: el programa conoce 52 obras y sólo aparecen las que usó.

Se elige idioma, título y autoría, y si se incluyen las figuras. El informe es **un solo archivo HTML autocontenido**: sin hoja de estilo que buscar, sin tipografía que descargar, sin guion que ejecutar. Se ve en cualquier navegador y se imprime a PDF desde ahí.

! UN BORRADOR HONESTO, NO UN MÉTODO TERMINADO

Lo que el programa no puede escribir es **por qué** elegiste lo que elegiste: por qué ese exogrupo, por qué ese fósil en ese nodo, por qué ese tope de rango. Eso lo pones tú. El informe te ahorra los parámetros y las citas, que es donde se cometen los errores de transcripción, no el criterio.

12.9 El paquete reproducible

Un archivo con todo: los datos tal como entraron, los árboles en los tres formatos, las figuras en SVG con sus colores ya resueltos, las tablas en CSV, el informe, y un archivo de texto que dice **qué es cada cosa y con qué parámetros se hizo**. Se elige qué partes incluir.

✦ EL ZIP LO ESCRIBE EL PROPIO PROGRAMA

Byte por byte, sin biblioteca externa y sin red. Por eso funciona igual con la app abierta por doble clic, sin servidor y sin conexión —que es como la vas a usar el día que la necesites en una computadora ajena.

12.10 Qué tan bien lo hace, medido

Este bloque no calcula: **entrega**. Así que se validó haciendo que R hiciera lo que haría quien reciba el paquete —abrirlo y leerlo con sus propias herramientas—. **38 comprobaciones** y ningún desacuerdo.

- **El ZIP:** la función `unzip()` de R lista y extrae todos los archivos, **comprobando cada CRC32 por el camino**, y los tamaños extraídos son los declarados.
- **Newick y NEXUS:** leídos por `ape::read.tree` y `ape::read.nexus`, las mismas 18 puntas, distancia topológica 0 entre ambos y longitudes de rama idénticas hasta 10^{-6} .
- **phyloXML:** analizado por `xm12`; sus nombres de punta son los del árbol y sus longitudes de rama suman lo que suma el Newick (2.446035 contra 2.446036).
- **El alineamiento:** leído por `ape::read.dna` en 18×1711 , con los taxones del árbol.
- **El informe:** un archivo sin `<link>`, sin `<script>` y sin `<img>`, con sus figuras como SVG en línea; y, en un paquete armado sólo con un árbol de distancias, **sin citar reloj, ni biogeografía, ni MCMC**, porque ninguno corrió.
- **Las figuras:** XML bien formado y sin ningún `var(--...)` sin resolver, que en Illustrator sería una línea negra.
- **El CRC32** contra el valor que la propia especificación del ZIP nombra para la cadena «123456789»: `0xCBf43926`.

I LO QUE APARECIÓ AL VALIDAR

El módulo del informe dependía del traductor de la página, lo que lo rompía fuera de la app y, peor, producía un documento a medio traducir: los fragmentos que iba pegando —«arranque no paramétrico (100 réplicas)», «por exogrupo», «verosimilitud penalizada»— se resolvían **una vez**, en el idioma en que estuviera la interfaz, y luego se metían en el párrafo español y en el inglés. Ahora cada fragmento se guarda como pareja, y el módulo ya no sabe en qué idioma está la página.

Y uno que da risa y enseña: el genoma de una partición se guarda como un código de dos letras, cosa razonable en un menú y absurda en una sección de métodos. Decía «**los genomas representados son: nu**».

Del estudio de figuras salieron otros dos. La clase `.art-link` se usaba y nunca se había definido en la hoja de estilo —los nombres de las puntas del cronograma caían a negro, invisible en el tema oscuro—; y el estudio parcheaba la exportación antes de que existiera lo que iba a parchear, porque su archivo se cargaba *antes* del que envuelve. Lo destapó la página de pruebas, que exporta sin esperar a que el documento esté listo.

12.11 Errores frecuentes

✗ PUBLICAR UN CLADOGRAMA Y HABLAR DE ÉL COMO DE UN FILOGRAMA

Sin longitudes, la figura no dice nada sobre cuánto cambio hubo. Si el texto habla de ramas largas o de evolución acelerada, la figura tiene que llevarlas.

✗ SUBIR EL UMBRAL DEL APOYO Y NO DECIRLO

Un árbol del que se han borrado los apoyos bajos parece mucho más firme de lo que es. Decir «se muestran los apoyos ≥ 70 » cuesta seis palabras.

✗ COLOREAR UN GRUPO PARAFILÉTICO SIN AVISAR

El panel te dice cuáles lo son. Un color en una figura se lee como «linaje»; si no lo es, hay que escribirlo en el pie.

✗ PONER UNA FOTO SIN COMPROBAR DE QUÉ ESPECIE ES

Por eso hay una casilla que no se puede saltar. La foto va a ser lo primero que mire el lector y lo último que dude.

✕ MANDAR UN PNG CUANDO ACEPTAN SVG

El SVG no tiene resolución y se imprime a cualquier tamaño. Un PNG a 300 ppp que luego se amplía en maqueta llega borroso a la imprenta.

✕ ENTREGAR EL INFORME TAL CUAL

Trae los parámetros y las citas correctas; no trae tus razones. Añade por qué ese exogrupo, ese fósil y ese modelo antes de mandarlo.

✕ GUARDAR SÓLO LA FIGURA

El paquete pesa poco y contiene los datos como entraron, los árboles en tres formatos y el índice de qué es cada cosa. Es lo que te va a salvar cuando el revisor pregunte, seis meses después, con qué parámetros se hizo.



APÉNDICES

Apéndices

Lo que hace falta tener a la mano y no cabía en ningún capítulo: qué archivos lee y escribe el programa, el catálogo completo de modelos con la cita de cada matriz, todas las reglas de decisión de los doce bloques reunidas en una sola tabla, el vocabulario, qué hacer cuando algo no sale, las referencias y la licencia de la herramienta.

A Los archivos que el programa lee y escribe

B El catálogo de modelos

C Las reglas de decisión, reunidas

D Glosario

E Cuando algo no sale

F Referencias

G La herramienta: licencia y cómo citarla

A Los archivos que el programa lee y escribe

PhylogenyPro es un programa de escritorio que corre en el navegador y **no manda nada a ningún servidor**: todos los archivos entran y salen de la carpeta de tu computadora. Este apéndice dice cuáles son.

A.1 · Lo que lee

FORMATO	DÓNDE Y PARA QUÉ
FASTA .fasta .fas .fa .fna	Bloque 2. Es el formato con el que casi todo el mundo empieza.
PHYLIP .phy .phylip	Bloque 2, en sus cuatro sabores: estricto y relajado, secuencial e intercalado. El lector dice cuál interpretó.
NEXUS .nex .nexus	Bloque 2. Bloques DATA , CHARACTERS , SETS y TREES , con MATCHCHAR y comentarios.
Clustal .aln MEGA .meg	Bloque 2, alineamientos ya hechos en otro programa.
GenBank .gb .gbk .seq	Bloque 2, el archivo plano tal como se descarga.
Tabla .csv .tsv .txt	Bloque 2 para una matriz morfológica; Bloque 9 para los caracteres, con una fila por especie y una columna por carácter.
Esquema de particiones .txt .part .nex .cfg	Bloque 2. Lee el formato de RAxML y el bloque SETS de NEXUS.
Árboles .tre .tree .newick .nwk .txt	Bloque 11, uno por línea: los de cada gen, los de un colega, los de un artículo.
Áreas .data .csv .tsv .phy .txt	Bloque 10. El formato de LAGRANGE —el mismo que usa BioGeoBEARS— o una tabla con una columna por área.
Imágenes	Bloque 12, arrastradas al gestor. Un archivo que se llama como su taxón encuentra su sitio solo.

1 UN LIBRO DE CÁLCULO NO SE LEE, Y ES A PROPÓSITO

No hay lector de **.xlsx** ni de **.ods**. Incorporar uno significaría meter en el programa una biblioteca ajena de cientos de miles de líneas, y quedaría dentro para siempre. Se prefirió que el programa **no cargue una sola línea que no sea propia**: es justo lo que le permite abrirse con doble clic, sin instalar nada y sin internet. Guarda la hoja como **.csv** y listo.

A.2 · Lo que escribe

FORMATO	QUÉ SALE Y DESDE DÓNDE
FASTA, PHYLIP, NEXUS	Bloque 2: el alineamiento, recortado o no. El NEXUS lleva sus charsets .
Esquema de RAxML	Bloque 2, para llevar las particiones a otro programa.
Newick	Bloques 4 a 12. Universal y estrecho.

FORMATO	QUÉ SALE Y DESDE DÓNDE
NEXUS de árboles	Bloque 12, con bloque TRANSLATE y el bloque que lee FigTree.
phyloXML	Bloque 12. El único de los tres que lleva a la vez el apoyo, la edad y el intervalo de un nodo.
CSV	De casi todos los bloques: modelos, distancias, apoyos, concordancia, rangos ancestrales, eventos, divisiones, ABBA-BABA.
SVG	Todas las figuras. Sin resolución, con los colores resueltos y con las imágenes dentro.
PNG	Todas las figuras, a los puntos por pulgada que pidas, con la cuenta de píxeles enseñada antes de generarla.
Informe .html	Bloque 12. Un solo archivo autocontenido; se imprime a PDF desde el navegador.
Paquete .zip	Bloque 12. Todo lo anterior más un índice que dice qué es cada cosa.

A.3 · Atajos de teclado

Prácticamente no hay, y conviene decirlo en vez de inventar una lista: el programa se maneja con el ratón. Lo único que responde al teclado es **Esc**, que cierra la ficha de ayuda de interpretación y el gestor de imágenes, y la **barra espaciadora** o **Intro** sobre una tarjeta de la portada, que abre ese bloque.

B El catálogo de modelos

B.1 · Los 56 modelos de ADN

Siete esquemas de tasas, cada uno con frecuencias iguales o empíricas —catorce modelos base— y cada uno en las cuatro variantes de variación de tasa entre sitios: **a secas**, **+I**, **+G** y **+I+G**. Catorce por cuatro, cincuenta y seis.

FREC. IGUALES	FREC. EMPÍRICAS	TASAS	QUÉ AÑADE SOBRE EL ANTERIOR
JC	F81	0	El punto de partida: todos los cambios iguales.
K80	HKY	1	Las transiciones se distinguen de las transversiones.
TrNef	TrN	2	Las dos transiciones, con tasas distintas.
K81	K81uf	2	Dos clases de transversión.
TIMEf	TIM	3	Transiciones distintas y transversiones distintas.
TVMef	TVM	4	Las cuatro transversiones libres.
SYM	GTR	5	Las seis tasas libres. No hay nada más general.

El **+I** añade una proporción de sitios invariables; el **+G**, una gamma discreta con α estimada (Yang 1994), con las tasas reescaladas como lo hace PAML. La columna de la derecha es, leída de arriba abajo, la cadena de pruebas de razón de verosimilitudes que el bloque también sabe correr.

B.2 · Las doce matrices de proteína

Cada una con sus 190 intercambiabilidades y sus 20 frecuencias de equilibrio, y cada una en las mismas variantes, con **+F** para usar las frecuencias de tus datos en vez de las de la matriz. Todas se verificaron contra cinco distribuciones canónicas independientes.

MATRIZ	PARA QUÉ SE HIZO, Y SU PUBLICACIÓN ORIGINAL
LG	Proteínas nucleares en general; la de uso preferente hoy. Le y Gascuel (2008).
WAG	Proteínas globulares. Whelan y Goldman (2001).
JTT	La sucesora de Dayhoff, con muchos más datos. Jones, Taylor y Thornton (1992).
Dayhoff	La primera de todas, de valor histórico y todavía útil. Dayhoff, Schwartz y Orcutt (1978).
cpREV	Proteínas de cloroplasto . Adachi, Waddell, Martin y Hasegawa (2000).
mtREV24	Proteínas mitocondriales . Adachi y Hasegawa (1996).
VT	Derivada de alineamientos muy divergentes. Müller y Vingron (2000).
RtREV	Retrovirus. Dimmic, Rest, Mindell y Goldstein (2002).
Blosum62	La matriz de puntuación clásica, usada aquí también como modelo. Henikoff y Henikoff (1992).
FLU	Virus de la influenza. Dang, Le, Gascuel y Le (2010).
HIVb	VIH, entre hospederos. Nickle y colaboradores (2007).
mtMam	Mitocondrias de mamífero. Yang, Nielsen y Hasegawa (1998). En el menú aparece como mtmam .

B.3 · Los demás modelos, por bloque

DÓNDE	MODELOS
Morfología Bloque 3	Mk y Mkv con la corrección por comprobación de Lewis (2001), que es la que hay que usar cuando la matriz sólo tiene caracteres variables.
Distancias Bloque 3	p, JC69, K80, F81, TN93, LogDet (Lockhart et al. 1994) y paralineal (Lake), Poisson y Kimura para proteínas, con sus variantes corregidas por gamma.
Reloj Bloque 7	Estricto; verosimilitud penalizada con λ por validación cruzada (Sanderson 2002); mínimos cuadrados (To et al. 2016); y el relajado no correlacionado del muestreador bayesiano (Drummond et al. 2006).
Diversificación Bloque 8	Rendimiento puro, nacimiento—muerte, dos tasas, densodependiente y exponencial.
Caracteres Bloque 9	Continuos: browniano, Ornstein—Uhlenbeck y estallido temprano. Discretos: Mk en sus variantes ER , SYM y ARD .
Biogeografía Bloque 10	DEC (Ree y Smith 2008), DIVALIKE y BAYAREALIKE , cada uno con y sin el salto fundador +J (Matzke 2013).

C Las reglas de decisión, reunidas

Las escalas que el programa aplica a cada número, en un solo sitio. En pantalla no hace falta consultarlas: la ayuda de interpretación pinta la banda al lado del valor. Aquí están para citarlas, para discutir las y para llevarlas a una reunión.

! LA MITAD DE ESTOS CORTES SON COSTUMBRES, NO LEYES

El 70 % del arranque, el 0.95 de la posterior, el 200 del ESS: son **convenciones de lectura** que la comunidad adoptó, no umbrales derivados de una teoría. El programa lo dice en cada ficha donde es el caso, y este apéndice lo repite una vez para todas. Úsalas para orientarte, no para decidir sola.

C.1 · Datos y alineamiento

CANTIDAD	ESCALA
Sitios informativos por taxón	<2 muy pocos · 2–10 justos · 10–40 razonables · >40 holgados
Huecos en la matriz	<0.05 muy limpia · 0.05–0.2 normal · 0.2–0.5 mucha ausencia · >0.5 más hueco que dato
Recorte: columnas eliminadas	<0.1 casi nada · 0.1–0.3 normal · 0.3–0.5 mucho · >0.5 el alineamiento era el problema
Puntaje SP	<0.7 mal alineado · 0.7–0.9 aceptable · 0.9–0.98 bueno · >0.98 casi perfecto
χ^2 de composición (p)	<0.01 heterogénea, cuidado · 0.01–0.05 dudosa · >0.05 compatible con homogeneidad

C.2 · Modelos

CANTIDAD	ESCALA
ΔAIC frente al mejor	0–2 igual de bueno · 2–4 casi igual · 4–10 claramente peor · >10 descartado
Peso de Akaike del mejor	<0.5 sin ganador claro · 0.5–0.9 preferido · >0.9 ganador neto
LRT (p)	<0.01 el complejo gana claro · 0.01–0.05 el complejo gana · >0.05 basta el simple
α de la gamma	<0.5 muy desigual · 0.5–1 desigual · 1–3 moderada · >3 casi homogénea
κ (ts/tv)	<1.2 sospechosamente baja · 1.2–4 normal · 4–10 alta · >10 muy alta

C.3 · Árboles y apoyos

CANTIDAD	ESCALA
CI (consistencia)	<0.3 mucha homoplasia · 0.3–0.5 bastante · 0.5–0.75 moderada · >0.75 poca
RI (retención)	<0.4 poca estructura · 0.4–0.6 algo · 0.6–0.8 buena · >0.8 muy buena

CANTIDAD	ESCALA
Arranque (%)	<50 sin apoyo · 50–70 débil · 70–95 apoyada · >95 fuerte
UFBoot (%)	<85 sin apoyo · 85–95 dudosa · >95 apoyada
SH-aLRT (%)	<80 sin apoyo · >80 apoyada
Prueba AU (p)	<0.05 se rechaza · 0.05–0.1 al borde · >0.1 no se rechaza
RF normalizada	<0.1 casi el mismo árbol · 0.1–0.3 diferencias menores · 0.3–0.6 discrepan · >0.6 topologías distintas

I LAS TRES ESCALAS DE APOYO NO SON LA MISMA

Un **70 % de arranque**, un **95 % de UFBoot** y una **posterior de 0.95** vienen a decir lo mismo. Leer el UFBoot con la vara del arranque —celebrar un 75— es el error más común con el arranque ultrarrápido. Están en tres filas distintas por esa razón.

C.4 · Bayesiano

CANTIDAD	ESCALA
Posterior	<0.5 sin apoyo · 0.5–0.95 dudosa · >0.95 apoyada
ESS	<100 insuficiente · 100–200 justo · >200 suficiente
PSRF ($\hat{R}$)	<1.01 convergieron · 1.01–1.05 al borde · >1.05 no convergieron
ASDSF	<0.01 convergieron · 0.01–0.05 aún no · >0.05 lejos
2·ln(BF)	<2 sin diferencia · 2–6 positivo · 6–10 fuerte · >10 muy fuerte (Kass y Raftery 1995)

C.5 · Tiempo, diversificación y caracteres

CANTIDAD	ESCALA
r^2 raíz–punta	<0.2 sin señal temporal · 0.2–0.5 débil · 0.5–0.8 clara · >0.8 reloj muy marcado
Reloj estricto (p)	<0.05 se rechaza · >0.05 no se rechaza
Variación de tasa (CV)	<0.1 prácticamente reloj · 0.1–0.3 moderada · 0.3–0.6 alta · >0.6 muy alta
γ de Pybus y Harvey	<–1.645 desaceleración · –1.645 a 1.645 compatible con tasa constante · >1.645 aceleración
$\epsilon = \mu/\lambda$	<0.2 poca extinción · 0.2–0.6 moderada · 0.6–0.9 alta · >0.9 casi todo se extingue
λ de Pagel	<0.2 sin señal · 0.2–0.6 parcial · 0.6–0.9 buena · >0.9 browniano
K de Blomberg	<0.5 menos señal que el browniano · 0.5–1 algo menos · >1 más que el browniano

C.6 · Discordancia

CANTIDAD	ESCALA
gCF (%)	<33 la mayoría discrepa · 33–50 conflicto fuerte · 50–75 mayoría a favor · >75 acuerdo amplio
sCF (%)	<36 sin señal · 36–45 muy repartida · 45–60 mayoría · >60 clara
 z del jackknife (D)	<2 sin evidencia · 2–3 sugerente · >3 flujo génico

D · Glosario

Alineamiento

Hipótesis de que las columnas de una matriz de secuencias son posiciones homólogas. No es un paso previo neutro: es el primer resultado del estudio.

Apoyo

Medida de con cuánta seguridad *estos* datos sostienen una rama. No dice que la rama sea cierta, ni cuántos genes la ven.

Arranque (*bootstrap*)

Remuestreo de columnas con reemplazo. La frecuencia con que una rama reaparece es su apoyo de arranque.

ASDSF

Desviación estándar promedio de las frecuencias de división entre corridas independientes. Mide si dos cadenas llegaron al mismo sitio.

Clado

Un ancestro y todos sus descendientes. Un grupo que deja fuera a alguno es parafilético.

Cladograma

Árbol dibujado sin longitudes de rama: afirma parentesco y nada más.

Cladogénesis

Lo que ocurre en el nodo cuando un linaje se divide. En biogeografía es donde el rango se reparte entre las hijas.

Concordancia (gCF, sCF)

Qué proporción de los árboles de genes, o de los sitios, contiene una rama. Es otra pregunta distinta del apoyo.

Consenso

Árbol resumen de un conjunto. Estricto, de mayoría, semiestricto o codicioso; todos tiran lo que se contradice.

Contrastes independientes

Diferencias entre nodos hermanos, escaladas por sus ramas, que convierten n especies no independientes en $n-1$ observaciones que sí lo son (Felsenstein 1985).

Convergencia (filogenética)

Dos linajes que llegan al mismo estado por caminos separados. Es la fuente de la homoplasia.

Convergencia (de una cadena)

Que el muestreador ya está tomando muestras de la distribución posterior y no del camino hacia ella. Se diagnostica con ESS, PSRF y ASDSF, nunca con uno solo.

Cronograma

Árbol cuyo eje es el tiempo, no el cambio. Requiere un reloj y al menos una calibración.

Cuarteto

Un grupo de cuatro puntas. Tiene tres resoluciones posibles, y contarlas es la base del árbol de especies y de una distancia entre árboles.

DEC

Modelo de dispersión, extinción y cladogénesis para rangos geográficos (Ree y Smith 2008).

Distancia de Robinson–Foulds

Número de divisiones presentes en un árbol y ausentes en el otro. Se rompe con facilidad: una punta mal colocada la lleva a su máximo.

División (*split*)

La partición de las puntas en dos conjuntos que produce una rama interna. Todo árbol no enraizado es su conjunto de divisiones.

Ensayo de calibración

Poner por escrito de qué fósil, de qué acontecimiento o de qué tasa sale cada edad, con su prior. Es la parte de un estudio de datación que más se discute.

ESS

Tamaño de muestra efectivo: cuántas muestras *independientes* equivale a tener tu cadena.

Estado ancestral

Valor reconstruido de un carácter en un nodo interno. Se reporta como probabilidades, no como un ganador.

Estallido temprano

Modelo en que la tasa de evolución de un carácter decae con el tiempo; el modelo de la radiación adaptativa.

Exogrupo

Taxón que se sabe fuera del grupo de estudio y sirve para poner la raíz. Elegirlo mal desplaza toda la historia.

Factor de Bayes

Cociente de verosimilitudes marginales entre dos modelos. Compara integrando sobre todos los valores de los parámetros, no con un atajo como el AIC.

Filograma

Árbol con longitudes de rama: afirma además cuánto cambio hubo.

Gamma discreta

Reparto de la variación de tasa entre sitios en unas pocas categorías, con un solo parámetro de forma α (Yang 1994).

Homoplasia

Parecido que no viene de un ancestro común: convergencia, paralelismo o reversión.

Introgresión

Paso de material genético entre linajes por hibridación. Deja una asimetría que la clasificación incompleta de linajes no deja.

Jackknife por bloques

Estimación del error quitando bloques contiguos de sitios, porque los sitios vecinos no son independientes.

K de Blomberg

Compara la varianza observada de un carácter con la que el browniano predice sobre ese árbol. Mide magnitud, no forma.

 λ de Pagel

Multiplifica las covarianzas entre especies sin tocar las varianzas. Mide forma, no magnitud.

Longitud de rama

Cantidad de cambio esperada por sitio a lo largo de esa rama. En un cronograma, tiempo.

Mapeo estocástico

Sorteo de historias completas del carácter sobre el árbol, condicionadas a las puntas. Convierte probabilidades en cuentas de eventos.

Máxima verosimilitud

Criterio que elige el árbol y los parámetros que hacen más probables los datos observados bajo el modelo.

MCMC

Cadena de Markov por Monte Carlo: el algoritmo con que se muestrea la posterior bayesiana.

Mk

Modelo de k estados para caracteres discretos (Lewis 2001); Mkv añade la corrección por haber muestreado sólo caracteres variables.

Monofilético

Dicho de un grupo que es un clado completo.

Movimiento browniano

Modelo de deriva pura para un carácter continuo: la varianza entre dos especies crece con el tiempo que llevan separadas.

Ornstein–Uhlenbeck

Modelo con una fuerza que jala el carácter hacia un óptimo. Su α se lee como vida media frente a la profundidad del árbol.

Paraflético

Grupo que excluye a alguno de los descendientes de su ancestro común.

Parsimonia

Criterio que prefiere el árbol que exige menos cambios.

Partición

Subconjunto de columnas con su propio modelo: un gen, una posición de codón, un genoma.

PGLS

Regresión generalizada cuya matriz de covarianzas es la del árbol. Da la misma pendiente que los contrastes bajo movimiento browniano.

Politomía

Nodo con más de dos hijas. Casi siempre significa «no sé en qué orden», no «se dividieron a la vez».

Posterior

Probabilidad de una rama dados los datos, el modelo y el prior. No está en la misma escala que un apoyo de arranque.

Prior

Lo que se afirma antes de ver los datos. En datación, la forma con que se declara la incertidumbre de una edad.

PSRF

Factor de reducción de escala potencial ($\hat{R}$): compara la variación dentro de cada cadena con la variación entre cadenas.

Rango nulo

El estado de un linaje que perdió su última área. Es absorbente, y tenerlo es lo que hace real a la extinción en el modelo.

Red de divisiones

Figura que conserva las divisiones incompatibles en vez de tirarlas, dibujándolas como cajas.

Reloj molecular

Supuesto de que el cambio se acumula a una tasa comparable entre linajes. Estricto si es una sola tasa; relajado si varía de rama en rama.

Saturación

Estado en que tantos cambios se han superpuesto que la diferencia observada ya no crece con el tiempo.

Salto fundador (+J)

Una hija que, al dividirse el linaje, se marcha a una sola área fuera del rango del ancestro (Matzke 2013).

Señal filogenética

Cuánto se parecen los parientes más de lo que cabría esperar por azar. Es un patrón, no un proceso.

Tanglegrama

Dos árboles enfrentados, unidos punta con punta. Sin cruces no significa que sean iguales.

Ultramétrico

Árbol en que todas las puntas quedan a la misma distancia de la raíz. Un cronograma de especies vivas lo es.

Vicarianza

División de un rango en dos por una barrera. En DEC una de las hijas se queda con una sola área; en DIVALIKE el corte puede ser de cualquier tamaño.

Y (de Pybus y Harvey)

Compara dónde caen los nodos de un árbol con dónde caerían bajo tasa constante. Negativo, desaceleración; pero faltar especies la imita exactamente.

E Cuando algo no sale

LO QUE VES	QUÉ SUELE SER
«No se encontró ese taxón» al cruzar dos archivos	Casi siempre el guion bajo: <code>Bursera_palmeri</code> frente a <code>Bursera palmeri</code> . El Bloque 9 lo perdona; los demás lo dicen por su nombre. Corrige el archivo, no la lista.
El árbol sale con una politomía enorme	Un consenso con muchas divisiones por debajo del umbral. No es un error: es que los datos no resuelven ese nodo.
La cadena bayesiana no converge	Mira el ESS y el PSRF antes que nada. Si el ESS es bajo sólo en un parámetro, suele bastar con correr más; si el PSRF es alto, las cadenas están en sitios distintos y el problema es el modelo o el prior.
Las ramas salen larguísimas en el análisis bayesiano	El prior de longitud de rama. Con datos divergentes, una exponencial de media 0.1 tira del árbol entero hacia abajo. El panel compara con el árbol de máxima verosimilitud antes de correr: hazle caso.
El OU gana pero la vida media es enorme	Es indistinguible de un browniano. No concluyas selección estabilizadora.
Un modelo +J gana por mucho	Es lo esperable. Reporta cuánto gana y sobre qué modelo; no lo conviertas en dispersión a larga distancia sin más.
El PNG sale en blanco o el programa se niega	Pediste más píxeles de los que un navegador puede dibujar. Baja los puntos por pulgada, o manda el SVG, que no tiene resolución.
Las imágenes no aparecen en el árbol	Falta marcar la casilla de confirmación de cada una. Es deliberado.

LO QUE VES	QUÉ SUELE SER
Los colores del SVG exportado no son los de la pantalla	No debería pasar y hay pruebas que lo vigilan; si ocurre, vuelve a exportar desde el Bloque 12, que es donde el estudio de figuras engancha la exportación.
El informe cita algo que no corriste	No debería: el informe se arma con lo que realmente corrió. Si lo ves, es un error y vale la pena avisarlo.
Un bloque tarda muchísimo	Revisa el número de taxones y de sitios contra la tabla de tamaños de la portada. Los cálculos pesados corren en hilos aparte, así que la página no se congela aunque parezca que no avanza.
Perdiste todo al cerrar	El programa no guarda solo. Arma el paquete del Bloque 12 antes de cerrar; es un solo botón.

F Referencias

Las obras citadas en este manual. El programa conoce muchas más y arma la bibliografía del informe con las que tu estudio realmente usó.

- Adachi, J. y Hasegawa, M. (1996). Model of amino acid substitution in proteins encoded by mitochondrial DNA. *Journal of Molecular Evolution* 42: 459–468.
- Adachi, J., Waddell, P.J., Martin, W. y Hasegawa, M. (2000). Plastid genome phylogeny and a model of amino acid substitution for proteins encoded by chloroplast DNA. *Journal of Molecular Evolution* 50: 348–358.
- Blomberg, S.P., Garland, T. y Ives, A.R. (2003). Testing for phylogenetic signal in comparative data: behavioral traits are more labile. *Evolution* 57: 717–745.
- Bremer, K. (1994). Branch support and tree stability. *Cladistics* 10: 295–304.
- Brown, J.M., Hedtke, S.M., Lemmon, A.R. y Lemmon, E.M. (2010). When trees grow too long: investigating the causes of highly inaccurate Bayesian branch-length estimates. *Systematic Biology* 59: 145–161.
- Castresana, J. (2000). Selection of conserved blocks from multiple alignments for their use in phylogenetic analysis. *Molecular Biology and Evolution* 17: 540–552.
- Cooper, N., Thomas, G.H., Venditti, C., Meade, A. y Freckleton, R.P. (2016). A cautionary note on the use of Ornstein–Uhlenbeck models in macroevolutionary studies. *Biological Journal of the Linnean Society* 118: 64–77.
- Dang, C.C., Le, Q.S., Gascuel, O. y Le, V.S. (2010). FLU, an amino acid substitution model for influenza proteins. *BMC Evolutionary Biology* 10: 99.
- Dayhoff, M.O., Schwartz, R.M. y Orcutt, B.C. (1978). A model of evolutionary change in proteins. *Atlas of Protein Sequence and Structure* 5(3): 345–352.
- Desper, R. y Gascuel, O. (2002). Fast and accurate phylogeny reconstruction algorithms based on the minimum-evolution principle. *Journal of Computational Biology* 9: 687–705.
- Dimmic, M.W., Rest, J.S., Mindell, D.P. y Goldstein, R.A. (2002). rtREV: an amino acid substitution matrix for inference of retrovirus and reverse transcriptase phylogeny. *Journal of Molecular Evolution* 55: 65–73.
- Drummond, A.J., Ho, S.Y.W., Phillips, M.J. y Rambaut, A. (2006). Relaxed phylogenetics and dating with confidence. *PLoS Biology* 4: e88.

- Felsenstein, J. (1978). Cases in which parsimony or compatibility methods will be positively misleading. *Systematic Zoology* 27: 401–410.
- Felsenstein, J. (1985). Phylogenies and the comparative method. *The American Naturalist* 125: 1–15.
- Fitch, W.M. (1971). Toward defining the course of evolution: minimum change for a specific tree topology. *Systematic Zoology* 20: 406–416.
- Garland, T. y Ives, A.R. (2000). Using the past to predict the present: confidence intervals for regression equations in phylogenetic comparative methods. *The American Naturalist* 155: 346–364.
- Gotoh, O. (1982). An improved algorithm for matching biological sequences. *Journal of Molecular Biology* 162: 705–708.
- Henikoff, S. y Henikoff, J.G. (1992). Amino acid substitution matrices from protein blocks. *Proceedings of the National Academy of Sciences USA* 89: 10915–10919.
- Huelsenbeck, J.P., Nielsen, R. y Bollback, J.P. (2003). Stochastic mapping of morphological characters. *Systematic Biology* 52: 131–158.
- Jetz, W., Thomas, G.H., Joy, J.B., Hartmann, K. y Mooers, A.O. (2012). The global diversity of birds in space and time. *Nature* 491: 444–448.
- Jones, D.T., Taylor, W.R. y Thornton, J.M. (1992). The rapid generation of mutation data matrices from protein sequences. *Computer Applications in the Biosciences* 8: 275–282.
- Kass, R.E. y Raftery, A.E. (1995). Bayes factors. *Journal of the American Statistical Association* 90: 773–795.
- Kuhner, M.K. y Felsenstein, J. (1994). A simulation comparison of phylogeny algorithms under equal and unequal evolutionary rates. *Molecular Biology and Evolution* 11: 459–468.
- Le, S.Q. y Gascuel, O. (2008). An improved general amino acid replacement matrix. *Molecular Biology and Evolution* 25: 1307–1320.
- Lewis, P.O. (2001). A likelihood approach to estimating phylogeny from discrete morphological character data. *Systematic Biology* 50: 913–925.
- Lockhart, P.J., Steel, M.A., Hendy, M.D. y Penny, D. (1994). Recovering evolutionary trees under a more realistic model of sequence evolution. *Molecular Biology and Evolution* 11: 605–612.
- Magallón, S. y Sanderson, M.J. (2001). Absolute diversification rates in angiosperm clades. *Evolution* 55: 1762–1780.
- Marshall, D.C. (2010). Cryptic failure of partitioned Bayesian phylogenetic analyses: lost in the land of long trees. *Systematic Biology* 59: 108–117.
- Matzke, N.J. (2013). Probabilistic historical biogeography: new models for founder-event speciation, imperfect detection, and fossils allow improved accuracy and model-testing. *Frontiers of Biogeography* 5: 242–248.
- Minh, B.Q., Nguyen, M.A.T. y von Haeseler, A. (2013). Ultrafast approximation for phylogenetic bootstrap. *Molecular Biology and Evolution* 30: 1188–1195.
- Minh, B.Q., Hahn, M.W. y Lanfear, R. (2020). New methods to calculate concordance factors for phylogenomic datasets. *Molecular Biology and Evolution* 37: 2727–2733.
- Müller, T. y Vingron, M. (2000). Modeling amino acid replacement. *Journal of Computational Biology* 7: 761–776.
- Nickle, D.C., Heath, L., Jensen, M.A., Gilbert, P.B., Mullins, J.I. y Kosakovsky Pond, S.L. (2007). HIV-specific probabilistic models of protein evolution. *PLoS ONE* 2: e503.
- Pagel, M. (1999). Inferring the historical patterns of biological evolution. *Nature* 401: 877–884.

- Patterson, N., Moorjani, P., Luo, Y., Mallick, S., Rohland, N., Zhan, Y., Genschoreck, T., Webster, T. y Reich, D. (2012). Ancient admixture in human history. *Genetics* 192: 1065–1093.
- Pauplin, Y. (2000). Direct calculation of a tree length using a distance matrix. *Journal of Molecular Evolution* 51: 41–47.
- Pybus, O.G. y Harvey, P.H. (2000). Testing macro-evolutionary models using incomplete molecular phylogenies. *Proceedings of the Royal Society B* 267: 2267–2272.
- Rabosky, D.L. y Lovette, I.J. (2008). Density-dependent diversification in North American wood warblers. *Proceedings of the Royal Society B* 275: 2363–2371.
- Ree, R.H. y Smith, S.A. (2008). Maximum likelihood inference of geographic range evolution by dispersal, local extinction, and cladogenesis. *Systematic Biology* 57: 4–14.
- Ree, R.H. y Sanmartín, I. (2018). Conceptual and statistical problems with the DEC+J model of founder-event speciation and its comparison with DEC via model selection. *Journal of Biogeography* 45: 741–749.
- Robinson, D.F. y Foulds, L.R. (1981). Comparison of phylogenetic trees. *Mathematical Biosciences* 53: 131–147.
- Sanderson, M.J. (2002). Estimating absolute rates of molecular evolution and divergence times: a penalized likelihood approach. *Molecular Biology and Evolution* 19: 101–109.
- Sankoff, D. (1975). Minimal mutation trees of sequences. *SIAM Journal on Applied Mathematics* 28: 35–42.
- Steel, M.A. y Penny, D. (1993). Distributions of tree comparison metrics—some new results. *Systematic Biology* 42: 126–141.
- Title, P.O. y Rabosky, D.L. (2019). Tip rates, phylogenies and diversification: what are we estimating, and how good are the estimates? *Methods in Ecology and Evolution* 10: 821–834.
- To, T.-H., Jung, M., Lycett, S. y Gascuel, O. (2016). Fast dating using least-squares criteria and algorithms. *Systematic Biology* 65: 82–97.
- Whelan, S. y Goldman, N. (2001). A general empirical model of protein evolution derived from multiple protein families using a maximum-likelihood approach. *Molecular Biology and Evolution* 18: 691–699.
- Xie, W., Lewis, P.O., Fan, Y., Kuo, L. y Chen, M.-H. (2011). Improving marginal likelihood estimation for Bayesian phylogenetic model selection. *Systematic Biology* 60: 150–160.
- Yang, Z. (1994). Maximum likelihood phylogenetic estimation from DNA sequences with variable rates over sites: approximate methods. *Journal of Molecular Evolution* 39: 306–314.
- Yang, Z., Nielsen, R. y Hasegawa, M. (1998). Models of amino acid substitution and applications to mitochondrial protein evolution. *Molecular Biology and Evolution* 15: 1600–1611.

La herramienta: licencia y cómo citarla

G.1 · Qué es y qué no es

PhylogenyPro es un programa **escrito por completo desde cero**: no carga ninguna biblioteca de terceros, ningún archivo de una red de distribución, ningún código minificado. Todo lo que hace —el motor de verosimilitud, el muestreador, los dibujos, el lector de ZIP— está en su propio código y se puede leer.

Lo que sí contiene de fuera son **constantes numéricas publicadas**: las doce matrices de aminoácidos, la matriz BLOSUM62 del alineador, el código genético y la escala de tiempo geológico. No son la expresión creativa de nadie: son los parámetros de modelos científicos publicados, y el archivo `PROCEDENCIA.md` documenta de dónde sale cada uno y cómo se verificó.

G.2 · Licencia

Se distribuye bajo la **Licencia Pública General de GNU, versión 3 o posterior** (GPL-3.0-or-later). El texto completo está en el archivo `LICENSE`, en la raíz del programa.

I LICENCIAR NO ES CEDER LA AUTORÍA

Elegir una licencia libre es una decisión sobre **qué puede hacer quien recibe el programa**. La autoría no se transfiere, ni se renuncia a ella: los derechos morales del autor son inalienables. Puedes usar el programa, estudiarlo, modificarlo y redistribuirlo; lo que la GPL pide a cambio es que, si distribuyes una versión modificada, la distribuyas con las mismas libertades.

G.3 · Cómo citarlo

En la raíz del programa hay un archivo `CITATION.cff` y un `codemeta.json` con los datos completos y legibles por máquina; muchos gestores de referencias los leen directamente. La forma corta:

Σ CITA SUGERIDA

Barrera-Guzmán, L.Á. (2026). *PhylogenyPro: filogenia molecular en el navegador, del alineamiento al árbol fechado* (versión 1.4.0). Zenodo. <https://doi.org/10.5281/zenodo.23005815>

Ése es el **DOI de concepto**: lleva siempre a la versión más reciente, y es el que conviene citar. Si necesitas fijar exactamente la versión con la que corriste tu análisis —que es lo correcto cuando el resultado tiene que poder repetirse—, toma el DOI propio de esa versión del registro en Zenodo. El de la 1.4.0 es `10.5281/zenodo.23005816`.

Cita además, en la sección de métodos, **los trabajos de los métodos que hayas usado**: el modelo de sustitución, el tipo de apoyo, el método de datación, el modelo biogeográfico. El informe del Bloque 12 los reúne solo, y sólo los que tu estudio realmente usó, que es exactamente la lista que hay que poner.